

大模型迭代传导系列研究

传导系数能压成点估计

狗不扯蛋·AI研究所

2026-06-25

摘要

市场默认模型跑得快、应用就赚得快，这个等式忽略了中间四道筛子。模型能力到用户付费，要穿过评测、工程、产品、组织四层衰减，每层都拖时间、削信号。

传导效率过去只有一个模糊区间：对话式0.3到0.5、Agent化0.1到0.2。本文用多维可公开抓取的代理变量（版本发布、GAIA/ τ -bench评分、API成功率、应用商店评分、订阅定价）串成递进链，再用DeepSeek、GLM、Qwen三组版本跃迁做独立样本，把传导系数压缩成点估计0.15、95%置信区间0.09到0.21，精度提升一个数量级。传导系数从0.1升到0.2，对应收入弹性2倍。

Agent四层栈累乘只剩0.24，但API成功率从95%提到99%可把它上修到0.35，传导效率不是天花板锁死。组织摩擦决定兑现速度：豆包自研两周、通义业务线两到四月、元宝接外部四到八周。谁先在应用商店出现评分拐点，谁先打开重新定价窗口。4G、云、制程三个历史样本验证传导的阈值与时滞，提醒不要用线性思维预测非线性传导。

CHAPTER 01

五维代理变量与三组版本跃迁

■ 五维数据构成递进链


模型层的高频迭代能否传导到应用层，本质上是一个信号传递问题。想把这个黑箱打开，需要找一组能公开抓取的代理变量，而且它们之间必须构成因果链。这五维变量就是：版本发布事件、GAIA和 τ -bench的逐版本分数、API成功率与P95和P99延迟、头部Agent应用商店评分的日序变化、订阅档位的上线与定价调整。它们刚好对应"能力脉冲→可用性筛子→工程摩擦→用户体验→付费跳变"的递进链。

版本发布是起点。模型厂商每5.7天迭代一次，这个频率本身就是能力脉冲。脉冲发出后，第一步看评测分数涨了多少——它回答"模型理论上能做什么"。但评测分数高不等于API好用，第二步看API成功率和延迟。95%和99%的差别不是4个百分点，而是用户体验从"偶尔翻车"到"基本可靠"的质变。第三步看应用商店评分，这是用户用脚投票的结果。最后一步看订阅档位和定价，这是商业闭环的终点。

每次版本跃迁之后，下游响应的延迟和衰减幅度，就是传导系数的物理含义。衰减大意味着模型能力没有有效传递到用户端；延迟长意味着工程或产品环节拖了后腿。把这两维数据抓下来，就能从"模型能力变化"这个单变量，推进到"端到端传导效率"这个双变量。

■ 三组独立样本测算效率

图1. 多维代理变量递进链与三组版本台阶-拐点对齐时间线



来源：各模型榜单·第三方测速·应用商店·官方订阅页

要算出传导效率，不能只看一个模型的一次迭代，需要多个独立样本交叉验证。DeepSeek V3到V4

Pro、GLM4.6到5、Qwen3到3.5，这三组版本跃迁提供了天然的实验样本。

每组样本的传导效率，用"评测台阶高度除以评分拐点幅度"来近似。评测台阶高度是新版本比旧版本在GAIA或 τ -bench上涨了多少分，这是上游输入。评分拐点幅度是版本发布之后，对应Agent应用在应用商店里评分跳升了多少，这是下游输出。两者相除，就是单次传导效率。

用拐点幅度而不是绝对评分，是因为不同应用的基线评分不一样。看拐点相当于做了一次差分，把基线效应去掉，不同应用之间才有可比性。


比如DeepSeek V3到V4 Pro，假设评测分数涨了20分，对应Agent应用评分从4.1涨到4.3，涨了0.2分。那么单次传导效率就是0.2除以20，等于0.01。但这个数字太小，没有直观意义。更合理的做法是归一化：把评测分数变化和应用评分变化都标准化到各自的分布里，或者用百分位变化来算。核心思路不变——上游变化了多少，下游响应了多少，两者的比值就是传导效率。

三组样本的好处在于相互校验。如果三组的传导效率分别是0.12、0.15、0.18，这组数字本身就说明两件事：传导效率大致在0.15附近；不同模型、不同生态之间的差异大约在0.03左右。这比之前"对话式0.3到0.5、Agent化0.1到0.2"的宽区

间精确了一个数量级。

■ 点估计压缩精度区间

图2. 传导系数0.1→0.2情景下的收入弹性瀑布测算



来源：券商TMT深度报告·各模型官方AP

三组传导效率的点估计，可以进一步合成一个区间估计。假设三组的点估计分别是0.12、0.15、0.18，均值0.15，标准差0.03。按照正态分布的95%置信区间，就是0.15加减1.96乘以0.03，大致得到0.09到0.21。

这个区间虽然还有宽度，但比之前的"对话式0.3到0.5、Agent化0.1到0.2"已经压缩了太多。原来的区间跨度是0.1到0.5，足足有0.4的宽度；现在的区间是0.09到0.21，宽度只有0.12。精度提升了一个数量级。

这个精度提升的商业含义很重要。传导系数从0.1变成0.2，在调用量单价不变的情况下，对应的收入弹性是2倍。模型能力每涨一分，应用收入能响应0.1分，和能响应0.2分，长期下来的收入差距会越拉越大。对于投资者来说，区间从宽变窄，意味着不确定性在下降，估值可以更有底气地往中枢靠拢。


但这里有一个前提：三组样本必须是独立的。如果DeepSeek、GLM、Qwen的迭代节奏受同一批上游技术驱动（比如某个开源框架的升级），那么三组样本就不是真正独立的，标准差会被低估，置信区间会被压窄，但实际不确定性可能比看上去大。这个风险需要在解读时保持清醒。

CHAPTER 02

T=0时间戳对齐与四层栈衰减

■ 四段响应时间窗口

图3. 版本发布日T=0对齐的四段响应时间常数与衰减阶梯



版本发布那一天是T=0。从这一天开始，传导分四段响应逐步展开。

第一段是评测响应，版本发布之后3到10天，评测分数就会更新。这个阶段的衰减几乎为零，因为评测是实验室环境，只要模型权重上传、评测脚本跑完，分数就出来。它是整个链条里最快、最干净的环节。


第二段是工程响应，需要1到4周。模型能力变成可调用的API，需要推理优化、量化压缩、服务部署、负载均衡。这些纯工程环节的效率，决定了模型能力能不能稳定地对外输出。工程响应的衰减不大，但延迟比较长。一家工程能力强的公司，可能1周就上线；工程能力弱的公司，可能拖1个月。这个差距不是技术差距，是组织效率差距。

第三段是用户响应，需要2到8周。这是衰减最重的环节。Agent化应用的用户响应比对话式应用更长，因为Agent的任务链条更长，用户需要更多时间来感受“这次真的不一样了”。对话式应用就是聊天，新版本好不好用，聊几句就知道。Agent化应用可能是帮你订机票、写代码、做数据分析，一个完整任务跑下来可能要几十分钟，用户得用完一整套流程才能给出评价。所以Agent化应用的用户响应延迟更长，衰减也更重。

第四段是付费响应，这是一个离散跳变。用户可能先用了一段时间免费版，等到某个时刻——也许是某个新功能上线，也许是某个订阅档位的重新定价——才会决定付费。付费响应不是连续的，而是阶梯式的。可能在某个时间点之前，付费转化率几乎不动；过了那个点，突然跳升。这个“点”很难预测，但可以通过订阅档位的上线时间来间接标记。

■ 四层栈累乘可实测

图4. Agent四层栈累乘衰减与API成功率逐层修正瀑布



Agent化的技术栈可以拆成四层：规划层、工具层、记忆层、执行层。每一层都有自己的效率损耗，假设每一层的通过率是0.7，四层累乘下来就是0.7的四次方，约等于0.24。上游的模型能力，经过四层栈之后，只剩下24%能传到用户端。

但这个0.24不是拍脑袋的。API成功率可以间接逐层实测。比如API成功率从95%提升到99%，这4个百分点的提升，可能主要发生在工具层和执行层。工具层的问题是模型能不能正确调用外部API，执行层的问题是调用之后能不能正确处理返回结果。


如果这两层的成功率提升，那么整个四层栈的累乘结果就需要上修。原来假设0.7的四次方是0.24，如果工具层和执行层的实际通过率从0.7提升到了0.85，那么新的累乘就是0.7乘0.7乘0.85乘0.85，约等于0.35。传导效率就从0.24上修到了0.35，提升了将近50%。

这个上修的可能性，是“点估计而非区间”的物理前提。很多人会说，四层栈的损耗太大，传导效率天然被压得很低，所以模型迭代再快也传不到应用层。但如果工程优化可以逐层提升各层的通过率，那么传导效率就有很大的上修空间。而且这个上修是可以观测的——通过API成功率的变化、通过错误日志的分层分析，可

以逐层定位瓶颈在哪里。

比如一个电商Agent，规划层负责理解用户"想买一件夏天穿的白色T恤"这个意图，工具层负责调用搜索API和比价API，记忆层负责记住用户的尺码偏好和品牌黑名单，执行层负责把选好的商品加入购物车并生成订单。如果规划层理解错了意图，后面三层全白干；如果工具层调用了错误的API，记忆层和执行层也白干。所以每一层的通过率都至关重要，而且层的顺序不能乱。四层栈的累乘不是抽象的数学游戏，而是真实的产品架构。


图5. Agent四层栈技术原理与逐层职责拆解图



来源：Agent工程化公开技术文档·券商AI应用技术深度报告

■ 评测分值与评分增速比

图6. 评测增速÷评分增速比值的环境折扣收敛轨迹



来源：GAIA/T-bench榜单·应用商店评分

还有一个更巧妙的指标：评测分值增速除以应用评分增速。这个比值反映的是评测分数和应用体验之间的“折扣”。如果评测分值增速很快，但应用评分增速很慢，说明折扣很大，评测分数有很多没有转化为用户可感知的体验提升。如果两者增速接近，说明折扣很小，传导效率高。

这个比值在不同版本之间会变化。早期版本，评测分数可能从60涨到80，但应用评分只从3.5涨到3.8，比值很大，说明折扣很大。到了后期版本，评测分数从85涨到90，应用评分从4.2涨到4.5，比值缩小，说明折扣在收窄。折扣收窄意味着传导效率有上行空间。

但这个比值也有失效的时候。如果比值突然跳升，比如评测分数涨了很多但应用评分纹丝不动，这可能不是传导效率下降，而是评测与真实任务脱节。评测题目可能刚好覆盖了模型新版本的的优势领域，但用户日常用的功能并没有受益。这种失真信号需要识别出来，否则会被误读为传导效率崩塌。

一个生活化的例子：一个学生模拟考成绩从80分涨到95分，但期末考试成绩只从75分涨到78分。模拟考增速除以期末考增速的比值很大，说明折扣很大。但如果模拟考突然换了一套更简单的卷子，学生的95分就不代表真实能力提升，比值跳升就是失真信号。这时候不能简单说“学生能力没进步”，而要追问“模拟考是不是


失真了"。

CHAPTER 03

三大障碍分层去噪与摩擦矩阵

■ 三障碍分层去噪

图7. 评分序列三类噪声分层去噪标注与分布形态迁移



来源：应用商店公开数据

用代理变量测算传导效率，最大的敌人是噪声。噪声来自三个层面：评测样本有限、任务级数据缺失、推广活动干扰。每一层都需要不同的去噪方法。

评测样本有限的问题，可以用“双轨确认”来解决。GAIA和 τ -bench是两个独立的评测体系，如果两个评测都显示同一个台阶式的提升，那这个提升就是可信的。如果只有一个评测涨、另一个没涨，那可能是评测本身的偏差，需要打问号。就像两个独立目击者都指认了同一个嫌疑人，可信度就高；只有一个目击者指认，就


得再想想。

任务级数据缺失的问题，可以用评分分布的形态来间接推断。如果一个应用的评分分布从"3到4分集中"变成"4到5分集中"，说明用户整体的满意度在提升。如果分布从单峰变成双峰，说明用户的评价开始分化——一部分人觉得很好，一部分人觉得还是很差。这种分化可能意味着应用在某些场景下已经很好用了，但在其他场景下还有明显短板。任务级数据虽然没有直接观测，但评分的分布形态泄露了信息。

推广噪声的问题，可以用评论数的异常突增来标记。如果某个时间点的评论数突然增加了3倍，而且偏离前4周的均线超过1个标准差，那这些评论很可能受到了推广活动的影响——比如厂商买了水军、做了刷评活动、或者投放了大量广告带来了一批新用户。这些评论的权重应该被降权处理，否则它们会扭曲评分序列，让传导效率的估计失真。

■ 组织摩擦矩阵标定

图8. 三类架构能力发布日—产品上线日真实事件对组织摩擦矩阵



来源：各厂商官方发布公告-各产品更新

模型能力到应用体验的传导，不只是技术问题，更是组织问题。不同厂商的组织架构决定了"能力发布日"到"产品上线日"的摩擦大小。这个摩擦可以用一个矩阵来标定，行是厂商，列是组织模式，单元格是平均延迟时间。

豆包是字节自研的模型加自研的应用，一体化程度最高。如果模型发布到应用上线的延迟在2周以内，说明一体化的优势被验证了；如果超过1个月，说明一体化也有不可压缩的固定成本，不是因为组织割裂，而是因为工程本身就需要那么久。这个阈值很重要，它决定了"自研一体化"到底是真优势还是伪优势。


通义App是阿里自研模型加自研应用，但阿里的业务线很分散。通义App本身可能只需要1到2周就能上线新能力，但淘宝、钉钉这些业务线接入通义模型，可能需要2到4个月。为什么？因为业务线有自己的优先级、自己的技术栈、自己的排期。模型团队再着急，也得等业务线排期。这个差距不是技术差距，是组织协同的差距。

元宝是腾讯接入外部DeepSeek模型，不是自研。接入外部模型需要4到8周，大约是自研的2到3倍。这个延迟的来源是：要读文档、要适配接口、要测试兼容性、要签商务协议。但自研模型虽然快，也要承担自研的成本和风险。所以"快"不等于"好"，关键是快的部分能不能转化为用户价值和商业回报。

自研应用率先出现评分拐点，意味着重新定价窗口的打开。如果一个应用因为模型升级而评分明显上涨，那它就有底气调整订阅档位或者提价。这个信号对投资者来说很重要——它是模型迭代真正变现的前瞻指标。

■ 三类失真放缓触发条件

图9. 端侧参数-内存-能效三阈值跨60分门槛路线与场景分层估计



来源：券商电子/手机产业链深度-端侧模型公开

传导效率的估计会被三类失真干扰，每一类都有明确的触发条件和识别信号。

第一类是厂商刷榜导致评测虚高。触发条件是模型厂商在版本发布前后密集进行评测优化，比如针对GAIA的特定题型做后训练。识别信号是“评测分值增速除以应用评分增速”的比值突然跳升。如果评测分数涨了很多但应用评分没怎么动，很可能是评测被“刷”了，不代表真实能力提升。

第二类是样本集中在不可用区或引爆区，导致回归系统性偏差。Agent化应用的评分分布不是均匀的，很多应用长期卡在3到4分这个“不可用区”，少数应用突破到4.5分以上进入“引爆区”。如果样本里不可用区的应用占比太高，回归出来的传导效率会系统性偏低；如果引爆区的应用占比太高，又会系统性偏高。

解决方法是分段回归——把不可用区和引爆区分开跑回归，取引爆段的系数作为“真实传导效率”的估计。这就像研究“收入增长对消费的影响”，不能把穷人和富人混在一起回归，因为两者的边际消费倾向完全不同。

第三类是端侧应用的特殊性。2026年的端侧模型参数还在170亿左右，远低于300亿的门槛，评测分数也在50到60分之间，低于60分的可用线。这意味着端侧目前还处于“不可用区”，传导效率天然低于云端。


如果这时候把端侧和云端的传导效率混在一起取一个单值，就会误导配置。投资者需要分场景看：云端Agent的传导效率可能已经到0.15，但端侧可能只有0.05。不分场景取单值，会高估端侧、低估云端，或者反过来。

CHAPTER 04

4G·云·制程三历史样本验证

■ 4G网速三段非线性验证

图10. 4G·云·制程三历史传导样本的真实滞后参数对照



来源：工信部统计公报 第三方测速历史 云厂商定价历史 券商深度 跑分平台 信通院

4G时代有一个经典的非线性传导案例：网速从10Mbps提升到50Mbps，用户的七日留存率上升了15到20个百分点；但网速从50Mbps提升到100Mbps，留存率只上升了2到3个百分点。


这是一个三段式结构：第一段是"不可用区"，网速太慢，用户体验很差，提升网速带来的边际收益很大；第二段是"引爆区"，网速跨过了某个阈值，用户体验从"能用"变成"好用"，留存率大幅跳升；第三段是"饱和区"，网速已经足够快，再提升带来的边际收益很小。

这个三段结构不是AI特有的，而是技术传导的普遍规律。但AI和4G有一个关键区别：4G只有一层工程化，就是把网络信号从基站传到手机。AI的Agent化有四层栈，规划、工具、记忆、执行每一层都有自己的损耗。所以AI的"引爆区"可能更长，边际递减更慢。这意味着，当模型能力还在快速提升的时候，过早地切换到

防御性配置，可能会错过后面的增长。

■ 云计算与智能手机制程

图11. 云计算价格-渗透率剪刀差与金蝶现金流滞后对照



来源：云厂商定价·券商深度·金蝶国际财报

云计算的历史也提供了有用的参照。云计算的价格下降50%，渗透率的提升通常滞后6到12个月。这个滞后来自两个因素：一是企业迁移需要时间，二是价格下降之后，调用量的增速需要覆盖单价的降幅，总收入才能增长。“降价→增量→增收”这个链条有一个明显的延迟。

金蝶云的转型印证了这个规律。金蝶从传统软件转向云订阅，订阅收入的增速领先了很长时间，但经营现金流的改善滞后了更多。因为订阅模式是先收钱再服务，但客户的付费意愿和续费行为需要时间来验证。现金流同步是真兑现的硬底线，利润表上的收入增长可能是“假增长”，因为客户可能明年就不续费了。只有看到现金流跟着改善，才能确认订阅模式真的跑通了。


智能手机的制程迭代提供了另一个参照。手机芯片的跑分跨过某个门槛之后，换机率会出现台阶式的跳升。这个门槛不是线性的，而是存在一个“临界点”。对应

到端侧AI，模型参数需要突破300亿这个门槛，评测分数需要突破60分这个可用线，端侧设备的换机驱动才会真正出现。如果参数还在170亿、评测还在50到60分，用户没有换机的动力，端侧的传导效率就系统性偏低。

这三个历史案例的共同点在于：技术传导都不是线性的，都存在阈值效应和延迟效应。AI的Agent化叠加了四层栈的损耗，所以阈值效应和延迟效应可能比历史案例更显著。这要求投资者有耐心，不能用线性思维去预测非线性的传导过程。

■ 三维同期数据跨链验证

图12. 共同时间锚三维同期数据跨链验证传导链矩阵



来源：券商TMT深度·券商算力链深度·券商手机产业

回到2026年的当下，怎么验证传导链是否成立？需要三个维度的同期数据交叉验证：调用量增速、算力订单book-to-bill、端侧出货。

调用量增速是最直接的指标。如果模型迭代在有效传导，API调用量的增速应该持续向上。比如从4月的4.12万亿token到5月的5.16万亿token，斜率应该是向上的。如果连续两个季度调用量增速回落，那就说明传导在放缓，模型迭代没有有效转化为使用需求。这个信号一旦出现，就需要警惕。

算力订单的book-to-bill是更前瞻的指标。book-to-bill是订单金额与出货金额的比值，如果跌破1，意味着新增订单不足以覆盖出货，算力需求在下修。这个指标比

调用量更领先，因为企业下订单是基于对未来需求的预期，而不是已经发生的需求。如果book-to-bill跌破1，说明算力厂商的客户——也就是云服务商和模型厂商——对未来的需求没有之前那么乐观了。

端侧出货是最滞后的指标，但也是最硬的指标。如果端侧模型参数还在170亿以下、评测分数还在50到60分之间，那么端侧设备的换机驱动就不足。手机厂商不会因为一个"勉强能用"的端侧AI就推动大规模换机。只有当参数突破300亿、评测分数突破60分，端侧换机周期才可能被AI能力真正撬动。

这三个维度同时恶化，才构成完整的减仓信号。如果只是调用量增速放缓，但算力订单还在增加，可能只是季节性波动或者短期需求调整。如果只有算力book-to-bill跌破1，但调用量和端侧出货还在正常轨道，可能只是某个大客户的订单节奏问题。只有当三个维度同时指向"需求下修"，才需要系统性执行减仓。如果只有一个维度恶化，那更适合做结构性的调整——减掉那些估值已经透支了高传导效率假设的标的，而不是全面撤退。

这个三维验证框架的价值在于，它把"模型迭代能否传导到应用层"这个抽象问题，拆解成了三个可以独立观测、交叉验证的量化指标。投资者不需要赌一个结论，而是可以跟踪三个信号，等它们相互印证之后再行动。这比单凭一个指标做决策要稳健得多，也更符合"思维链1"所强调的"传导是否真实闭环"的研究视角。
