

大模型迭代传导系列研究

应用贝塔卡在临界点

狗不扯蛋·AI研究所

2026-06-25

摘要

当前AI应用贝塔卡在传播期向验证期过渡的临界点，可以参与，但必须卡仓位。

2026年全球AI资本开支突破2万亿美元，是产业地基也是双刃剑：增速扩张时算力充裕、迭代加速；拐头时算力过剩、单价快降、剪刀差反噬。资本开支先于应用层景气一到两个季度，是天然的宏观领先风控指标。判断周期位置用三把标尺：Token调用量、AI手机渗透率、模型迭代频次，当前读数两盏偏亮一盏待亮——调用量斜率向上且反超美国，迭代频次2025年前九月182次、5.7天一次但能力跃迁收窄存隐患，AI手机渗透率18%到34%未跨45%门槛。


两面历史镜子校准坐标：2019新能源车渗透率跨10%后从 β 转Alpha，2023算力链订单兑现后龙头从 β 切EPS、头腰估值分化。当前赔率高于2023算力链、低于2019新能源车，胜率高于算力链、低于算力龙头。配置纪律是双层减仓加双绿加仓，避开PS超10倍但2027增速预期低于30%的标的。

CHAPTER 01

两万亿资本开支与三把标尺

■ 2026年AI资本开支两万亿是产业地基

图1.全球AI资本开支2万亿地基与双刃属性时间序列



资料来源：第三方研究机构与券商资本开支报告

2026年全球AI资本开支突破2万亿美元，这笔钱覆盖训练算力、推理算力和数据采购，由科技巨头、云厂商、创业公司和各国政府合力承担。它是整个产业的地基——模型层、应用层、芯片层三层楼都架在上面。


2万亿对应的是整条产业链在2026年的“电量预算”。模型训练、推理服务、数据清洗全部消耗算力。2023年ChatGPT爆火时H100一卡难求，根源就是地基突然不够用。此后微软、谷歌、亚马逊、Meta四家年资本开支合计超过两千亿美元，目的是把地基打厚。到2026年预算再翻数倍，才勉强匹配应用层的扩张节奏。

这个地基有双面性。算力充裕时，模型迭代加快，应用工具变强，用户体验提升，付费意愿上升，正向飞轮转动。一旦增速拐头——比如2027年因经济周期或地缘因素，全球AI资本开支增速从50%跌到20%——剪刀差就会出现。算力仍在建设，需求端未能跟上，芯片价格下降，云服务打折，模型API单价年跌10%到20%。那些依赖“高单价、高毛利”叙事的应用公司，收入增速会骤然失速。2万亿既是

燃料也是火药，供给稳定时推进器升空，供给错配时发射架爆炸。

■ 资本开支是天然领先风控指标

图2. 三把标尺赔率-胜率坐标定位与锚定数据条目



资料来源：券商TMT深度、券商手机行业报告、券商大模型迭代跟踪

AI产业有一个关键特征：应用层景气变化比资本开支变化晚一到两个季度。资本开支是火车头，应用层收入是车厢。火车头减速时，车厢靠惯性还能滑行一段，但只看车厢速度的人，发现慢下来时已经迟了。

传导链条清晰：资本开支增速下降→云厂商与芯片公司订单减少→一到两季度后模型公司签约放缓、应用公司客户预算收缩。对配置者而言，不能等应用层业绩变脸才动作，必须盯住火车头。

操作方法：把全球主要云厂商和芯片巨头的季度资本开支加总，算同比增速。连续两个季度增速拐头向下，即使应用层当季财报亮眼，也应拉响警报。这是产业传导链条的朴素逻辑——资本开支是根，应用层是叶，根烂了，叶子再绿也撑不久。

■ 三把标尺：Token量、渗透率、迭代频次

地基之上，需要三把标尺衡量楼体的结实程度：Token调用量、AI手机渗透率、模型迭代频次。

Token调用量相当于AI的"用电量"。每次对话、每个字的生成都消耗Token。数值越高，说明越多用户和企业真正消费AI，反映的是商业化热度。2024年全球调用量还在千亿级别，2025年冲到万亿，2026年还要再翻几倍。斜率越陡，需求越旺，胜率越高。

AI手机渗透率是端侧的临界标尺。当前手机里的大模型功能多为噱头，但当AI助手真正好用驱动用户换机时，行业会发生质变。经验门槛：45%。跨过之后，芯片成本摊薄、软件生态统一、开发者涌入，硬件公司从"卖设备"转向"卖推理订阅"。45%之前，端侧AI只是传播期故事；之后，才是业绩兑现期。

模型迭代频次是叙事新鲜感的生命线。2025年1月到9月，全球主要大模型发布182次迭代，平均5.7天一次。这个频率维持着资本市场的估值预期，类似于大片密集上映才能保住影院人流。但频次高也有副作用，后续展开。

三把标尺读数越亮、斜率越陡，产业贝塔的胜率和赔率越高。它们是判断AI产业周期阶段的核心工具。

■ 锚定真实刻度需五组数据条目

标尺需要具体数据来锚定刻度，共五组。

第一组：全球及中国Token调用量的季度数据。看环比增速和同比增速，关键是增速是否在加速。Token调用量从4.12万亿涨到5.16万亿，环比增速继续走高，即为绿灯。

第二组：AI手机出货量和渗透率。关注渗透率从18%到34%再到45%的路径，以及AI手机模型参数规模从130亿到170亿的增长、16GB运行内存是否成为基础配置。参数越大、内存越足，端侧能力越强，用户付费基础越扎实。

第三组：模型迭代频次与每次迭代的能力跃迁幅度。GPT-3到GPT-4是质变，4.0到4.1可能是量变。频次越高但提升越小，就是边际效用递减的信号。

第四组：全球主要云厂商和芯片公司的季度资本开支及增速。按地域拆分中国、美国、欧洲各自增速，地缘政治会导致资本开支的区域错配。

第五组：头部AI应用的季度收入和付费用户数。比如豆包的付费用户分档及各档ARPU。调用量暴涨但收入不涨，就是剪刀差前兆。

五组数据覆盖从基础设施到终端、从模型到应用的全链条，放在一起才不会被单点叙事蒙蔽。

图3.全球AI资本开支与AI手机渗透率产业趋势时间线

- 全球AI资本开支持续扩张，AI手机渗透率加速提升，2025年成为关键拐点，2027年资本开支增速或放缓，需关注“剪刀差风险”。
- AI手机渗透率在2027年突破45%后，规模效应有望释放，推动生态繁荣与应用深化。


资本开支扩张
AI基础设施持续投入

渗透率跃升
AI手机加速普及

规模效应释放
生态协同与价值释放

全球AI资本开支规模（亿元）

AI手机渗透率（%）



资料来源：第三方产业研究与券商行业深度报告(Alpha派数据库)

CHAPTER 02

三把标尺读数与切换信号

■ Token调用量偏亮且斜率向上

图4.三把标尺仪表盘：两盏偏亮一盏待亮



两盏偏亮 一盏待亮、处切换触发线上



数据来源：券商TMT深度、券商手机行业报告、券商大模型迭代跟踪


Token调用量当前偏亮。2025年某季度全球调用量还在4.12万亿，下一个季度跳到5.16万亿，环比接近25%，且斜率向上——增速本身在加速。

中国有一个额外叙事：反超美国。2023和2024年美国凭OpenAI和Google先发优势领先，但2025年中国大模型在性价比上显出优势，同能力调用便宜30%到50%。这对中小企业和开发者是致命吸引力，中国Token调用量开始追赶并在部分月份实现反超。这折射出全球AI产业链分工重构——美国在高端模型领先，中国在普惠推理主导，制造业故事重演。

深层含义：飞轮在加速。调用越多→反馈数据越多→模型越好用→调用越多；同时调用量越大→云厂商采购芯片扩建数据中心→算力成本摊薄→API价格下降→更多人用得起。2025年这个自强化循环已经转起来且转速加快。对配置者而言，这盏灯亮着意味着产业贝塔方向向上，赔率还在。

■ 迭代频次最亮但边际效用递减

图5.三大切换信号实判与当期维持仓位状态机



资料来源：券商TMT深度、券商手机行业报告、公司/券商应用层跟踪

模型迭代频次是当前最亮的灯。2025年1月到9月全球182次迭代，平均5.7天一次，科技史上空前。资本市场喜欢这种节奏——新鲜感支撑估值高位。

双刃剑在于：如果每次能力跃迁幅度收窄，高频发布就从“惊喜”变为“疲劳”。餐厅每月出新菜，越出越好吃顾客排队；只换摆盘不换味道，顾客就走了。GPT-3到GPT-4脱胎换骨，GPT-4到4.5修修补补。182次迭代若150次是小修小补，市场终将厌倦，估值压缩随之而来。

边际效用递减在AI行业特别贴切。2023年每次迭代能力曲线陡峭上升；2025年同样迭代次数，曲线斜率已经变平。任何技术都有S型曲线——早期突飞猛进，中期放缓，后期趋于成熟。AI正从中期向后期过渡，频次仍高但“估值含金量”在下降。当市场从“数迭代次数”转向“看迭代质量”时，靠发布会维持热度的公司会率先暴露。

■ AI手机渗透率待亮且规模效应未释放

AI手机渗透率当前待亮。2025年全球渗透率在18%到34%之间（各家口径不同），核心结论一致：未跨过45%临界点。18%意味着每五台手机一台带像样AI功能，34%是每三台一台——不低，但不够。

原因：AI手机目前的卖点是“锦上添花”而非“非你不可”。写文案、修图、总结纪要——不错，但不足以驱动换机。科技消费品历史表明，只有功能从锦上添花变为

刚需，渗透率才会陡然加速。iPhone触摸屏、4G移动互联网、5G短视频，均是跨临界点后才飙升。

硬件瓶颈同样存在。端侧AI要好用，模型参数至少130亿到170亿级别，运行内存需16GB基础配置。2025年主流机型仍有不少停留在8GB或12GB，端侧能力被硬件天花板锁住。等下一代芯片量产、内存成本下降，AI手机才能从“能跑”变成“跑得好”，渗透率向45%靠拢速度才会加快。这盏灯目前是黄的。

■ 三大切换信号实判约一绿一待亮一待验

三盏灯对应三个切换信号。

信号一：Token调用量连续两到三个季度环比加速。当前已持续——从4.12万亿到5.16万亿的跳升及后续延续，信号转绿。需求端飞轮在加速，商业化热度在升温。

信号二：AI手机渗透率向45%靠拢并跨过门槛。当前18%到34%，方向向上但距45%仍有距离。信号待亮。一旦突破40%且斜率陡峭化，端侧规模效应将释放，硬件和软件利润模型都将切换。

信号三：头部应用季度收入跃升，取决于豆包等超级应用的付费用户数据。Token调用量涨了不等于收入涨了——如果免费用户占比高、企业客户用低价套餐，调用量换不来利润。豆包的付费分档及ARPU数据尚未充分公开或形成市场共识，信号待验。

当前状态：一绿一待亮一待验，过渡临界点。不是全面牛市也非全面熊市，站在十字路口。

■ 当期纪律：维持仓位，加仓需等双绿

过渡临界点的纪律：维持仓位，不加不减。一盏灯绿说明需求端有支撑，两盏没绿说明端侧和变现尚未确认。此时加仓是在赌另外两盏灯必然转绿——赌对赚，赌错买在半山腰。

加仓条件：至少两个信号同向转绿。Token加速+渗透率破45%=需求端与端侧共振；Token加速+头部应用收入跃升=需求端与变现端确认。单信号不构成大幅加仓理由。过渡期不确定性高，需要多个独立信号共振降低误判概率。


维持仓位的好处是保留流动性：信号走弱可减仓，信号走强可加仓。子弹一次性打光在过渡期很危险。2023年算力链最疯狂时满仓追入者，2024年震荡一年心态崩溃。AI贝塔大、波动也大，过渡期活得久比赚得快更重要。

CHAPTER 03

剪刀差反噬与双层减仓纪律

■ 资本开支滞后回归确认1-2季前置窗口

图6.资本开支增速对景气1-4季滞后扫描相关系数柱




资料来源：第三方与券商资本开支报告、券商TMT深度

验证火车头领先车厢多远的方法：把全球主要云厂商和芯片公司的季度资本开支增速与AI应用层季度收入增速做滞后回归。将资本开支增速分别移后1、2、3、4个季度，跑OLS回归，看哪个滞后期 R^2 最大。若 R^2 峰值落在1到2个季度且相关系数 ρ 显著为正，"资本开支领先应用层1到2季度"就获得统计验证。

这件事的意义：配置者拿到一个定量化前置窗口。不需要等应用层暴雷，资本开支增速拐点即可开始警惕，争取1到2个季度的反应时间。在资本市场，这有时意味着几十个点的波动空间。

■ 反噬五环逐级传导路径

图7. 资本开支拐头五环剪刀差反噬链路与双层减仓



资料来源：资本开支报告、券商TMT深度、综合标尺读数

资本开支增速拐头后，反噬沿五个环节传导，逻辑紧密如多米诺骨牌。

第一环：资本开支增速拐头。云厂商和芯片公司订单增长放缓，削减资本预算，财报体现为资本开支增速下降或指引下调。

第二环：算力过剩，单价快速下降。芯片生产周期长，前期订单仍在交付，供给还在增加但需求增速放缓，算力过剩。直接后果是价格战——云厂商打折，API调用价格年降10%到20%，过剩严重时降幅更大。

第三环：付费占比低于30%，"调用量升收入不升"的剪刀差形成。价格便宜后Token调用量继续涨，但免费用户占比高、付费ARPU下降，收入走平。调用量曲线向上，收入曲线走平，开口即剪刀差，产业在赔本赚吆喝。

第四环：远期想象被证伪，PS压缩，应用层率先杀估值。"调用量升收入不升"连续几个季度后，投资者意识到变现能力不达预期，估值从"PS看未来"切回"PE看现在"。应用层收入增速放缓、利润未转正，龙头可能跌30%，腰部跌50%以上。

第五环：融资降温、研发采购收缩、调用量放缓、算力订单下修、端侧量产放缓、换机周期下修，跨链蔓延。一级市场降温，创业公司融资困难、裁员、收缩研发，产品创新停滞进一步拖累调用量。芯片公司库存积压，AI手机供应链模组厂、代工厂跟着遭殃，整条链条从上游到下游蔓延。

这不是危言耸听。2018年半导体周期、2021年互联网反垄断、2022年新能源回调，每一轮都能在这些环节里找到影子。历史不重复但押韵。

■ 双层减仓纪律：宏观前置与微观证伪

面对反噬路径，需要双层减仓纪律。第一层管"什么时候减"，第二层管"减多少"。

第一层：宏观前置。资本开支同比增速连续两个季度拐头向下时，降低弹性仓位——即对产业贝塔最敏感的股票：中小市值应用公司、高PS的SaaS公司、未盈利模型公司。这些标的贝塔向上涨最快，向下跌最惨。不等应用层财报恶化，火车头减速即减仓，因为有1到2个季度前置窗口。

第二层：微观证伪。三把标尺中任何一个由亮转暗，启动减仓。Token调用量环比加速度转负是第一信号；AI手机渗透率增长斜率由陡变平是第二信号；模型迭代频次从平均5.7天变成15天是第三信号。一个信号转暗，减20%到30%；两个转暗，减50%以上；三个全暗，清仓或极度防御。

两层纪律同向时减仓幅度最大——宏观与微观共振意味着概率和赔率都在恶化。两层纪律背离时以宏观前置为主：资本开支仍向上说明基本面未全面恶化，Token调用量短期走弱可能是季节性或结构性因素，但要提高警惕密切跟踪下季数据。


核心思想：把减仓决策拆分为两个独立维度，宏观指标定时机，微观指标定幅度。不凭感觉，不赌方向，只跟数据走。

CHAPTER 04

历史区间校准与当前贝塔定位

■ 2019-2020新能源车政策转消费切换

图8.2019新能源车跨10%前后估值驱动转业绩驱动行情



资料来源：中汽协产销数据、板块指数行情与估值、产业链公司财报

第一个对标区间：2019年底到2020年初的新能源车。彼时渗透率10%以下，行业靠政策补贴驱动（国补+地补+免购置税），估值靠2030年燃油车全面淘汰的宏大叙事支撑。特征：高赔率、低胜率、传播期。赚的是估值扩张的钱。

关键切换发生在渗透率跨过10%。这是科技消费品经验门槛——跨过之前买单的是政府和早期尝鲜者；跨过之后主流消费者接受，销量超预期，EPS从亏损收窄到转正。驱动力从“估值”切换到“业绩”，波动从“普涨β”切换到“分化Alpha”。2020年之后比亚迪、特斯拉仍大涨，但逻辑变了：之前是信念，之后是业绩。

2019年底新能源车还有一个特点：验证路径短。一辆车好不好卖，三个月看订单、六个月看交付、一年看财报。消费者用钱包投票，数据来得快。渗透率跨过10%后，从“讲故事”到“看业绩”的过渡期只有一两个季度。


2023-2024算力链β转EPS切换

图9. 2023算力β转EPS龙头-腰部估值分化对照

特别算法：

分化度=龙头估值溢价倍数÷腰部估值倍数，比较β转EPS切换前后扩大幅度；
真实PS/PE须回填。

估值倍数（示意性PS或PE）



资料来源：龙头市值与盈利、腰部市值与盈利、代表标的财报

第二个对标区间：2023年到2024年的算力链。2023年中之前，投资逻辑是纯粹β——英伟达股价涨并非因当季利润超预期，而是市场相信AI需要无限芯片。PS和PE扩张速度远快于收入增速，买英伟达、光模块、服务器都是买"AI需要算力"这个信念。信念在估值涨，信念动摇估值跌。


2023年中之后，订单兑现。英伟达财报不再只是"指引好"，而是"当期收入真的爆了"。光模块出货量、服务器backlog纷纷落地。龙头率先从β切换到EPS兑现——估值仍高但有当期业绩锚定。腰部公司订单增速和利润率跟不上，切换后估值分化显著拉大：龙头PS/PE维持高位，腰部被压缩。核心故事：从普涨β到分化Alpha，先兑现者享溢价，后兑现者承压。

教训：提前布局"先兑现者"，而非赌普涨β。2023年初随便买算力概念股可能赚；到2024年只有真有订单、有利润、有壁垒的公司涨，蹭热度的全跌回去。算力链β转EPS切换比新能源车更快，因为芯片订单到交付只要几个季度，不需要建渠道做品牌。

■ 当前AI应用贝塔定位与配置含义

图10.当前AI应用贝塔相对2019新能源车/2023算力坐标校准

避开PS>10倍
2027增速<30%透支



将当前AI应用贝塔放入两个历史坐标系。

赔率：高于2023年算力链，低于2019年底新能源车。高于算力链是因为2023年算力链已涨过一轮、估值反映了远期预期，而AI应用层仍处过渡早期，验证成功的空间更大——很多公司未盈利、PS在10倍以下，一旦验证估值翻倍的潜力存在。低于新能源车是因为彼时渗透率接近10%门槛、验证路径短、兑现快；AI应用层Token到收入到利润中间每一环都可能卡住，渗透率也没有统一口径，市场共识形成更慢。

胜率：高于2023年算力链整体，低于2023年算力龙头。高于算力链因为彼时投资靠信念缺乏定量跟踪工具，现在有Token量、渗透率、迭代频次三把标尺。低于算力龙头因为英伟达2023年已进入EPS兑现期、当期业绩可锚定估值；AI应用层大多数公司仍靠想象驱动，想象驱动的胜率永远低于业绩驱动。

配置含义：可以参与，必须卡仓位。过渡临界点赔率在、胜率比纯猜高，但未到可满仓阶段。加仓条件：至少双绿。双绿之前不超配。避开PS超10倍但2027年增速预期低于30%的标的——估值透支、增速跟不上，市场风格切换时最先被杀。2023年算力链里大量此类公司涨时无人在意、跌时才发现裸泳。AI应用层同样在吹泡沫，"有验证的贵"可持有，"没验证的贵"必须远离。