
Meta算力外租系列研究

Capex见顶多为假拐点

狗不扯蛋·AI研究所

2026-07-03

摘要

Capex增速掉头不等于需求见顶。本报告区分需求驱动型、供给约束缓解型、会计基数型、结构切换型四类放缓，认为只有第一类才接近真实拐点。"折旧/收入比"比Capex增速更早暴露周期拐点，但Token质量决定闭环真伪：若高价值Token占比下滑、低价推理占比抬升，总Token创新高可能只是"伪闭环"。

CHAPTER 01

Capex见顶多是节奏切换

图9. 四大云厂Capex增速分类归因矩阵






图10. 云厂管理层Capex相关措辞的语义变化追踪




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图11. 全球AI推理Token量与训练Token量的月度趋势




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图12. 芯片层/基础设施层/应用层投资增速的剪刀差




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图13. ARR、RPO、收入、折旧/收入比的季度面板




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图14. 前瞻指标与收入指标的增速剪刀差




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图15. 2018-2019云Capex周期的三角闭环验证



数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图16. AI算力Capex-Token-收入三角闭环季度监测仪表盘



数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

■ 需求降温与节奏切换要分清

Capex增速掉头，第一反应不该是“需求见顶”，而是先看管理层在说什么。口径如果还围绕“需求强、供给紧、全年继续投”，更可能是节奏优化、基数抬高、区域和产品切换。只有话风转向“资本纪律、回报约束、利用率不足”，才说明内部开始担心需求不够撑现有投放。

判断Capex放缓类型，可以先分四类。第一类是真需求放缓，训练、推理、企业AI消费、云订单一起走弱。第二类是供给约束缓解，之前超前下单，现在进入消化期。第三类是会计和基数效应，绝对投放还高，只是同比自然下去。第四类是结构切换，训练集群减速，推理和网络、电力、存储还在加速。只有第一类才接近周期见顶，其余三类更多是节奏和结构问题。

■ Capex对收入弹性是真正关键

判断Capex是不是“假拐点”，关键看一块钱Capex未来能带来多少收入。更合理的方式，是把当前Capex和之后几个季度的云收入、AI收入放在一起看。算力建设到上线再到客户使用，中间要跨几个季度，折旧先走，收入后走。

如果Capex增速下来了，但后面几个季度云收入增速没掉头甚至略有改善，说明前期投放还在贡献。看到的“顶”只是斜率回归，不是需求退潮。反过来，如果Capex还在高增，但收入弹性走弱，一块钱Capex换来的收入增量越来越少，就要警惕投放效率在下滑。这种场景下，即使Capex表面很热，底层已经从“高景气扩张”滑向“低效率堆资产”。

■ ARR和RPO比收入更早变脸

云和AI业务很多是先签合同，再按进度确认收入。这样，ARR和RPO往往比收入更早反映需求变化。ARR是年度经常性收入，RPO是在手合同剩余履约义务，两者都带有前瞻性。

如果ARR和RPO还在高增，只是收入确认偏慢，Capex放缓多半是节奏调整。公司看到了后面几年订单，愿意牺牲一点短期利润去提前把资产铺好。真正危险的情形，是ARR斜率、RPO斜率和Capex斜率一起往下，电话会上反复提客户预算收紧、项目延迟、使用量低于预期。那就不是供给端的问题，而是需求胃口在缩小。此时Capex收缩更像被动防守而不是主动优化。

■ 折旧压力是Capex真假拐点放大镜

算力行业投入前置、折旧周期长，一旦大批资产转固，折旧会多年压着利润表。折旧上升而收入还在爬坡，利润率承压很常见，未必是坏事。只要利用率和收入后面能跟上，几季之后利润率可以修复。

问题出在折旧压力高企却长期等不到收入兑现。折旧/收入比一路往上，超过公司过去习惯区间，ARR和RPO又给不了支撑，说明历史Capex在盈利上有失配。这个时候，Capex收缩已经不只是财务优化，而是不得不选。公司会把资源往回报更确定、回收期更短的项目挪，对外口径自然从“积极扩张”转向“控制节奏、提回报”。

反过来，如果折旧抬升，但ARR和RPO增速仍快于收入，就说明订单储备还在累积。利润率承压更多是投资前置的会计结果，而不是需求见顶。在这种背景下，所谓“Capex见顶”，往往是错把会计挤压当成周期终点。

■ 四分类框架识别Capex假拐点

把Capex放缓放进一个可落地框架，可以提高判断胜率。简单做法，是为不同类型的放缓配一套“证据组合”，避免盲目类比。

需求驱动型放缓的证据，是训练和推理Token增速掉下去，企业AI消费放缓，云订单、ARR明显走弱，管理层反复提预算约束和项目延后。Capex见顶在这种情况下更像真拐点。供给约束缓解型放缓，则往往伴随GPU、机房、电力短缺缓和，原先超前下的单子进入投产，新增订单回归正常，话术集中在交付改善和供应链缓和。

会计与基数型放缓的特征，是Capex绝对额仍高，折旧/收入比略升或持平，收入和ARR不弱，解释集中在“去年基数高”“项目转入运营”，并不强调客户问题。结构切换型放缓，则表现为训练集群投放斜率降下来，但推理集群、网络、电力、存储配套还在高位；同时，总Token里推理占比抬升，Agent任务和企业AI订阅增长更快。管理层开始谈“训练与推理结构优化”“从扩容量转向提效率”。

■ 三角闭环失灵才是真拐点

最终看拐点，绕不开“Capex—收入—利润率”这个三角闭环。只盯Capex，很容易被基数和节奏误导，需要把三条边一起看。


第一条边看Capex本身，包括规模、增速和投向。第二条边看收入和ARR，看订单、RPO和Token能不能顺利转进收入。第三条边看利润率和折旧/收入比，看折旧压力是否被新收入消化。真拐点的表现，是单位Capex对应的收入增量明显下降，利润率修复失灵，前瞻订单不再扩张，三边同时不给力。假拐点通常只有一边出噪音，比如单季Capex节奏变化或折旧短期抬升。

只要ARR和RPO还在走高，推理Token和Agent任务还在涨，折旧/收入比还能被收入提速覆盖，Capex增速的拐点更像节奏调整。真正要担心的，是三角闭环一起出问题，而不是某个指标短期回落。

CHAPTER 02


折旧收入比先暴露周期拐点

图34. Capex增速相关图表




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图35. 资本形成层增速相关图表




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图36. 折旧/收入比相关图表




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图37. Token增速相关图表




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图38. 高价值Token占比相关图表




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图39. 训练效率释放GPU时长相关图表





数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图40. 新代际单位Token成本下降率相关图表




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图41. 旧资产现金回收能力相关图表



数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图42. Capex增速相关图表



数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

■ 折旧收入比是闭环的体温计

折旧/收入比的变化，比Capex增速更早暴露真实拐点。原因很直接：Capex先发生在资产负债表，再通过折旧进利润表；收入要等项目上线、客户使用、账单开出才会出现，中间存在时间差。两边节奏一快一慢，差值先在折旧/收入比上体现。

可以把一轮基础设施投资拆成三步：先花钱建机房、买GPU，这是Capex；设备装好点亮，开始计提折旧；模型上线，客户调用，生成Token，最后变成收入。如果第二步走得比第三步快，折旧先上来，收入还在路上，利润表就像被突然加了一道费用。这种挤压期在重资产行业非常常见。

旧代际GPU的经验也能提供参照。API价格往下走，新一代推理芯片性能价格比改善，折旧政策短期不会轻易调，三件事叠加，决定旧卡在现有租金水平下能不能把剩余折旧赚回来。如果新卡单位Token成本下降得比旧卡租金下降快，旧卡要在更低租金下竞争，表面“量增”，实质“价跌”，折旧/收入比自然被推高。

■ 三层面板串起Capex到收入

要让折旧/收入比真正有用，需要放进一张完整的季度面板。面板至少包含三层：资本投入、算力产出、商业兑现，否则很容易把长期趋势看成短期噪音。

资本投入层看当季Capex、累计Capex、在建工程转固节奏，以及折旧政策是否变化。折旧年限选三年还是五年，会显著影响短期折旧/收入比。算力产出层看总Token、推理Token占比、任务结构下的利用率，以及每一美元Capex能产出多少可计费Token。资料中提到，推理Token占比大概在六成以上，说明算力消耗重心已从一次性训练向高频推理迁移。

商业兑现层看API和云收入，单位Token对应收入，租赁价格趋势，以及价格变化和利用率变化是否相互抵消。算力产出撑起的是使用量故事，商业兑现才撑起赚钱故事。折旧/收入比最终要在这一层得到解释。

用这张面板看周期，大致能分出三种状态。真景气时，Capex、Token、收入一起上升，折旧/收入比稳定或下降，说明新增投资被市场消化。伪繁荣时，Capex高增、Token高增，但收入兑现慢于折旧释放，折旧/收入比上行，说明靠堆资产、靠低价Token填满算力。真拐点时，Capex增速放缓，Token增速也没法覆盖折旧基数扩张，单位Token变现继续走弱，折旧/收入比进一步上行，利润表等于在劝管理层“别再投那么猛”。

■ 折旧挤压期早于需求走弱

折旧/收入比值得盯紧的地方，在于利润表会先经历一段“挤压期”。在这段时间里，需求不一定弱，但折旧已经上来了，收入仍在向高位慢爬。

机房建好、GPU装完后，折旧按会计政策开始计提。客户项目却要时间：模型训练、应用开发、企业内部集成审批，最后才变成稳定调用。折旧释放和收入爬坡之间的时间差，构成了挤压期。旧代际GPU上，挤压期表现为折旧照旧计提，但租金被新卡竞争和API降价拖住。旧卡看似还能租出去，真实折旧/收入比已在恶化。

这说明折旧/收入比的拐点，往往出现在需求曲线真正拐头之前。需求总量可能还在涨，只是单位需求价格被压，任务结构偏向低价调用。折旧/收入比上行，先提醒“现在赚得不够快”，随后才在Capex决策里体现为“以后少投一点”。

■ 折旧收入比倒逼资本纪律

折旧/收入比一旦长时间停在高位，Capex收缩就不再是管理层的选择，而是利润表和股东共同推着走。因为这个比率直接影响“新增一美元Capex，几年内能赚回来”的心算结果。


折旧/收入比抬升，毛利率和营业利润率承压，管理层自然会问三个问题：现有资产利用率够不够高？单位Token价格和毛利守得住吗？新的Capex项目回本时间比老项目长还是短？三题答不上来，新Capex就会被砍或推迟。

这种倒逼机制沿产业链向下传导。云厂商从“抢装机”切到“提利用率、提单卡收入、延长资产寿命”，首先削的往往是GPU和服务器新单，光模块、交换机、液冷等配套其后感到边际变冷。应用侧AI热度可能仍在上升，但折旧/收入比恶化后，云厂商会优先压缩回收期长、价格压力大、任务结构不清晰的投资项目，就会出现“应用很热、设备订单开始冷”的背离。

CHAPTER 03


折旧比必须嵌入三角闭环

图61. 四大云厂折旧/收入比增速的四类驱动因素分解面板




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图62. 四类驱动因素对折旧/收入比变化的贡献度时序




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图63. 折旧释放速度、收入兑现速度与ARR转化速度的时滞对比




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图64. 折旧/收入比恶化后各环节订单增速的时滞传导链




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图65. 已签约未确认收入、订单积压与折旧/收入比的背离面板




算法：背离度 = 已签约未确认收入增速 - 折旧/收入比变化率
数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图66. 折旧费用中会计估计变更贡献度与正常转固贡献度拆分




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图67. AI收入增速陡峭化与折旧/收入比高位的组合情景




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图68. 2018-2019年云厂商折旧/收入比、ARR、收入增速的三角闭环时序




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图69. 2000年互联网基础设施折旧/收入比与Capex、收入、利润率的闭环验证



数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图70. 电信运营商折旧/收入比与Capex增速的历史相关性演变



数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

■ 折旧比是资本兑现效率的映射

折旧/收入比的核心功能，是告诉你历史Capex今天兑现得好不好。它是已投产资本在利润表上的映射，反映的是资本兑现效率，而不是孤立费用率。

第一层含义，是过去几季Capex落地了多少。Capex只有转成可用资产开始计提折旧，才进入利润表。折旧上行，说明机房、GPU、网络等资产已经投产，而不是停在在建工程。第二层含义，是收入端能不能跟上折旧节奏。折旧刚性，到了年份必须摊；收入弹性，取决于客户上云进度和AI服务接受度。如果AI收入、推理收入、企业ARR没同步爬坡，折旧/收入比上行就代表“资产先行、需求滞后”。

第三层含义，是新增Capex的边际回报是否优于存量资产。同样的折旧可以来自旧代际集群，也可以来自新架构。如果新Capex带来更高收入密度，折旧/收入比短期上行可能只是“先投后收”。反之，如果新Capex只能维持原有收入甚至摊薄单卡收入，比率上行就是红灯，说明新增一美元Capex回收期在拉长。

■ 四类驱动的周期含义不同

折旧/收入比上行背后，至少要分四类驱动，否则容易得出相反结论。第一类是需求驱动型。AI客户签约放缓，推理调用量增速下降，企业ARR减速，算力已经投

产但可计费负载爬坡跟不上，折旧/收入比上行说明“资产先落地、需求后跟进”的缺口在放大，这最接近Capex见顶的前兆。

第二类是供给约束缓解型。前期因GPU、网络、电力等约束压着的项目集中投产，折旧在一两个季度内跳升，收入端还需要更长时间完成客户迁移和应用上线。比率短期抬头，更像交付集中落地。第三类是会计基数型。折旧年限缩短、资本化比例调整、投产确认口径改变，都会机械性抬高折旧/收入比。收入经营未变，但会计估计改变会制造“假性恶化”。

第四类是结构切换型。云厂商从训练导向转向推理导向，或从内部自用转向外部出租，资产利用方式和结算口径都会变化。历史上“安全区间”就不再好用。研究折旧/收入比上涨时，需要先判断属于哪一类，再讨论是不是Capex顶部信号。

■ 需求驱动型才接近周期顶部

折旧/收入比上行，只有归到需求驱动型，才真正接近周期见顶。其他三类更像投放节奏、供给释放或会计噪音。

判断是否为需求驱动型，可以看三组信号。第一，看AI收入和云整体收入增速。如果折旧/收入比上行时，两者增速明显下滑，更像需求降温；若收入仍稳健，比率上行可能只是阶段性挤压。第二，看ARR和RPO。如果签约合同金额和承诺消费仍在扩，比率上行就很难解释为需求见顶。

第三，看管理层口径。折旧/收入比恶化时，如果电话会重点转向资本纪律、回报约束、利用率优化，而不是供给不足和订单太多，说明内部已经把“继续高Capex”从常态变成例外。供给约束缓解型上行，口径更偏向交付集中和此前受限项目释放；会计基数型上行，往往伴随折旧政策变更说明；结构切换型，则常和业务线拆分、产品组合调整一起出现。

真正危险的是三点同时出现：折旧/收入比上行、AI收入和ARR掉速、管理层强调资本纪律。只有在这种组合下，“Capex见顶”的判断才比较站得住脚。

CHAPTER 04

Token质量决定Capex闭环真伪

■ Token总量不等于闭环成立

总Token创新高，并不能说明商业闭环成立。关键在于这些Token能不能稳定收钱、收多少钱。更实用的框架，是先把Token拆成三层：能不能计费、价格稳不稳定、背后负载是否有持续复购和低价格弹性。

第一层是可计费性。很多调用是免费试用、捆绑套餐或内部测试，消耗了算力但不形成收入。如果这类Token占比太高，利用率好看，收入和利润却难以同步。第二层是价格稳定性，同样可计费，有的是长期合同价，有的是短期促销价，价格战阶段单位Token价格会持续下压。第三层是复购和价权，有些企业会把Agent嵌入核心流程，迁移成本高、愿意长期付费；有些开发者只偶尔调用基础API跑Demo，生命周期短、对价格敏感。

Capex扩张带来供给释放和模型能力提升，供给多了、价格下来了，Token自然容易高增长。真正能构成闭环的是，高价值Token占比不掉，或者低价值Token放量足以补偿单价下行。只看总Token，很容易忽略价格和结构的恶化。

■ 高质量Token占比影响收入弹性

高质量Token占比下滑，增长容易从收入扩张变成利润稀释。常见的路径是：云厂商重投Capex，推理价格被压，低价API和批量推理好卖，低价值Token快速放量，总Token继续高增，但单位Token收入下滑，收入/Capex比、毛利/Capex比开始走弱。

高Capex阶段，企业面前有两条路。一条是优先做Token规模，押注平台活跃度和生态渗透率；另一条是优先守单位Token收入和毛利，稳住价格体系和合同结构。在需求旺、竞争激烈、资本偏热时，第一条路更常被选。问题在于，低价API和补贴流量本质上换的是“量”不是“质”，确实能把GPU占满，也能支撑一段时间继续扩Capex，但如果对应的是价格敏感、可替代、单次价值低的任务，收入弹性就上不去。

此时，Token曲线仍然很好看，收入曲线却没有同步加速。产业链被总量叙事带着走，芯片、服务器、光模块、液冷的订单景气不受影响，但终端回报率并没有跟着Total Token一起抬升。

■ Token质量分层先改订单质量

Token质量分层，先改变的是订单质量，再改变的是订单总量。芯片和服务环节承接Capex扩张最直接，云厂新增训练和推理集群，订单自然充足，产能利用率和收入短期都亮眼。

如果高价值Token不足，情况会逐步变形。云厂从追求“性能领先”转向强调“性价比”，客户愿意延长旧代际GPU经济寿命，偏好旧卡再利用、推理专用化和

资产周转效率。新项目的主诉求变成“在现有机柜多挤点吞吐”，而不是“再上新集群”。

光模块、液冷等环节在高密度集群建设阶段先受益。一旦商业兑现慢于资本开支，后续新增订单结构会从“扩容型”转向“优化型”，改造、升级、降耗比新建多。顺序大致是：先改变订单质量——项目更挑客户、更挑场景；再改变订单总量——当优化空间用完，高质量收入仍难改善，新增项目数量才显著下滑。

市场通常在订单总量下滑时才充分定价风险，回看才发现订单质量早已变味。

■ 用高价值Token证伪“伪闭环”

总Token堆得再高，不足以推翻“伪闭环”判断。真正能证伪的，是高价值Token本身在加速。可以抓四组交叉变量来观察：Agent渗透率、企业模型服务ARR、API价格体系、先进代际GPU紧张度。

如果Agent在真实业务里的渗透率明显上升，说明单用户调用深度在加大，模型开始嵌入工作流。企业模型服务ARR加速，说明企业不只试用而是正式把模型当生产工具。API价格结构往上移但客户没大规模流失，说明能力和场景足以支撑定价权。先进GPU在推理侧再次紧张，说明市场真正需要的是能承接高价值Token的优质算力。

只要这四组变量往高质量方向一起走，即使短期收入曲线不完美，也不能草率定性“伪闭环”。反过来，如果训练效率提升与推理利用率缺口扩大，高价值推理任务占比提升与旧代际GPU利用率下降同步，新代际GPU单位Token成本下降快于旧代际租金下降，就说明低质量Token更容易填满低端供给，高质量Token不足以撬动整体回报率。

在这种阶段，流动性可以继续追AI故事，Capex也可以继续走高，但基本面兑现从“收入共振”退化为“订单先行、回报滞后”。此时研究最该盯的，不是总Token，而是价格、结构、合同化程度和先进资源紧张度这四个领先变量。只要它们长期朝“低质量化”方向走，Capex—Token—收入闭环讲出的更大概率是一个包装精致但质量一般的故事。