
Meta算力外租系列研究

旧代际GPU的延寿定价


狗不扯蛋·AI研究所

2026-07-03

摘要

旧代际GPU能否延长经济寿命，核心不在于训练效率提升释放了多少算力，而在于这些算力在推理端能否转化为稳定可计费负载。本报告提出"每美元Capex可计费Token"的定价框架，认为技术适配性决定从"能跑"到"能盈利"的跨越，折旧年限假设与实际可盈利寿命的错配是延寿叙事的限速器。若商业流量向旧卡短板集中，延寿将从"资本回报重估"退化为"低价续命"。

图82. 旧代际GPU技术参数对比




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

CHAPTER 01


旧代际GPU能否延寿取决于算力与负载咬合

图82. 旧代际GPU技术参数对比




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图1. 旧代际GPU训练效率提升与推理利用率的时间序列对比




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图2. 不同推理负载下的每美元Capex可计费Token产出矩阵




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图3. 主流推理任务对GPU技术参数需求映射




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图4. 推理任务类型分布与GPU代际利用率的相关性




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图5. 新旧代际GPU单位Token成本与租赁价格的动态比较





数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图6. 旧代际GPU租赁价格与利用率的历史走势




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图7. 历史算力资产迁移中的价格下修与利用率修复时间线
资产价格下修幅度 利用率修复节奏



数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要；示意数据）

图8. 旧代际GPU在租赁市场的上架率与租金水平分布



数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

■ 训练释放的算力要被推理吃满

旧代际GPU能不能延长经济寿命，关键在两条曲线能否对得上：训练效率提升释放出的GPU时长曲线，和旧代际GPU在推理端能接住的可计费负载曲线。

训练侧通过FP8、MoE、上下文压缩等技术，减少单个模型的训练时间，看起来同一批卡可以训练更多模型。但这些只是供给侧的技术事实，并不自动变成收入。只有当多出来的训练时长被推理需求稳定消化，形成高利用率和可计费Token，旧卡的经济寿命才被真正延长。

推理侧的约束更复杂。需要有足够多的、可持续的调用，把这些卡的时间填满；需要有清晰的计费方式，把Token与收入挂钩；还需要客户有复购和长期预算，而不是一次性试验。训练释放出来的是“可再分配的GPU时间”，推理要做的是把这些时间变成“可兑现的收入时间”。

如果训练效率释放的供给增速，长期快于推理端可计费Token的增速，旧代际GPU就会出现一个常见局面：卡表面上有需求，实际利用率和单位收入却拉不起来。延寿只停留在折旧年限的会计调整，经济回收并没有改善。

■ 推理市场是分层需求池而不是一个池子

旧代际GPU承接的不是抽象的“总推理需求”，而是一堆按任务类型切出来的小池子。不同池子对硬件的要求不一样，对价格的敏感度也不一样。

短文本问答更像吞吐问题。客户关心的是同样的钱能跑多少Token，只要延迟在可接受范围，旧卡通过批处理和调度优化，仍有机会把吞吐拉高。长上下文RAG更像显存和带宽问题。显存不够、带宽不够，吞吐自然上不去，旧卡能不能吃这块，要看显存规格和系统优化水平。

Agent多轮调用对延迟和抖动敏感。每次调用间要等工具、等API、等等外部资源，GPU很难一直高负载。旧卡在这种场景下，性能短板容易暴露，即便算力够用，用户体验也可能不及新卡。批处理离线推理相对友好。只要在某个时间窗口内完成任务，平台可以在夜间或低峰堆批次，让旧卡保持高负载。

这几个池子加起来，才是旧代际GPU的真实空间。关键不是“推理需求多不多”，而是“哪几块需求落在旧卡适配性比较好的区间”。一旦主流新增需求集中在旧卡短板场景，旧卡就会被自然挤出主战场。

■ 用“每美元Capex可计费Token”重建定价框架

判断旧代际GPU有没有延寿价值，不能停在“缺不缺卡”“还有没有人用”。更有用的框架是：同样一美元Capex，在不同负载结构里，折旧期内能产出多少可计费Token。

纵向看，是利用率分层。旧卡在不同任务上，有多大比例时间上架，有多少时间被实际占用，有多少占用时间产生了计费Token。上架率体现供给投放，利用率体现需求匹配，有效计费率体现收入质量。

横向看，是单位资本产出。把旧卡和新卡放在同一折旧期，对比每美元资本能产出多少Token，再乘以平均单Token价格和毛利率，才能看出谁的资本效率更高。如果旧卡在主流任务上的单位资本产出明显落后，新卡就会抢走大部分高价值负载，旧卡难以形成独立租赁层。

反过来，如果能找到一块任务池，让旧卡的单位资本Token产出差距不大，通过更低购置价或更长折旧期摊薄成本，旧卡就有机会在这块池子里站住。那时，“每美元Capex对应多少可计费Token”，才算对旧卡重新给出了一个新均衡价格。

■ 推理结构偏向短板时延寿故事会打折

推理需求不会平均分布在所有任务类型上。若未来增长主要来自高度互动的Agent、多模态、超长上下文、极低时延API，这些恰好是旧卡最难发挥优势的方向。

Agent需要低时延和低抖动，多模态要频繁在视频、图片、文本之间切换，超长上下文吃显存和带宽。这些场景放大了新卡在延迟、能效、机柜密度上的优势。旧卡即便“能跑”，在性能价格比上的劣势会通过延迟、功耗、机房成本等多条链条放大。


在这种结构下，旧卡更像特定行业或内部系统的专用工具，而不是通用生产资料。它们可能在某些批处理场景活得不错，但整体市场空间会比单纯看“推理Token总量”乐观得多。延寿更多是“再利用价值”，而不是“核心要素继续主宰生产”。

一旦商业流量向旧卡短板集中，问题会沿着一条路径展开：技术适配性变差，先变成利用率折价，再变成租金折价，最后落实为资产价格折价。所谓延寿，就会变成“低价续命”，而不是“资本回报重估”。

CHAPTER 02


技术适配性决定旧卡能否从可运行变成可盈利

图25. FP8训练效率提升率相关图表




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图26. 训练效率提升率相关图表




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图27. 推理任务类型相关图表




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图28. 推理任务类型占比相关图表




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图29. 新代际GPU单位Token成本相关图表




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图30. 旧代际GPU租赁价格相关图表




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图31. 任务类型相关图表




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图32. 旧代际GPU租金降幅相关图表



数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图33. 账面折旧年限相关图表



数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

■ “能跑模型”只是门票

旧代际GPU还能加载主流大模型，只说明“能跑”，不说明“能赚”。要从可运行走到可盈利，需要同时满足显存容量、显存带宽、端到端延迟和瓦特效率几个约束。

显存容量限制模型规模和上下文长度。容量不够，模型要分片或裁剪，系统复杂度上升。显存带宽限制每秒可以读写多少数据，影响高并发和长上下文场景。端到端延迟决定交互体验，特别是Agent类应用。瓦特效率决定电费和散热，对大规模机房尤为关键。

只要有一项明显落后，旧卡在某类任务上的价格权就会丢失。平台只能通过降租金换利用率，用低价去补短板。这看起来利用率不错，实际单位Token利润已经被压到了边缘。

■ 不同任务对旧卡友好程度差别很大

短文本问答对延迟有一个弹性区间。几百毫秒到一两秒，大多数用户可以接受。

平台可以通过堆Batch提高吞吐，让旧卡在较大的批次下跑满。长上下文RAG则受

制于显存和KV cache，显存中要维护大上下文，多轮对话或长文档检索，对内存和带宽都是考验。

Agent多轮调用更极端。链式调用多，等待外部系统多，GPU利用率本身就不容易稳定在高位。延迟和抖动一旦失控，用户体验很快滑坡。旧卡在这类任务上，如果延迟指标难以保证，价格就很难坚持在中高段。

批处理离线推理场景则更宽松。任务对交互不敏感，平台只要求在某个时间段内整体跑完。旧卡可以在夜间或非高峰集中承接，通过长时间满负荷运行，把单位折旧和电费压下来。这里技术适配性和运营策略较容易配平。

所以，技术适配本质上是“具体任务”和“具体硬件”的相容性。有的任务天然偏爱新卡，有的任务可以接受旧卡。旧卡的重定价，不会平均地发生在所有任务上，而是随着任务结构变化，在不同细分场景上分段发生。

■ 技术适配性通过定价直接传导到资产价值

租赁市场价格不是凭空拍的，会把技术适配差异一层层映射出来。旧卡技术适配性好不好，最终表现为三件事：可持续利用率、可接受的租金上限、单位Token成本。

某类任务如果在旧卡上利用率高，延迟和稳定性又达标，平台就有机会用中等偏上的价格签中长期。可计费Token产出稳定，资产回报可以预测。资本市场也更愿意给长寿命假设。

反之，如果某类负载在旧卡上延迟频繁超标，显存又是硬伤，平台就只好在短期、机会型需求上打低价游击战。利用率上下波动，租金随行就市，资产价值更接近残值。折旧年限看似还长，经济寿命已经打折。

从这个角度看，技术适配性不仅是工程团队的指标，还会通过价格、合约条款和折旧政策，反向改变旧卡的生命周期。旧卡能否从可运行跨到可盈利，就是看“技术参数—任务结构—价格体系”三者能不能形成闭环。

CHAPTER 03

折旧错配是旧代际GPU延寿叙事的限速器

图51. 旧代际GPU拍卖/合约/现货价格分位数与负载类型对应关系






图52. 旧代际GPU合约价格与剩余折旧覆盖能力的匹配度




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图53. 负载结构变化到三类价格重新形成稳定梯度的时间差




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图54. 技术适配性指标与租金波动率的背离程度




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图55. 旧代际GPU在高价值负载中的调用份额与总推理需求增速对比




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图56. 拍卖/合约/现货价格价差与旧代际GPU利用率的关系




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图57. 旧代际GPU租金覆盖剩余折旧的能力与利用率分层关系




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图58. 传统IDC标准化进程与长期合约占比的历史趋势




数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图59. ASIC/FPGA历史价格与通用GPU的估值偏离度



数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

图60. 云市场现货与预留实例在资产定价中的权重历史演变



数据来源：Alpha派数据库（行业数据库/券商报告/财报纪要，示意数据）

■ 真正约束不是“有人租”，而是能不能赚回折旧

旧代际GPU租得出去，不说明这笔投资一定赚到了。决定资产寿命的，是整个折旧期内，租金能不能覆盖原始投入、运营成本和合理回报。

这里至少有三条线要一起看。第一条是API定价权，上层定价能力被压得越狠，下层可分到的毛利越少。第二条是新一代推理芯片的性能价格比。新卡单位算力成本越低，旧卡在价格战中越被动。第三条是云厂商内部的折旧政策。折旧年限设得越长，历史投资负担越重。

若API价格一路往下，模型厂商和云平台把算力效率提升的大头用在降价和补贴上，下游租赁市场即便调用量不错，也很难拿到厚毛利。旧卡为了留在牌桌，只能靠降低租金换利用率。

当新一代芯片在单位延迟、单位瓦特、单位机柜密度上优势明显，客户迁移的理由就不只是“新卡更快”，而变成“旧卡撑不回折旧”。折旧年限一旦比实际盈利寿命长，账面上的资产价值会显得虚高，真实回报已经掉下来了。

■ 折旧假设快于商业重定价时，延寿会半途失速

云厂商在投产时就会确定折旧年限，这往往参考历史代际更替节奏。如果实际商业寿命因技术迭代加速而缩短，就会出现折旧和盈利寿命错位。

一开始旧卡还看起来不错。租金有，利用率也有，折旧按计划计提。但随着新卡上架、API价下行、任务结构迁移，旧卡租金和有效利用率会一起被压。到某个点，折旧覆盖能力开始恶化。折旧政策不调整时，折旧/收入比抬升，ROE和ROIC下行，管理层扩Capex的动力自然减弱。

这时如果市场还在讲“推理需求增长，旧卡都能消化”的故事，延寿叙事就会显得乐观。只要把折旧覆盖能力拉出来看，就会发现，延寿只是低价拉长使用年限，并没有恢复原来的资本回收节奏。

■ 增长路径从“量增价稳”到“低价续命”

折旧错配出现后，旧卡往往会经历三段式的增长路径。

第一阶段，推理需求上来，旧卡短期享受“量增价稳”。利用率提升，租金还没明显下调，看上去回报不错。

第二阶段，新卡单位Token成本快速下降，API价格战开始。旧卡为了跟上，只能降租金。利用率可能还在上涨，但价跌速度更快，毛利率被挤压，这是“量增价跌”。

第三阶段，租金跌到接近边际成本，新卡提供更好的延迟和功耗表现，旧卡就退到细分场景和中长尾客户。租金稳定在低位，利用率可能还行，但折旧早已难以覆盖，这是“低价续命”。

这条路径说明，折旧错配不会立刻把旧卡变成“负资产”，而是缓慢把它们从核心资产推到边缘资产。延寿若没有折旧重估配合，最后更像库存清理，而不是资产再定价。

CHAPTER 04

真正的延寿是找到新清算价和新纪律

■ 历史上旧硬件靠再定价延寿

回看硬件迭代历史，旧设备延寿成功的例子，不是靠继续留在原来高端场景，而是通过再定价和重新定位。

CPU服务器是经典案例。高性能计算时代的设备，并不是自然延寿到云计算时代。只有那些能在虚拟化、多租户、弹性调度环境下保持高利用率的服务器，才成了云基础设施。其他设备加速淘汰，折价处理。

在特定推理场景中，ASIC和FPGA对GPU形成替代，也是类似逻辑。GPU功能没有消失，但在固定模型、稳定流量、成本约束下，专用硬件把“能跑”变成“要更便宜地跑”，GPU退居二线。

这些例子的共同点是三件事：原用途里的边际收益明显下降；新用途对绝对性能要求低一些，对成本和稳定性要求高很多；资产价格先经历一轮非线性下修，再在新市场找到稳定回报。

■ 旧代际GPU要找新需求池

放到H100、H200等旧代际GPU上，重点就不在“还能训练”“还能推理”。真正的问题是：有没有一个足够大的需求池，性能要求不苛刻，但对成本和生态兼容性要求更高，让旧卡能形成新的均衡。

一类可能的需求池是中腰部企业的内部推理平台。这些企业不追求效果最好的模型，更看重成本可控、部署简单、生态成熟。旧卡在这类场景中，凭借成熟软硬件和存量规模，可以保持较高上架率。

另一类是批量离线推理、日志分析、辅助模型服务等。任务对时延不敏感，对单位Token成本敏感，可以长时间批量执行。旧卡靠更低购置价和拉长折旧期，把单位Token成本压下来，在这类任务中形成“性价比位”。

在这些新需求池里，旧卡不再需要训练时代的溢价，只要做到利用率稳定、租金合理、Token产出可预测，就可以构成一种“次优但稳”的资产层。

■ 清算价格与利用率纪律是延寿核心

旧代际GPU的真正延寿标志，不是“还在干活”，而是“形成了新的清算价格”和“遵守新的利用率纪律”。

清算价格，是市场愿意长期支付的租金区间，体现单位资本的长期回报。利用率纪律，是平台在这个价格水平下，能否长期把利用率稳定在某个区间，不因为短期波动频繁打折。

如果新需求只是阶段性消化库存，旧卡在某轮景气高点被拿去填短缺，很快又被新卡替换，这更像库存出清。价格一次性下台阶，利用率短期冲高后回落，经济寿命并未真正拉长。

反过来，如果旧卡在某个细分市场长期保持高上架率、稳定利用率和可预测租金，就说明它们完成了一次资产再定价。“每美元Capex可计费Token产出”这条线才有机会重新抬高，延寿叙事才有现金流支撑。

所以，看旧代际GPU要聚焦两个问题：哪类场景旧卡能跑出新的价格，哪类场景旧卡能坚持新的利用率纪律。只要这两点成立，旧卡就不会自然沦为负债；反之，即便推理需求总量继续增长，没有清晰分层市场和清算价格，旧卡也难逃加速折价。

CHAPTER 05

租金分层是“每美元Capex可计费Token”的前提

■ 旧卡对应的是多个割裂市场

旧代际GPU的经济寿命能否延长，取决于训练释放的GPU时长，在推理端能否被稳定利用率和可重复计费的Token消化。如果做不到，只是把闲置时间从训练侧挪到推理侧，本质上还是闲置。

同一张H100或H200，落在不同负载上，经济含义完全不同。短文本问答看吞吐和单位成本。长上下文RAG看显存和带宽，吞吐不一定高，但显存被占用时间长。Agent多轮调用对时延和抖动敏感，哪怕算力够，抖动也毁体验。

这意味着，旧卡并不是进入一个统一推理市场，而是被拆进几个割裂的小市场。在短文本场景，只要吞吐还能堆，旧卡可以靠低价“填仓”。在长上下文和Agent场景，旧卡很快被新卡挤出，只能捡边角活。

研究旧卡租金不能用一个“平均价格”概括。必须先回答一个问题：这个价格是在什么负载、什么时间、什么服务质量下形成的。卡和负载不一一对应，“每美元Capex可计费Token”这个指标就会被平均数污染。

■ 拍卖、现货、合约对应不同供给形态

拍卖价、现货价、合约价表面上是三个市场，本质上对应三种供给形态和时间颗粒度。

拍卖多对应临时腾出的碎片时段。例如训练效率提升后，晚上空出来几个小时。这些时段如果不卖就是纯闲置，于是丢到拍卖或现货里，以低价出掉。从资产视

角看，这是库存盘活，不是资产重估。

现货多对应短期的边际供需冲击。训练或推理短期抢资源，租点短期卡。价格波动大，但持续性有限。合约更接近长期能力定价。客户为稳定供给、SLA和可预测延迟支付溢价。

因此，拍卖和现货价下探，不必马上解读为“旧卡资产塌方”。只要中长期合约价仍坚挺，说明客户仍愿意为稳定能力付溢价。反过来，如果合约价也向拍卖价靠近，才意味着可计费Token的“可持续性”在松动。

■ 不分负载的平均价会误导Capex回收测算

很多测算喜欢拿一个“旧卡平均租金”算回本周期，这其实风险不小。这个平均价通常把不同负载、不同时段、不同行权方式混在一起。

拍卖里多是碎片时段，负载以短文本和批量任务为主，迁移灵活度高。现货价高度受阶段冲击影响。合约价受最低利用率、最低单卡收入、任务结构约束，和折旧回收直接相关。

把三类成交混在一起求加权价，再拿这个价算“每美元Capex能回多少Token”，容易出现系统性高估。因为高质量负载和高价Token往往已经迁到新卡，旧卡更多承接低价、波动大的订单。平均价好看，实际质地一般。

更可靠的做法，是构建一个“价格—负载—机制”的矩阵。一边是任务类型：短文本、长上下文、Agent、多模态、批处理等。另一边是定价机制：拍卖、现货、合约。每个格子对应自己的利用率曲线和Token产出曲线。只有在格子层面算Capex回收，再汇总，才有资产定价意义。

■ “每美元Capex可计费Token”要绑定服务标签

“每美元Capex可计费Token”这个指标听上去简洁，但“可计费Token”本身也有档次。不同Token对应不同价格、不同合同质量和不同复购稳定性。

例如，同样是100万Token，一种来自企业内部RAG应用，有最低调用量和服务等级约定，价格有锁定条款。另一种来自公有云上的实验调用，开发者用完就走，价格竞争激烈。显然，两者对折旧回收的贡献完全不同。

如果价格体系不区分这种差别，“每美元Capex可计费Token”就会变成一个“摇晃的锚”。高质量Token多的季度，指标好看；低质量Token占主导时，指标瞬间下滑。研究员很难在噪音中提炼出稳态结论。

解决方法就是两步。第一，把服务质量标签绑定到价格和产品上。标清延迟上限、并发保证、中断补偿、最低调用、违约条款等。第二，把不同服务质量下的利

用率和Token产出单独统计，而不是混在一个口径里。

当一张旧卡在某类服务质量下，既维持稳定利用率，又产出足够Token，合约价还能覆盖折旧，这一格的“每美元Capex可计费Token”才是真锚。有了这一层，再谈资产延寿才有说服力。

■ 合约价格是折旧回收的最后防线

旧代际GPU能不能被看作长寿资产，关键看合约价能否覆盖剩余折旧。合约价如果也被压到拍卖价附近，说明市场不再认可其长期服务价值。

从资产视角看，一份好的合约至少要锁三件事：最低利用率，最低单卡单时段收入，以及与负载结构匹配的Token结算效率。只锁机柜或时间，不锁调用质量和Token产出，合约收入就可能只是表面稳定，内在回收能力却不稳。

极端一点，如果合约锁了资源，但未锁API价格和Token结算方式，上层平台一降价，旧卡这头就得跟着降。合约形式上还在，折旧回收能力已经缩水。

放在延寿讨论中，一个核心问题就是：在现在的合约结构下，这批旧卡能否在剩余折旧期内，持续产生足够多、价格不塌的可计费Token。如果答案是否定的，“延寿”多半只是会计上的延后减值，而不是资产重估。

■ 不按负载分层的市场，会把旧卡推向库存属性

如果租金发现不按负载分层，旧卡就会在训练、推理、拍卖、现货之间漂泊。训练端被新卡替换，退居次要角色；推理端高价值任务偏爱新卡，旧卡接杂活；拍卖和现货用来出清碎片时段。

这种状态下，旧卡更像库存资产，而不是产能资产。资产方心态也会变，从追求长期回报转为“多回一点是一点”。价格发现脱离基本面，更多受短期供需和情绪驱动。

要避免走到这一步，研究和定价必须回到起点：按负载分层，再按服务质量分层，再按租赁机制分层。只有在这个格子系统里，看旧卡还在哪些格子有优势，还在哪些格子守得住合约价，才能说它具备“延寿”的基础。否则，旧卡的延寿故事，很容易演变成“价格一路打到清算，最后集体减值”的财务故事。

CHAPTER 06

客户结构决定旧卡是可出租还是可定价

■ 大客户锁定是从可出租到可定价的起点

旧代际GPU能不能被当作资产，而不仅是设备，取决于客户结构。核心问题不是“有没人租”，而是“是谁在租、租多久、续不续、跑什么负载”。

如果租户主要是短周期、碎片化、机会型项目，机柜看起来很忙，收入却高度不稳定。这种状态下，旧卡更像“现货机器”，难以做中长期收益估算。

反过来，如果大客户占比高，合约期限长，续约率稳，负载结构与旧卡技术适配度高，情况就不同。算力利用率波动收敛，Token吞吐中枢清晰，单位Capex对应的Token产出更可预测。这时旧卡才开始具备被DCF估值的基础。

旧卡能否被重定价，本质是一条链：训练效率释放算力时长，旧卡接住推理和Agent负载，形成稳定利用率和可计费Token，覆盖剩余折旧并延长经济寿命。客户结构就是中间那颗齿轮。这颗齿轮不稳，上游技术进步和下游租金表现都站不住。

■ 客户结构通过供需匹配效率影响定价

客户结构改变旧卡定价，不仅在情绪层面，更是在供需匹配效率层面。

不同任务对显存、带宽、延迟、功耗约束各不相同，旧卡在不同任务上的性价比曲线也不同。客户群自然分布在不同负载上，最终反映到利用率和租金上。

一个主要服务低时延不敏感、批量化、成本优先场景的算力池，旧卡更容易形成“次优但稳定”的供给层。任务批量进来，排期可预测，工程团队可以围绕这类任务优化系统。客户集中度高未必是坏事，反而有利于做稳定Token产出。

反过来，如果商业流量集中在高复杂度、高服务质量的Agent和超长上下文场景，高价值客户会优先绑定新卡，旧卡承接的就是更碎片、更临时的负载。客户结构看似分散，本质是“好客户在别处”，旧卡在扮演补位角色，很难支撑有质量的资产定价。

客户结构背后至少有三组驱动：需求产业化程度、供给替代压力、合同机制设计。需求越成熟，合同越长期；新卡单位Token成本下降越快，旧卡续租风险越大；合同越能把波动调用转成可融资现金流，旧卡越有资产属性。

■ 客户结构要同时守住量、价、利三条边界

客户结构要支持资产定价，不仅要稳，还要稳在正确水平。简单说，要同时守住利用率上限、租金中枢和折旧覆盖三个边界。

先看利用率。训练释放出来的时长，要被推理端利用率曲线吃掉。大客户锁定本身不等于高利用率，关键要看大客户绑定的负载是否与旧卡适配。如果签的是延迟极敏感、带宽需求极高任务，旧卡即便忙，也不一定忙得高效。

再看租金中枢。客户集中度高，价格更多通过合同议价确定。好处是波动收敛，坏处是定价权集中。一旦新代际单位Token成本持续下降，大客户会用议价权把旧卡租金压到接近边际成本。租金表面稳定，资产安全边际在变薄。

最后看折旧覆盖。单位时间能回收多少折旧，要至少不低于账面折旧进度。这既依赖单位时间Token产出，也依赖每个Token净收入。如果“单位期可回收折旧”长期低于账面折旧，无论客户结构多稳，旧卡也只是延缓出清。

对研究员来说，一个实用提问是：当前这批客户，能否同时撑起Token产出、租金中枢和折旧回收三条线。如果三条线只成立一两条，旧卡还停留在“可出租”阶段，谈不上“可定价”。

■ 历史案例表明客户分层带来估值分层

云计算和IDC市场提供了现成对照。预留实例和现货实例，是两条完全不同的估值逻辑。预留实例把客户长期需求变成可规划现金流，现货实例处理的是剩余产能。

旧代际GPU如果主要依赖类似现货的碎片需求，“每美元Capex可计费Token”更像高频交易指标，波动大而难以做中枢判断。只有当部分客户愿意通过预留、保底或调用承诺锁定旧卡，算力资产才有机会向“基础设施”靠近。

传统IDC也说明，大客户集中和散户多，并无绝对优劣。集中度太高且缺乏健康议价结构，会把资产安全性绑定在少数客户上；过度散户化则抬高获客和空置成本，提高折现率。旧代际GPU最危险的，是表面上客户结构看似健康，实际需求高度同步且依赖短期风口。

CPU服务器历史经验还告诉我们，一旦硬件进入成熟代际，资产回报由任务标准化、合同期限和调度规模化决定，而不是由峰值性能决定。旧代际GPU正在走进这一阶段，性能仍重要，但溢价来自运营匹配。

沿着这个思路，对旧代际GPU的客户结构分析，需要结合四个维度：客户集中度变化与利用率波动是否同步；合同期限与租金折扣与空置改善的关系；行业结构与设备技术代际的匹配；在新卡压价时，老资产能否维持折旧覆盖。回答清楚这些问题，才能分辨哪些Token可预测，哪些现金流值得资本化，哪些算力只是阶

段性的现货故事。
