
系统效率溢价系列研究

HBM有效供给才是定价锚

狗不扯蛋·AI研究所

2026-07-04

摘要

内存带宽增速首次超越算力增速。昇腾从910C到970，带宽翻了4.5倍，算力只翻了10倍，带宽与算力的比值从1:2.5变成1:1.7。数据供给能力正在超越算力本身，成为系统升级的首要变量。

HBM的有效供给被三层漏斗压缩：DRAM晶圆可分配产能、TSV堆叠良率损耗、代际切换重叠损耗。有效供给的增长曲线天然滞后于有效需求。SK海力士把2026年全部产能锁定，供应紧张将延续到2027年。HBM4的溢价率预计达到30%，高于HBM3E的20%。

HBM产业链不同环节适用三套估值体系。颗粒厂适用PB与PE，接口芯片适用PE辅以PS校验，测试设备适用PE与EV/EBITDA。价格下行期的估值韧性排序：接口和控制器最硬，测试设备次之，HBM颗粒再次，模组制造最脆弱。份额提升本身不是安全垫，毛利率稳定才是。

国产HBM2/3的替代窗口由海外对华供给受限程度定义，而非代际差。最佳介入时点是海外有效供给向非中国客户倾斜、国内库存滑向紧平衡、国产方案完成关键客户验证三者重叠的区间。投资者需要建立的思维模型，不是"替代=必然盈利"，而是"替代在特定窗口内发生才能盈利"。

CHAPTER 01

HBM3E到HBM4切换期决定景气窗口

图7. Memory Bandwidth vs Compute Growth Race





图8. HBM Supply-Demand Balance & Pricing Framework



Source: TrendForce / Broker Models

图9. HBM Generational Transition: Structure vs Volume





图10. Ascend Single-Chip HBM Capacity & Bandwidth Leap



■ 结构切换期新代良率低导致有效供给低于设计值

HBM4的量产时间表已经清晰。SK海力士2026年下半年向主要客户交付工程样品，2027年进入规模量产。美光2026年Q2正式量产出货，下半年产能爬坡。三星2026年Q2启动量产交付，但HBM4量产时间表仍偏保守。TrendForce预测，2026年HBM总出货量将突破300亿Gb，HBM4在2026年下半年正式超越HBM3E成为市场主流，到2027年Q4占比超过80%。

但"成为主流"不等于"产能释放完毕"。新代产品初期的良率和认证进度，使有效供给始终低于设计值。三星HBM4E的可靠性测试良率刚提升到70%以上，行业通用的成熟良率门槛是80%及以上。HBM4的整套堆叠、封装与测试工艺还在收敛期，后续良率有望加快，但当前70%的水平意味着每生产100片，有30片要回炉或报废。这个损耗率直接吃掉名义产能。

认证进度是另一个隐形杀手。HBM4要配套英伟达下半年落地的Vera Rubin芯片，以及明年推出的Vera Rubin Ultra。芯片和内存的认证是双向的，任何一方的时序调整都会拉长周期。美光CEO在2025年底的业绩电话会上说，2026年HBM的所有价格和销量协议均已敲定，但HBM4的产能目标定在每月1.5万片晶圆，只占到美光整体DRAM产能的一小部分。头部客户已经提前锁单，但产能释放的斜率是受限的，不是不想快，是快不起来。

旧代产品不会马上消失。Blackwell Ultra的需求提前锁定了绝大部分HBM3E产能，2026年AI算力的最大供应链瓶颈之一仍然是HBM，而且是HBM3E和HBM4同时紧缺。不是新代产品一出来旧代就退休，而是两者在产能分配上互相挤压。

■ 昇腾对HBM需求是容量带宽双重上跳

昇腾的内存配置变化，是观察有效需求上跳的最佳样本。910C是128GB容量、3.2TB/s带宽。950PR维持128GB，但带宽降到1.6TB/s，这是为了Prefill阶段优化成本；950DT跳到144GB、4TB/s，开始发力Decode和训练。960直接翻倍到288GB、9.6TB/s，970维持288GB容量，但带宽再跳到14.4TB/s。

这组数字说明两件事。第一，国产高端算力芯片对HBM的需求不是单维度增长，而是容量和带宽交替上跳。950PR用更低的带宽证明"够用就好"也是一种策略，但950DT和960用翻倍的容量证明，训练场景对局部缓存的胃口没有上限。第二，970维持容量、提升带宽，说明到了一定阶段，带宽比容量更紧迫。这呼应了前面的核心判断：数据供给能力已成为决定系统代际跃迁的首要变量。

推理端的变化同样显著。950PR专攻Prefill，950DT主攻Decode，这种分工意味着推理不是单一芯片能解决的，而是需要内存架构的差异化配置。Prefill需要吞吐大

量数据，带宽是瓶颈；Decode需要持续读取缓存，容量是瓶颈。推理场景对HBM的需求，从"有就行"变成了"要配对"。

更隐蔽的趋势是每单位算力所需的HBM含量在上升。910C的算力是800TFLOPS，配128GB HBM，每TFLOPS对应0.16GB HBM。970的算力是8PFLOPS (8000TFLOPS)，配288GB，每TFLOPS对应0.036GB。看起来单位算力需要的HBM在下降，但要注意数据格式从FP16进化到FP8、FP4，实际有效算力密度提升的同时，对数据搬运效率的要求更高。带宽从3.2TB/s到14.4TB/s，增长了4.5倍，远超算力增长的10倍。这个交叉点意味着，HBM在系统总成本中的占比不会下降，反而会因为带宽溢价而上升。

■ 观察HBM4是替代还是资源重分配

HBM4量产后，对HBM3E的影响是理解景气窗口的关键。两种可能性：一是HBM4完全替代HBM3E，旧代产能迅速淘汰，新代产能承接全部需求；二是HBM4仅重新分配资源，HBM3E继续供应中低端算力芯片，新旧两代长期共存。

当前的数据指向第二种。Blackwell Ultra锁死了大部分HBM3E产能，说明即使HBM4量产，高端训练芯片仍需HBM3E作为备份和过渡。美光的策略更明确：HBM3E产能持续扩张，HBM4研发同步推进，用价格和供货弹性换份额。这意味着HBM3E不是被替代，而是被重新定位。

资源重分配的具体形态是：先进产能（TSV、混合键合、12层以上堆叠）转向HBM4，成熟产能（8层堆叠、MR-MUF键合）继续生产HBM3E。SK海力士的M15X工厂同时生产两代产品，就是典型的资源重分配。这种模式下，HBM3E的价格体系不会因为HBM4的出现而崩盘，而是会因为产能被挤压而维持高位。

真正需要警惕的是代际切换的节奏差。如果HBM4的良率爬坡快于预期，或者客户认证进度缩短，有效供给的释放会比市场直觉更快。TrendForce预测HBM4的溢价率是30%，高于HBM3E的20%。但这个溢价是基于制造难度的定价，一旦良率突破80%门槛，成本曲线会快速下降，溢价空间也会收窄。2026年下半年到2027年，是观察这个节奏差的关键窗口。

CHAPTER 02

HBM周期是结构性错位繁荣





图3 TrendForce出货节奏

■ 国产HBM节奏存在不确定性

国内HBM的进展可以用"验证走向量产"六个字概括。长鑫存储计划2025年底前交付HBM3样品，2026年全面量产，2027年宣布HBM3E并推动量产。这个时间表比海外晚一到两个代际。SK海力士2025年已经量产HBM3E，2026年启动HBM4；长鑫2026年才量产HBM3，2027年才能触及HBM3E。

代际差距不是唯一的不确定性。长鑫的HBM3基于什么工艺节点、良率水平如何、客户认证进度怎样，公开信息极少。2024年下半年长鑫开始量产HBM2，但HBM2在当前AI算力市场几乎没有竞争力。从HBM2跳到HBM3，再到HBM3E，每一步都需要TSV工艺、堆叠良率、封装测试的同步突破。这不是有钱就能加速的，设备、材料、工艺know-how都需要时间积累。

更现实的观察是产能调配。长鑫存储已经调整产能分配原则，从LPDDR移动端转向DDR内存，实行"内需优先"策略，优先保障国内服务器、互联网大厂和智能终端厂商的需求。这意味着HBM的扩产可能进一步推迟，因为DDR是国内更急需的基础产品。TrendForce预测2025年Q3中国DRAM加NAND出货量份额超过10%，但这个份额主要集中在传统DRAM，HBM的占比微乎其微。

一旦长鑫的HBM3导入顺利，国产HBM的供给释放会比市场直觉更快。国内客户的需求是刚性的，华为自研HBM（HiBL、HiZQ）已经随昇腾950系列量产。长鑫的HBM3一旦通过验证，面对的将是一个被海外厂商高价锁定的市场，价格弹性很大。但这个"一旦"的时间点，目前看至少在2026年下半年到2027年之间。

■ 高价高预期同时松动是反转信号

HBM周期的顶部特征，不是产能过剩，而是"高价+高预期"同时松动。当前HBM市场处于量价齐升阶段：2025年市场规模约300亿美元，占DRAM市场约30%；美光预测2025到2028年HBM总潜在市场（TAM）的复合年增长率约40%，规模从350亿美元增至1000亿美元。SK海力士2026年HBM产能售罄，HBM4报价显著上浮。行业普遍预期涨价周期延续至2027年。

但这些乐观预期的支撑点，正在出现边际变化。第一个信号是扩产节奏。三星的TSV工艺（HBM）晶圆加工能力到2026年底预计与去年持平，为15万片每月；SK海力士同比增长5万片到20万片；美光同比增长4.5万片到10万片。三家合计的HBM有效产能（折算为HBM3E等效晶圆）在2026年约为40到45万片每年。这个增量是在18到24个月前决定的，现在才进入释放期。2026年底到2027年，供给曲线的斜率会变陡。

第二个信号是库存。如果HBM4的良率快速突破，旧代HBM3E的库存若未及时消化，价格体系可能先从边际产品松动。美光2026财年HBM收入预计134.4亿美元，同比增长153.5%，但2027年增速降到24.2%，2028年只有4.0%。这个增速断崖说明，即使是头部厂商，也对后年的价格持谨慎态度。收入增速从三位数降到个位数，通常对应价格而非量的变化。

第三个信号是客户行为。NVIDIA一家的需求就能消耗全球HBM产能的50%到60%，加上Google、Amazon、Meta等云厂商自研芯片的需求，供给端持续偏紧。但云厂商的资本开支不是无限增长的。如果AI训练的需求边际放缓，或者推理效率提升降低了对峰值带宽的需求，HBM的需求曲线会flatten。这不是需求下降，而是需求增速下降，对高价格体系的支撑就会减弱。

■ 真正安全边际在控制器和接口替代

HBM行业的空间扩张，不等于所有参与方都能守住利润率。周期反转时，最先受损的是纯存储晶圆制造商，因为他们的成本结构中固定成本占比高，价格下跌时利润率压缩最快。真正有安全边际的环节，是即使HBM价格回落，仍能依靠控制器、接口、模组制造、设备材料替代继续兑现份额提升的公司。

HBM的产业链可以拆解为四层。最上游是DRAM晶圆制造，由SK海力士、三星、美光垄断，技术壁垒最高，但周期波动最大。第二层是TSV、堆叠和封装，涉及先进封装设备、键合材料、测试机台。第三层是内存接口芯片和控制器，如RCD、DB、HBM控制器。第四层是模组制造和系统集成，把HBM和逻辑芯片打包成最终产品。

国产替代的机会集中在第二层到第四层。长鑫存储的HBM量产，将带动国内封装设备、测试机台、键合材料的需求。精智达等国内设备商已经在配合长鑫开发HBM用测试设备。澜起科技在DDR5内存接口芯片（RCD/DB）上已有布局，HBM生态周边是自然的延伸。先进封装环节，国内龙头封装公司正在向CoWoS-L方向拓展，与国产AI芯片供应链合作突破。

设备材料环节的替代逻辑更硬。HBM4从8层堆叠升级到12层甚至16层，需要混合键合（Hybrid Bonding）技术取代传统的微凸块互联。这意味着对键合设备、CMP材料、清洗液的需求是结构性的，不会因为HBM价格波动而消失。2026年是玻璃基板从研发转试产的拐点，2027到2030年进入量产爬坡。玻璃基板相比有机基板，在热管理、信号完整性上有优势，是HBM封装的重要升级方向。

HBM晶圆的价格会周期性波动，但HBM堆叠层数增加带来的测试工序增长（从3到4道提升到15道以上）、封装复杂度提升（从微凸块到混合键合）、基板材料升级（从有机到玻璃），这些结构性变化是不可逆的。它们对应的设备、材料、接

口芯片需求，比HBM晶圆本身的价格周期更稳定。这就是在HBM的结构性错位繁荣中，寻找安全锚点的核心逻辑。

CHAPTER 03

HBM链条各环节估值锚分属三套体系





图28.Chart.2.2.1.2



■ HBM颗粒适用PB与PE

HBM产业链从晶圆到终端，不同环节赚钱的逻辑完全不同。颗粒厂卖的是存储容量，接口厂卖的是连接能力，设备厂卖的是产线节拍。三种生意的定价权来源不同，估值体系自然分属三套。投资人如果拿同一套PE倍数去横向比较HBM颗粒、接口芯片和测试设备，会犯方向性错误。

HBM颗粒厂的财务报表更像一家大宗商品企业。收入等于出货量乘以单位价格，成本等于晶圆折旧加上产能利用率分摊。毛利率直接由DRAM现货价与晶圆成本之间的剪刀差决定。韩国原厂给出2026年DRAM均价上涨62%、NAND均价上涨75%的预测，这个假设一旦成立，2026年和2027年EPS分别被上调56%和63%。HBM颗粒的估值弹性最大，但弹性完全锚定在一个价格假设上。颗粒厂的PB倍数反映的是资产重置价值，PE倍数反映的是价格周期中的盈利波动。如果价格周期拐头，PB会先于PE收缩，因为市场会重新评估晶圆厂资产的变现价值。

■ 接口芯片适用PE辅以PS校验

澜起科技的互连类芯片毛利率71.5%，收入占比94.18%。这不是卖存储容量，而是卖数据通路。接口芯片的定价逻辑与比特价格脱钩，取决于通道速率、延迟和

功耗指标。客户愿意为更高带宽付费，但付费方式不是按GB计价，而是按芯片颗数计价。这种模式下，PE是核心估值锚，PS作为成长校验。只要服务器出货量持续增长，接口芯片的营收增长就具备可见性。估值受存储价格波动的影响显著小于颗粒厂。但PS校验有一个前提：收入增速必须持续高于行业平均。如果增速掉队，PS收缩会先于PE反映。

■ 测试设备适用PE与EV/EBITDA

测试设备2025年销售额112亿美元，同比增长48.1%。设备厂的收入来自客户资本开支，不是来自存储产品本身。客户买测试机是为了验证HBM堆叠良率，买探针台是为了筛选KGD。设备厂的定价权来自技术领先度和产线不可替代性。PE和EV/EBITDA同时适用，因为设备厂有显著的运营杠杆，产能利用率一旦越过盈亏平衡点，利润增速会大幅高于收入增速。但底层驱动是客户CAPEX周期，不是存储价格周期。一台高端测试机的价格可能等于一整条模组产线的投资，但客户不得不买，因为良率损失的成本更高。这种不可替代性给了设备厂估值溢价，但溢价的前提是客户还在扩产。

CHAPTER 04

价格下行期估值韧性接口优先





图30.Chart.2.2.2.2



■ 价格传导链条长短决定韧性

存储行业周期性强。当价格从高位回落，不同环节受伤的程度不是均等的。核心变量只有一条：价格传导链条的长短。链条越长，库存价值重估和毛利压缩的空间越大。链条越短，定价越脱离存储现货，估值韧性越强。接口芯片和测试设备的定价与存储bit价格基本无关，它们按功能和性能收费。HBM颗粒有长协保护，但模组制造直接面对现货市场和渠道库存。这决定了价格下行期的估值韧性排序：接口和控制器最硬，测试设备次之，HBM颗粒再次，模组制造最脆弱。

价格传导链条是理解存储产业链估值韧性的核心工具。链条长短不是物理距离，而是价格信号从现货市场传导到企业利润表所需的环节数。HBM颗粒原厂签订3到5年长协，价格信号被合同锁定。模组制造企业与下游客户签订的是季度或半年订单，价格信号几乎实时传导。接口芯片和测试设备根本不按存储容量定价，价格信号传导链条接近于零。链条越长，缓冲垫越厚，但市场预期会提前打折扣。链条越短，利润表波动越直接，但市场预期也会提前price in。估值韧性的排序不是简单的利润稳定性排序，而是利润表波动与市场预期前置的博弈结果。

■ 颗粒长协缓冲模组直接承压

HBM颗粒原厂与客户签订3到5年长协，价格锁定机制让短期DRAM现货下跌不会立刻反映在利润表上。长协的存在让颗粒厂在价格下行期有6到12个月的盈利缓冲期。但模组制造企业的采购周期和销售节奏更短。原厂还在按长协价格出货时，模组厂已经需要面对渠道价格下滑和库存价值重估。市场往往提前三到六个月用"未来毛利回落"给模组板块定价。这种预期前置让模组制造在价格下行期的估值收缩早于颗粒原厂。投资人看颗粒厂还能看到长协支撑的实际利润，看模组厂只能看到库存减值和毛利率下滑的确定性。预期差决定了估值差的顺序。

■ 接口设备按功能收费抗波动

接口芯片和测试设备的收入不按存储容量计价。一颗HBM接口芯片的价格取决于它能支持多少GB/s的带宽，一台测试机的价格取决于它每小时能处理多少颗芯片。存储价格下跌时，客户对高带宽的需求不会消失，对良率测试的需求也不会消失。接口和设备厂商受伤的方式不是ASP塌缩，而是客户资本开支决策延后。客户不会因为DRAM跌了20%就少买接口芯片，只会因为服务器出货量下调而减少采购。只要客户的产线还在运转，接口和设备就有基本盘。这种定价模式的抗周期能力，本质上来自收入与存储价格的脱钩程度。

CHAPTER 05

份额提升不是安全垫毛利率稳定才是





图32.Chart.2.2.3.2



■ 澜起份额扩张毛利率攀升

投资人喜欢"份额提升"叙事。一家公司的产品在客户供应链中的占比从10%提升到30%，听起来是确定性的成长故事。但份额扩张本身不能自动转化为安全边际。关键变量是份额提升的同时，毛利率是否稳定，客户结构是否升级。如果份额提升是靠降价换来的，那增长只是规模放大，没有质量改善。如果客户结构没有升级，那份额提升只是同一批客户多买了一些，没有打开新的定价空间。

澜起科技是正面样本。毛利率从2023年58.91%升至2025年62.23%，2026年一季度进一步达到69.79%。份额扩张没有以牺牲价格为代价。产品结构从DDR4向DDR5切换，从标准品向高附加值品类延伸。DDR5接口芯片的复杂度高于DDR4，定价权更强。客户结构也在升级，从国内服务器厂商向国际头部客户渗透。国际客户对性能和稳定性要求更高，愿意支付溢价。份额和利润率同步上行，这才是可持续的增长。澜起的案例说明，份额提升叙事的安全边际，来自产品升级和客户升级的双重验证。单一维度的份额增长不能提供同样的保护。

■ 江波龙份额增长利润波动大

江波龙企业级业务同比增长93.3%，增速亮眼。但年报中同时提示了毛利率波动风险、晶圆价格波动风险、存货备货策略调整风险。份额在涨，但利润率没有同步企稳。企业级存储的竞争逻辑是规模优先，为了进入客户供应链，前期往往接受较低毛利。客户认证周期长，一旦进入供应商名单，后续订单有粘性，但前期投入大、回报慢。这种增长模式在价格上行期放大盈利，在价格下行期放大亏损。江波龙的案例说明，份额提升叙事如果没有毛利率稳定作为支撑，本质上是一个周期杠杆故事，不是成长故事。

■ 国产模组存货放大利润波动

国产模组厂的存货和DOI（库存天数）在涨价周期中已经成为利润波动的关键放大器。涨价时囤货带来账面浮盈，跌价时库存减值直接冲击利润。模组厂的商业模式天然带有存货杠杆。上游从原厂采购晶圆，需要提前备货；下游卖给客户，账期和价格谈判空间受限。两头挤压下，存货是利润波动的放大器。份额提升只是增加了存货的绝对规模，没有改变存货对价格的敏感性。DOI每增加10天，价格下跌周期中的减值损失就会按存货规模同比放大。投资人看模组厂的份额增长，必须同时看DOI和存货结构。如果DOI在扩张，份额增长反而增加了风险敞口。

■ 设备企业客户集中度双刃剑

长川科技前五大客户贡献销售额30.51亿元，占比57.66%。业绩弹性来自核心客户CAPEX扩张，但这也意味着一旦大客户扩产放缓或切换供应商，订单波动会很大。设备厂商的份额提升往往绑定在特定客户的新产线导入上。客户验证周期长，一旦通过验证，供应商粘性高，但份额不具备广泛的客户基础分散。集中度是双刃剑。繁荣期，大客户的扩产计划集中释放，设备厂订单爆发性强。退潮期，大客户的资本开支收缩会集中反映在设备厂的订单簿上。投资人看设备厂的份额提升，必须区分份额是分散在多个客户还是集中在少数客户。分散的份额是安全垫，集中的份额是杠杆。

CHAPTER 06

国产HBM2/3的窗口由供给缺口定义

图45.Chart.2.3.1.1





图46.Chart.2.3.1.2



■ 代际差不是窗口的决定因素

国产HBM2/3的替代窗口，表面看像是技术代际差开的口子，实则由海外对华供给的受限程度决定。HBM3E和HBM4已经量产，但国内客户能拿到多少，取决于出口管制清单的松紧。SK海力士、三星、美光三家合计占全球HBM供给95%以上，若管制持续收紧，国内系统厂能进口的有效颗粒就减少。HBM2/3虽在技术上落后两代，但昇腾910B等国产训练芯片的设计规格就是围绕HBM2/3带宽匹配的。芯片设计是冻结的，带宽接口定了，系统厂不会因为海外有了HBM4就重新流片。代际差存在，但系统厂的采购决策并不跟着代际差走，而是跟着“能买到什么”走。

这个逻辑就像你买了一辆只加92号汽油的车，炼油厂出了98号油，你理论上加不了，但对你来说真正的问题是附近加油站还有没有92号。国产HBM2/3的替代窗口，就是“92号加油站正在关店”的时间窗口。

海外三巨头的产能分配逻辑是优先服务最高价值客户。HBM3E和HBM4的单价更高、毛利更厚，良率爬坡阶段产能本就稀缺。如果管制限制对华出口高代际产品，新增产能会优先流向非中国客户。国内系统厂获得高代际HBM的渠道收窄，但存量需求还在，这就给国产HBM2/3留出了替代空间。代际差不是替代窗口的充分

条件，"有效供给受限"才是。

■ 库存缓冲期是验证时间的购买能力

系统厂对HBM的库存管理，不是简单的仓库盘点。HBM2/3的交付周期通常12-16周，加上封装测试和运输，系统厂从下单到装机可能要3-4个月。这个周期决定了安全库存至少要覆盖一个季度以上的出货需求。目前系统厂的库存策略通常按6-9个月的出货量设定。如果新增进口受限，这个库存能撑多久，取决于三个因素：现有仓库库存、渠道在途库存、安全库存的释放节奏。

缓冲期的核心意义不是数字本身，而是它为国产厂商争取了验证时间。HBM的验证不是简单的跑分测试，而是要在实际训练场景下跑满数千小时，确认良率、散热、信号完整性。这个验证周期通常6-12个月。库存能撑住，系统厂就有从容验证的空间；库存撑不住，系统厂只能跳过部分验证环节，直接上国产方案。国产厂商的介入窗口，在库存从"充裕"滑向"紧平衡"的区间。这个区间不是静态的，而是动态演化的。随着每一次出口管制更新，缓冲期都会重新计算。系统厂会同时调整库存策略和验证节奏，国产厂商的窗口也会相应移动。

■ 最佳介入时点是三者重叠的区间

国产HBM的最佳介入时点，不是单一事件，而是三个条件同时满足的区间：海外有效供给向非中国客户倾斜、国内库存滑向紧平衡、国产方案完成关键客户验证。这三个条件独立出现时是信号，同时出现时是交易窗口。

海外有效供给向非中国客户倾斜，表现为国内采购渠道出现交付延期、配额缩减或报价跳涨。国内库存滑向紧平衡，表现为系统厂开始调整安全库存策略，从"维持正常周转"转向"保核心产线不间断"。国产方案完成关键客户验证，表现为头部系统厂（如华为、寒武纪等）开始在非核心产线或新项目中小批量导入国产HBM。三个条件同时出现时，市场通常还在用"主题叙事"定价，而不是用"订单兑现"定价。这个定价错配创造了最佳风险收益比。一旦订单兑现数据出来，估值会迅速修复，窗口也会收窄。替代窗口的本质，是一个由供给受限、库存消耗和验证进度共同定义的时序区间，而不是一个静态的技术代际差。

CHAPTER 07

HBM3E向HBM4/5切换会压缩窗口





图48.Chart.2.3.2.2



■ 资源倾斜导致旧代际供给收缩

HBM3E向HBM4/5切换，不是平滑过渡，而是资源重新分配。SK海力士的HBM3E已经量产，HBM4的样品正在送测。三星的HBM3E也在爬坡，HBM4的路线图已经明确。美光虽然进度稍慢，但同样在向高代际集中。三家厂商的资本开支、封装产能、工程验证团队和头部客户资源，都会向HBM4/5倾斜。

这个倾斜对旧代际的供给不是线性的减少，而是结构性的挤出。HBM2/3的生产线不会立刻关闭，但新增产能不会再投向旧代际。旧代际的供给增长完全依赖现有产线的折旧摊薄和效率提升，增长速度会明显放缓。更关键的是，头部客户的采购订单也会向高代际转移。如果出口管制限制对华出口高代际，国内系统厂就会面临一个尴尬局面：想买HBM4买不到，想买HBM3E配额也在收缩。旧代际的存量供给，因为不再有新增产能支撑，会变得越来越不稳定。就像一个餐厅把厨师都调去做新菜，老菜单虽然还在，但上菜速度和质量都会下降。

旧代际供给的结构性收缩，不会立刻表现为价格暴涨，而是表现为交货周期拉长、最小起订量提高、长期协议难以续签。国产HBM2/3的窗口，就在这个"旧代际供给不稳定"的区间里被打开。但窗口不会无限持续，因为海外厂商的产能切换是持续进行的，旧代际的供给收缩也是持续的。一旦旧代际的供给缺口被国内系统

厂完全接受，并且系统厂完成了对国产方案的验证，窗口就会从"打开"转向"兑现"。这个兑现的速度，取决于国产厂商的量产能力和海外旧代际供给收缩的速度。

■ 双重挤压形成集中交易区间

HBM3E向HBM4/5切换的过程中，国内市场会面临一个双重挤压：先进产品买不到，成熟一代也未必稳定供给。这个双重挤压不是短期现象，而是会持续到HBM4/5的产能充分释放或者管制条件出现实质性变化。在这个双重挤压的区间内，国产HBM2/3的替代窗口会被压缩成一个更集中的交易区间。

集中交易区间的含义是：替代窗口不会均匀地分布在很长时间里，而是集中在某个较短的时间段内，在这个时间段内系统厂必须做出采购决策。如果系统厂错过了这个区间，后续可能面临两个结果：要么海外旧代际供给意外恢复，国产方案失去验证后的导入窗口；要么国产方案验证完成但系统厂已经通过其他渠道（如库存调配、第三方采购）解决了短期需求，国产方案的导入优先级被降低。集中交易区间的形成，本质上是因为HBM的供应链高度集中，且代际切换的节奏是行业性的。不是某一家厂商在切，而是三家头部厂商同时向高代际集中。这种行业性的资源倾斜，对旧代际的供给收缩是同步的，而不是错开的。国内系统厂没有"这家切了我还可以找那家"的缓冲空间，只能在有限的时间内做出选择。

■ 最佳介入时点落在过渡区间

替代窗口的时间可以拆分为四个阶段：海外供给缺口显性化、国产验证加速、量产爬坡、份额替代。最佳介入时点通常不是落在第四阶段，而是在第一阶段向第二阶段过渡，或者第二阶段向第三阶段过渡的区间。原因很简单：第四阶段的信息已经充分反映在市场定价中，估值修复基本完成。

第一阶段向第二阶段过渡的区间，是海外供给缺口刚刚被产业链确认，但国产验证还没有大规模展开。这时候市场还在争论"到底缺不缺"，而不是争论"国产能不能替代"。第二阶段向第三阶段过渡的区间，是国产验证已经出现可观测的进展，但量产爬坡还没有开始。这时候市场开始接受"替代是可能的"，但还没有看到"替代已经开始"。这两个过渡区间的共同点，是信息不对称最严重。产业链内部知道供给缺口和验证进展，但外部投资者还没有完全形成一致预期。这种信息不对称创造了定价错配，也创造了最佳的风险收益比。一旦进入第三阶段，国产厂商的量产爬坡数据会定期释放，市场会快速修正预期。一旦进入第四阶段，份额替代的数据会直接反映在财务报表上，估值弹性会明显收窄。替代窗口的交易属性，不是"长期持有等待替代完成"，而是"在信息差最大的区间内完成布局"。

CHAPTER 08

风险收益比是双向赛跑的赌注





图50.Chart.2.3.3.2



■ 替代是国产爬坡与海外松动的赛跑

国产HBM替代的本质，不是一场单向的技术追赶，而是两场赛跑的叠加：长鑫存储等本土厂商的量产与验证进度，对阵海外三巨头的HBM4/5良率提升、产能扩张，以及外部限制政策的边际松动。只要本土爬坡的速度快于海外松动的速度，替代窗口就被打开并延长。反之，如果海外高代际快速放量且对华供给边际改善，窗口就会明显收窄。

这个双向赛跑模型的关键变量，不是单一维度的“谁更先进”，而是“谁更快”。海外三巨头的HBM4/5良率爬坡，每提升一个百分点，有效供给就会增加。新增产能的开出，每增加一条产线，供给曲线就会右移。如果出口管制出现边际松动，哪怕是高代际产品的豁免范围扩大，都会直接影响国内系统厂的采购选择。国产厂商的爬坡，涉及DRAM制程的良率提升、TSV通孔工艺的稳定性、凸块焊接的可靠性，以及最终封装测试的良率。每一个环节都是工程问题，不是理论问题，都需要时间。

赛跑的结果不是“替代会不会发生”，而是“替代会在什么窗口内发生”。如果国产厂商在18个月内完成从验证到量产的闭环，而海外在这18个月内对华供给持续受限，替代窗口就是打开的。如果国产厂商需要36个月，而海外在第24个月就开始对

华恢复高代际供给，窗口就会在第24个月左右关闭。这个赛跑的时间差，就是风险收益比的核心来源。投资者不是在赌替代能否实现，而是在赌时间差能否创造足够的商业价值。

■ 价格回落的冲击看成本赛跑

HBM价格回落对国产盈利能力的冲击，不是简单的“价格跌了利润就少了”，而是要看价格回落的速度是否快于良率提升和固定成本摊薄的速度。如果价格回落是缓慢的、渐进的，国产厂商可以通过良率提升和产能扩张来对冲。如果价格回落是突然的、剧烈的，国产厂商还没完成良率爬坡，就会面临严重的盈利压力。

这个逻辑可以类比智能手机面板。国产OLED面板在2018-2020年大规模量产时，价格正处于下行周期。但京东方、维信诺等厂商通过良率提升，把成本降得比价格降得更快，最终实现了盈利。HBM的国产替代，面临同样的考验。HBM2/3的定价基准是海外三巨头的报价。如果海外因为旧代际供给收缩而维持价格，国产厂商就有相对宽松的盈利空间。如果海外因为需求疲软或新代际放量而大幅降价，国产厂商的盈利窗口就会收窄。关键变量是良率。HBM的良率比标准DRAM低得多，因为TSV工艺和堆叠工艺的复杂度远高于平面DRAM。良率每提升一个百分点，单位成本就会下降几个百分点。国产厂商的盈利模型，不是“价格-成本”的简单差值，而是“良率-成本-价格”的动态赛跑。

■ 最佳与最差介入时点

最佳介入时点，是验证已接近完成但市场仍按纯主题定价的阶段。这时候，产业链内部已经知道国产方案通过了关键验证，但外部投资者还没有看到订单数据，市场定价还停留在“主题投资”的逻辑。估值没有包含“订单兑现”的预期，一旦订单兑现，估值修复的空间很大。

最差介入时点，是价格已开始下行、海外供给改善而国产方案仍停留在样品和小批阶段。这时候，国产厂商面临双重压力：外部价格下行压缩了未来的盈利空间，海外供给改善降低了系统厂导入国产方案的紧迫性。国产厂商的谈判地位被削弱，验证周期可能被拉长，量产时间表也可能被推迟。最差时点的风险，不是“替代失败”，而是“替代延迟”。延迟意味着资本投入的时间价值损失，也意味着技术迭代窗口的错过。如果国产厂商在最差时点进入，可能会面临一个尴尬局面：好不容易验证完成了，但市场需求已经转向更高代际，或者海外供给已经恢复，国产方案只能以更低的价格和更小的份额进入市场。这个风险，比单纯的“技术失败”更隐蔽，也更难对冲。

CHAPTER 09

窗口取决于时间差而非代际高低





图64.Chart.2.4.1.2



■ 代际升级不等于国内可得性宽松

海外代际升级越快，国内可得性未必越宽松。HBM4/5的量产代表技术前沿前移，但不代表国内客户同步获得同等供给。头部厂商的新增资源会优先服务更高价值客户，旧代际产品可能因为资源重新分配而结构性收缩。国产HBM2/3的替代窗口，是“进口高端供给无法稳定覆盖本土需求”时形成的替代区间，而不是“海外技术落后”时形成的替代区间。

这个逻辑的核心在于，HBM的供给不是自由市场，而是被高度管制的寡头市场。SK海力士、三星、美光三家不仅决定了产能分配，还决定了客户的优先级。如果HBM4/5的产能紧张，头部厂商会优先满足英伟达、AMD、谷歌、亚马逊等全球顶级客户的订单。这些客户不仅订单量大，而且技术协同能力强，能配合厂商进行联合优化。国内系统厂虽然也是大客户，但在地缘政治风险下，优先级会被重新评估。即使国内系统厂愿意支付溢价，厂商也会考虑合规风险。代际升级带来的不是供给的普遍充裕，而是供给的结构性重新分配。旧代际的供给，因为不再新增产能投入，会变得越来越不稳定。国内系统厂要么接受旧代际供给的不稳定，要么转向国产替代。这个选择不是技术问题，而是供应链安全问题。

■ 库存是验证时间的购买能力

库存缓冲期的本质，不是仓库里有多少颗芯片，而是这些芯片能换取多长的验证时间。系统厂的安全库存策略，通常是按最坏情景设定的：如果新增进口完全中断，现有库存能支撑多久。这个“多久”决定了国产厂商是以“从容验证”进入市场，还是以“缺货倒逼”进入市场。

从容验证的优势是，系统厂可以完整跑完验证流程，确保国产方案在实际场景下的可靠性。缺货倒逼的劣势是，系统厂可能被迫跳过部分验证环节，或者在验证不充分的情况下就开始小批量导入，这会增加后续的技术风险。国产厂商当然希望系统厂能从容验证，因为验证越充分，导入后的客户粘性越强。但系统厂的库存策略不是由国产厂商决定的，而是由海外供给的稳定性决定的。如果海外供给持续受限，系统厂会主动延长验证周期，同时增加国产方案的验证投入。如果海外供给突然恢复，系统厂会重新评估验证节奏，甚至可能暂停国产验证，优先恢复海外采购。库存消耗速度、国产验证进度与海外供给恢复速度三者的交叉，决定了替代窗口的时序。这个时序不是固定的，而是随着每一个外部事件动态调整的。

■ 三者交叉决定窗口时序


库存消耗速度、国产验证进度、海外供给恢复速度，这三个变量不是独立运行的，而是相互影响、相互制约的。库存消耗快，会倒逼验证加速，但如果海外供给同时恢复，系统厂可能会选择跳过国产验证。国产验证进度快，会增加系统厂的导入信心，但如果库存充裕，系统厂没有导入的紧迫性，验证成果可能暂时搁置。海外供给恢复，会削弱国产替代的紧迫性，但如果库存已经消耗到临界点，系统厂可能会选择“双线并行”——一边恢复海外采购，一边继续国产验证。


三者交叉的时序，决定了替代窗口的开启、持续和关闭。最佳情景是：库存消耗到紧平衡、国产验证刚好完成、海外供给仍然受限。最差情景是：库存充裕、国产验证滞后、海外供给突然恢复。现实情景通常介于两者之间，且动态变化。投资者的任务，不是预测某一个具体时点，而是跟踪三个变量的相对变化，判断窗口的位置和方向。跟踪的指标可以包括：国内系统厂的库存周转天数变化、国产厂商的验证里程碑公告、海外三巨头对华出货的月度数据、出口管制清单的更新频率。这些指标的组合，会比单一指标更准确地反映窗口的时序。

CHAPTER 10

窗口长度可被测算因为缺口可传导

图65.Chart.2.4.2.1





■ 代际升级放大旧代际替代空间

HBM3E向HBM4/5切换，会放大而非立即消除HBM2/3的替代空间。代际升级带来结构性挤出，头部资源向新代际集中，旧代际若仍有存量需求，会出现供给斜率下降快于需求斜率下降的阶段。这个阶段为国产HBM2/3创造了"中间代际供给真空"。

供给斜率下降快于需求斜率下降，是一个关键判断。HBM2/3的需求不是突然消失的，而是随着系统厂的新产品设计而逐步转移的。昇腾910B等现有产品仍在出货，对HBM2/3的需求是持续的。但海外厂商的供给斜率，因为资源向新代际倾斜，会快速下降。当供给斜率下降的速度超过需求斜率下降的速度，就会出现供给缺口。这个缺口的持续时间，取决于新代际产能释放的速度和旧代际需求的衰减速度。如果新代际产能释放慢，旧代际需求衰减也慢，缺口会持续较长时间。如果新代际产能释放快，旧代际需求衰减也快，缺口会很快被弥合。国产HBM2/3的替代窗口，就在这个缺口的持续期内。

■ 有效供给是多重约束的乘积

有效供给的增长斜率，不是名义产能的简单线性函数，而是多重约束的乘积：名义产能×良率×可交付优先级×对华可售比例。只要其中任一项受约束，名义供给就无法转化为国内客户可用的有效供给。

名义产能是厂商规划的最大产出能力，但实际产出受良率限制。HBM的良率通常在60%-80%之间，低于标准DRAM的90%以上。良率每下降一个百分点，有效供给就会减少一个百分点。可交付优先级决定了产能分配给哪些客户。如果头部客户优先获得产能，国内客户的可交付量就会减少。对华可售比例是出口管制下的直接约束，如果高代际产品被限制，国内客户只能采购低代际产品，但低代际产品的优先级通常更低。这四个因素的乘积关系，意味着有效供给的弹性远低于名义产能。即使名义产能扩张了50%，如果良率下降、优先级调整、对华可售比例收缩，有效供给可能只增长10%甚至下降。这个乘积效应，是测算替代窗口长度时必须考虑的核心变量。

■ 名义产能不等于有效供给

HBM的良率爬坡和先进封装协同，决定了供给兑现速度。HBM的制造不是单一工艺，而是DRAM晶圆制造、TSV通孔刻蚀、晶圆减薄、凸块焊接、多层堆叠封装、最终测试的协同。每一个环节都有独立的良率，最终良率是各环节良率的乘积。如果DRAM晶圆良率90%，TSV良率95%，减薄良率98%，凸块良率95%，堆叠良率90%，测试良率98%，最终良率就是 $90\% \times 95\% \times 98\% \times 95\% \times 90\% \times 98\% \approx 70\%$ 。这个70%不是固定值，而是会随着工艺优化逐步提升。但提升的速度是渐进的，不是跳跃的。

先进封装的协同，也是供给兑现的关键。HBM需要和逻辑芯片（如GPU）通过2.5D/3D封装集成，封装厂的产能和工艺能力决定了HBM最终能形成多少有效系统。如果封装厂产能紧张，即使HBM颗粒本身供给充足，也无法转化为可用的系统。这个封装瓶颈在2023-2024年HBM短缺期间已经充分体现。台积电的CoWoS产能不足，导致HBM颗粒虽有库存但无法出货。国产HBM的替代窗口，不仅要考虑颗粒层面的供给，还要考虑封装层面的协同。如果国产HBM在颗粒层面验证完成，但封装协同能力不足，替代窗口也会被拉长。这个多环节协同的复杂性，决定了名义产能到有效供给的传导不是即时的，而是有显著时滞的。

CHAPTER 11

风险收益比的核心是测窗口关闭速度

图67.Chart.2.4.3.1





图68.Chart.2.4.3.2



■ 窗口关闭源于供给修复快过验证

窗口提前关闭，往往不是因为需求消失，而是因为供给修复的速度快过验证完成的速度。海外HBM4/5良率快速爬升、旧代际供给重新释放、或者限制条件边际放松，都会使客户重新把性能、稳定性和生态兼容性放在优先位置。国产方案会从"主供候选"退回"备份方案"。

退回备份方案的含义是，系统厂不再把国产方案作为核心采购对象，而是作为应急储备。这种心理转变是致命的。一旦系统厂把国产方案定位为"备份"，导入节奏就会放缓，验证投入就会减少，量产订单就会缩水。国产厂商的产能扩张计划也会受到影响，因为客户意向的不确定性增加了。这个退回过程通常不是突然发生的，而是渐进式的。先是系统厂在内部评估中重新排序，然后是在采购决策中降低国产方案的优先级，最后是在供应商名录中把国产方案从"主供"调整为"备选"。每一步都是不可逆的，因为一旦系统厂重新依赖海外供给，再想切换回来就需要重新验证，成本更高。

■ 价格回落先穿透毛利再穿透信心

HBM高景气阶段给予国产替代较宽容的试错空间。系统厂愿意给国产方案更多验证机会，因为海外价格高企，国产方案即使性能略逊，价格优势也很明显。一旦价格回落，国产方案的盈利模型会面临两层挤压：单位毛利收缩，客户对性能折价的容忍度下降。

单位毛利收缩是直接的财务冲击。HBM2/3的定价基准是海外报价，如果海外降价，国产厂商要么跟着降价，要么失去订单。跟着降价意味着毛利率下降，如果良率还没有提升到足够水平，降价可能直接穿透盈亏平衡点。客户对性能折价的容忍度下降，是更隐蔽的心理冲击。价格高的时候，客户会说服自己"性能差一点但便宜很多，可以接受"。价格低的时候，客户的评估标准会回归到"同等价格下性能最好"。国产方案如果不能在性能上追平海外，即使价格有优势，客户也会犹豫。这个心理变化不是理性的成本计算，而是采购行为的本能反应。国产厂商在高景气阶段积累的订单意向，在价格回落时可能大面积流失。

■ 从主供候选退回备份方案

国产HBM替代的最大风险，不是技术失败，而是时间错配。窗口的开启和关闭，取决于外部变量的相对速度，而不是单一维度的技术进度。如果国产厂商在窗口开启时已经完成验证，替代可以顺利推进。如果国产厂商在窗口关闭时还在验证，就会陷入"验证完成但市场已变"的困境。

这个困境的本质是，HBM的替代窗口不是由国产厂商自己控制的，而是由海外供给、出口管制、客户库存策略等外部变量共同决定的。国产厂商能做的，是尽可能加快验证和量产进度，缩短自己的响应时间。但即使做到了最快，如果外部变量突变，窗口仍然可能提前关闭。所以风险收益比的核心，不是判断替代会不会发生，而是测算窗口关闭的速度。如果窗口关闭的速度慢，国产厂商有充足的时间完成替代，风险收益比就好。如果窗口关闭的速度快，国产厂商可能在替代完成前就被挤出市场，风险收益比就差。这个测算不是精确的科学，但可以通过跟踪关键变量来动态评估。关键变量包括：海外良率爬坡的月度数据、出口管制清单的更新频率、国内系统厂的库存周转天数、国产厂商的验证里程碑。这些变量的组合变化，会比单一变量更准确地反映窗口的关闭速度。

投资者需要建立的思维模型，不是"替代=必然盈利"，而是"替代在特定窗口内发生才能盈利"。这个窗口的长度、位置和可预见性，决定了投资的风险收益比。如果窗口可预见且足够长，即使替代的技术难度大，投资也值得一试。如果窗口不可预见且可能随时关闭，即使替代的技术前景好，投资也面临巨大的不确定性。这个不确定性，就是国产HBM替代投资的最大风险来源。

CHAPTER 12

图表附录





图.7-Chart.2.1.1.1


图8. HBM Supply-Demand Balance & Pricing Framework



Source: TrendForce / Broker Models

图8-Chart.2.1.1.2


图9. HBM Generational Transition: Structure vs Volume



Source: TrendForce / Broker Research

图.9-Chart.2.1.2.1

图10. Ascend Single-Chip HBM Capacity & Bandwidth Leap



Source: Huawei Press / Broker Research

图.10-Chart.2.1.2.2




图.11-Chart.2.1.3.1




图.12-Chart.2.1.3.2




图.27-Chart.2.2.1.1




图.28-Chart.2.2.1.2




图.29-Chart.2.2.2.1




图.30-Chart.2.2.2.2




图.31-Chart.2.2.3.1




图.32-Chart.2.2.3.2




图.45-Chart.2.3.1.1




图.46-Chart.2.3.1.2




图.47-Chart.2.3.2.1




图.48-Chart.2.3.2.2




图.49-Chart.2.3.3.1




图.50-Chart.2.3.3.2




图.63-Chart.2.4.1.1




图.64-Chart.2.4.1.2




图.65-Chart.2.4.2.1




图.66-Chart.2.4.2.2




图.67-Chart.2.4.3.1




图.68-Chart.2.4.3.2
