
算力链定价逻辑系列研究

留存质量先于利用率决定拐点

狗不扯蛋·AI研究所

2026-07-08

摘要


监管压制训练侧后，算力需求没有消失，只是换了一条路走。但推理侧要形成真实闭环，需要单位Token经济成立、并发时延体验可控、利用率持续改善三者同时成立。推理商业化核心时滞不在需求出现，而在收入质量与成本结构同步成熟。利润表拐点不是看调用量涨了多少，而是先看客户留存质量，再看计费稳定性，最后才是利用率。头部玩家通过产品标准化、计费规则设定和客户结构筛选，把离散波动需求转化为稳定现金流，分走的是高质量收入。标准化通用市场趋于集中，但定制化、垂直化需求给中小服务商留下缝隙。历史参照云计算从IaaS到SaaS的价值迁移，推理市场正在重演从资源拥有者向资源组织者的利润转移。

1.推理侧需求闭环需三者同时成立

CHAPTER 01

1 监管后训练需求向推理迁移

1. 全球AI Token消耗量趋势



2025年1月，美国商务部发布新一轮人工智能出口管制新规，进入为期120天的征求意见期。这不是第一次。自2022年10月BIS首次对高端GPU实施出口限制以来，英伟达A100、H100以及后来的H20，相继被纳入管制清单。中国企业想要买到最先进的训练芯片，门槛越来越高，渠道越来越窄。

限制的效果立竿见影。2024年，中国移动智算中心（呼和浩特）的AI芯片国产化率已经超过85%。这不是一个企业的选择，而是整个供应链的被迫转身。训练侧的故事——万卡集群、千亿参数、Scaling Law——正在从“谁卡多谁赢”变成“谁还能拿到卡”。

但需求没有消失。它只是换了一条路走。

2025年春节前后，DeepSeek-R1发布。这个模型在推理能力上的惊艳表现，让市场突然意识到一件事：训练出一个好模型很重要，但让这个模型被高频调用、持续产生收入，可能是更迫切的命题。国内主流大模型的日均Token调用量已经达到数万亿级别。豆包大模型2024年的月度收入平均值约为500万元，2025年跃升至约7000万元。付费转化率从5%提升到10%。这些数字不大，但方向很明确：钱开始从用户口袋里流向推理端。


监管压制训练侧，不等于杀死算力需求。它更像是把需求从"修高速公路"推向了"高速公路上的车流量"。问题是，车流量能不能大到让收费站盈利。

<!-- 大图占位：图.2-Chart.2.0.0.1.png (1.5亿像素，PDF渲染OOM) -->

CHAPTER 02

2 推理侧是经营叙事而非总量叙事

图3.不同推理场景（搜索/聊天/代码）的并发-时延-成本三角关系



数据来源：行业测试、公司公告、公司财报 | 2025-2026

训练侧的逻辑是总量叙事。谁的参数多，谁的集群大，谁的算力储备吓人，谁就是王者。这个逻辑在2023年和2024年上半年统治了市场。资本愿意为一个"可能训练出下一代GPT"的故事支付百倍估值，因为一旦成功，回报是指数级的。

推理侧不一样。推理侧讲的是经营叙事。它的核心问题不是"你能做到多大"，而是"每调用一次，你赚多少钱，花多少钱，用户会不会再来"。

豆包大模型的定价变化很能说明问题。1.0版本的输入价格是0.3到0.6元每百万Token，输出价格更高一些。到了1.6版本，最低端版本的输入价格提升到0.8元，输出价格提升到2元。如果启用深度思考功能，输出价格可以达到24元每百万Token。这不是简单的涨价。它是在尝试证明：更好的推理质量，用户愿意付更多钱。


但经营叙事的关键指标不是价格本身，而是调用频次、并发水平、平均时延、客户留存和利用率。这些指标共同回答一个问题：用户是不是真的在用，用得够不够多，用的时候体验够不够好，用完之后会不会走。

2024年，大部分大模型API的调用场景还停留在尝鲜阶段。个人用户随便问几个问题，企业用户接个客服机器人试试水。调用量有，但粘性没有。到了2025年，情况开始变化。微信接入DeepSeek、AI手机预装大模型、AIPC本地化推理，这些场景的共同点是：调用不再是"试一试"，而是"每天用"。从尝鲜到日常，这是推理叙事从总量转向经营的关键一跃。

CHAPTER 03

3 三条件同时成立才形成真实闭环

图4.推理市场CR3/CR5集中度与头部企业利用率差异



推理需求要成为真实闭环，需要三个条件同时成立：单位Token经济成立、并发时延体验可控、利用率持续改善。

三个条件缺一不可。单位Token经济成立，意味着每次调用的收入覆盖每次调用的成本。如果覆盖不了，调用量越大，亏得越多。这听起来像是废话，但2024年很多大模型厂商就是在做这门“越大越亏”的生意。豆包2025年的提价策略，本质上是在测试用户的价格敏感度，试图找到那个“用户愿意付、厂商不亏本”的甜蜜点。

并发时延体验可控，是第二个条件。用户不会等。一个聊天机器人如果每次回复要思考十秒，用户用两次就走了。搜索引擎如果结果页加载超过两秒，跳出率就会飙升。推理不是离线批处理，它是在线服务。时延的伤害是直接的、即时的、不可逆的。DeepSeek-R1的深度思考功能很强，但思考时间越长，对并发基础设施的压力越大。这是一个需要在“能力”和“体验”之间反复权衡的跷跷板。

利用率持续改善，是第三个条件。GPU很贵。一张H100的价格超过两万美元。如果利用率只有30%，相当于这张卡大部分时间都在闲置折旧。东北证券的调研显

示，部分第三方智算中心的推理业务占比从30%跃升至65%之后，闲置GPU资源的利用率提升了200%。这是一个从“有卡没调用”到“有卡忙不过来”的转变。利用率每提升一个百分点，单位成本就下降一截。

只有当这三个条件同时成立，推理需求才会从概念替代变成真实闭环。任何一个条件掉链子，整个故事都会垮掉。单价覆盖不了成本，是商业模式不成立；时延太差伤害体验，是需求端跑掉；利用率上不去，是供给端烧钱。三者必须拧成一股绳，推理侧才能真正接棒训练侧的叙事。

CHAPTER 04

1 推理商业化链条拆解为四段递进

2024年春天，一家国产大模型厂商发布推理API，开发者社区里欢呼一片。上线第一个月，日均调用量突破一亿次，第二个月翻了三倍。团队在朋友圈晒截图，配文说“需求被验证了”。到了第三个月，技术负责人发现一个怪事：调用量继续涨，但账单上的收入几乎没动。原来，大量调用来自免费测试账号和最低档套餐的轻量用户，真正按量付费的企业客户不到10%。需求确实出现了，但需求的质地出了问题。

这不是一家公司的遭遇。行业正在经历一场典型的“虚假繁荣”：模型能力刚跨过可用门槛，开发者涌进来做PoC（概念验证），企业IT部门把AI功能写进标书，但钱还没真正从预算里流出来。推理商业化链条的真实顺序是：先有人调用，再把调用嵌入业务流程，然后计费模式稳定下来，最后资源利用率爬坡。四个环节环环相扣，任何一个卡住，整个链条就停在半空。

调用需求形成只是第一步。2024年国内大模型API日均调用量从年初的几十亿次冲到年末的数百亿次，但拆开结构看，超过60%的调用集中在文本生成和简单问答这类低客单价场景。嵌入业务流程是第二步，也是最漫长的一步。一家银行采购了智能客服推理接口，技术对接花了两个月，合规审查又拖了三个月，上线后发现一线柜员不爱用，因为系统返回的话术需要二次修改，没有直接节省人力。产品嵌入业务流程，不仅意味着API接通了，还意味着用户的工作习惯被改变了。这个改变的速度，通常比技术部署慢三到五个季度。


计费模式稳定是第三步。早期市场充满试探。厂商A按token计费，客户抱怨账单不可预测；改为包月套餐后，重度用户占了便宜，轻度用户流失。厂商B推项目制报价，前三个月收入好看，但第四个月客户要求免费迭代，利润被稀释。2024年

四季度，头部厂商开始推"基础包+超量按token"的混合模式，这本质上是在用价格工具筛选客户结构，把低价值调用从利润表上挤出去。计费模式稳定的过程，就是客户分层的过程。

资源利用率爬坡是第四步。推理服务的成本结构高度依赖GPU利用率。一家部署了千张A100的推理集群，如果平均利用率只有35%，每张卡的有效产出就被摊薄到极限。利用率上不去的常见原因有两个：一是峰值保护，为了应对早晚两个调用高峰，必须保留冗余算力；二是模型版本碎片化，不同客户绑在不同版本上，无法统一调度。2024年下半年，行业开始讨论"推理集群的波峰波谷调度"和"模型版本归一化"，这些技术问题的背后，是利润表对利用率数字的苛刻要求。

四个阶段的节奏并不一致。调用需求可能在三个月内爆发，但嵌入业务流程需要六个季度，计费模式稳定需要两到四个季度，利用率爬坡更是持续进行的基础设施工程。这就是推理商业化的核心时滞：需求已经站在了门口，但收入质量与成本结构还在门外徘徊。

图5.推理单位Token成本拆分示意图



CHAPTER 05

2 利润表拐点取决于计费与利用率同步

2023年，一家硅谷AI应用公司年收入从5000万美元跳到2亿美元，市场给了一个漂亮的PS倍数。到了2024年，收入继续涨到3.5亿，但股价跌了40%。财报电话会上，CFO说了一句被市场忽略的话："我们的推理毛利率是负12%。"需求验证完成了，收入增长也还在，但利润表拐点始终没有出现。问题出在两个数字没有同步爬坡：计费模式没稳定，资源利用率没上去。

计费模式稳定对利润表的影响比大多数人想象的更直接。按token计费的模式下，收入和客户使用量线性挂钩，但成本却受模型版本和集群架构影响呈阶梯式跳跃。每一次模型升级，推理成本可能下降30%，也可能因为上下文窗口扩大而上升20%。如果计费单价在模型升级前已经锁定，利润就被压缩。2024年，国内几家头部厂商在一年内调整了三次推理定价策略，每次调整都引发存量客户的重新谈判。定价策略的摇摆，本质上是在寻找"客户愿意付的钱"和"服务实际花的成本"之间的稳定交集。这个交集没找到之前，利润表上的毛利率就是漂移的。

资源利用率爬坡的困难在于推理负载的不可预测性。训练集群的负载是规划出来的，工程师知道三个月后要跑什么任务，可以提前把GPU排满。推理集群的负载是客户行为决定的，早上九点一个爆款应用触发调用洪峰，中午又陷入沉寂。为了保障延迟SLA，运营商必须保留30%到50%的冗余算力。这部分冗余在账单上没有对应收入，但在资产负债表上对应折旧。2024年行业出现一个新词叫"推理调度优化"，核心目标就是把冗余率从50%压到20%，手段包括模型切片、请求批处理、跨区域负载均衡。这些技术每推进一厘米，毛利率就改善一厘米。

两个因素必须同步。计费模式稳定决定了收入端的可预测性，利用率爬坡决定了成本端的效率。如果只有计费模式稳定而利用率低下，收入虽然好看，但每一块钱收入背后都拖着沉重的成本尾巴。如果只有利用率爬坡而计费模式仍在价格战里摇摆，成本效率的提升会被定价侵蚀，利润表依然站不住。利润表拐点的真正标志，不是收入增速达到某个百分比，而是"每增加一亿次调用，利润增加多少"这个斜率由负转正。这个斜率转正的时刻，才是推理商业化从叙事进入经营的里程碑。

CHAPTER 06

3 早期低价与冗余算力导致双率承压

2023年国产大模型推理定价大概在0.1元每千token。到了2024年春天，头部厂商把价格砍到0.01元，降幅90%。降价不是阴谋，是阳谋：模型能力接近，客户迁移成本极低，谁不降谁丢市场。但0.01元的背后，是一张被压缩的利润表。一家中型推理服务商在2024年二季度的财务数据显示，推理业务收入占总收入35%，但贡献了不到10%的毛利。更隐蔽的问题是，这35%的收入里，超过一半来自项目制交付，而不是标准化的API调用。

项目制报价是早期市场的通病。客户说"我要一个智能客服系统"，厂商报价80万，包含模型微调、接口开发、运维保障。项目做完，客户运行一年，调用量涨了三倍，但厂商收不到增量钱，因为合同是一次性定价。项目制的本质，是用工程师的工时换取客户的信任，但工时在利润表上体现为费用，而不是可复用的资产。2024年，行业开始从项目制转向订阅制，但订阅制的转化过程极其痛苦。客户已经习惯了"一锤子买卖"，对"每年续费+按量叠加"的模式充满抵触。订阅化转化慢，意味着收入确认方式始终停留在低质量区间。


冗余算力是另一个利润杀手。推理服务为了保障延迟体验，必须预留峰值缓冲。一家服务于C端应用的推理集群，峰值调用可能是均值的五倍，运营商不得不把集群规模按峰值配置。结果是，日均利用率不到30%。2024年三季度，某头部云厂商披露其推理集群平均利用率为38%，而训练集群平均利用率为72%。这34个百分点的差距，就是推理毛利率被压缩的暗道。冗余算力不直接出现在利润表上，它藏在折旧费用里，藏在运维成本里，藏在每一张只发挥了三分之一能力的GPU账单里。

毛利率和费用率因此同时承压。低价策略压缩了收入端的毛利率，项目制交付和冗余算力推高了成本端的费用率。双率承压的结果，是一些推理业务在收入规模已经过亿的情况下，经营利润仍然为负。2024年四季度，市场开始重新评估推理服务商的估值逻辑，从"收入增速叙事"转向"单位经济模型叙事"。这个转换的触发点，正是利润表上双率承压的现实无法再被收入增长掩盖。收入增长越快，亏损放大越快，这就是低质量增长的陷阱。

CHAPTER 07

1 核心竞争力需满足四重条件

图6. 推理市场头部/中腰部/长尾企业收入结构（留存率/折扣率/利用率）截面



推理业务如果要形成真正的竞争壁垒，需要同时满足四件事：单位Token收入成立、单位Token成本下降、并发与时延不恶化到伤害需求、最终转化为更高的利用率。

四件事缺一不可。缺了收入成立，就是白忙活。缺了成本下降，就是规模越大越痛苦。缺了时延控制，用户会头也不回地走掉。缺了利用率提升，固定资产折旧会拖死现金流。


这四件事不是并列的，而是递进的。先要有产品效果，用户才愿意付第一笔钱。然后要想办法降本，让这笔生意有利可图。降本的过程中不能牺牲体验，否则用户留存会崩。最后，通过技术手段把降本的空间转化为更高的批处理效率和调度效率，让同一张GPU能服务更多请求，利用率自然就上去了。

DeepSeek的做法很典型。通过动态稀疏训练技术，单次推理成本降低了70%。这不是简单的“少算一点”，而是在保持模型能力的前提下，精准地跳过不必要的计算。代价是什么？代价是工程复杂度急剧上升。不是每家公司都能做这种级别的优化。能做的人，成本曲线会向下弯；做不了的人，只能在价格战中被越甩越远。

CHAPTER 08

2 四者递进关系决定盈利路径

图7. 推理企业"留存率→计费稳定性→利用率→利润率"传导链条时滞



推理业务的盈利路径，可以用一条链条来理解：产品效果决定用户是否愿意付费；用户付费之后，厂商开始考虑降本；降本的手段不能伤害产品效果；降本省下来的空间，一部分变成利润，一部分变成价格优势，吸引更多用户；更多用户带来更高的利用率；更高的利用率进一步摊薄固定成本，形成正向循环。

这条链条任何一环断裂，盈利路径都会中断。

如果产品效果不好，用户不付费，后面一切都无从谈起。2024年很多大模型API的窘境就在于此：模型能回答问题，但回答质量不够稳定，企业客户不敢把核心业务流程绑在上面。到了2025年，随着R1、GPT-4o等模型在推理能力上的突破，

"产品效果"这一环开始真正闭合。

如果降本手段太粗糙，伤害体验，用户会流失。想象一个场景：一个代码生成模型为了节省算力，把思考深度从十层压缩到三层，结果代码正确率从90%跌到70%。开发者用两次就会发现"这玩意不好使"，然后回到GitHub


Copilot。降本必须是一个精细的手术，而不是粗暴的截肢。

如果利用率上不去，固定资产折旧会吃掉所有利润。火山云太行算力中心二期规划了1.6万个12kW机柜，总投资45亿元。单机柜总投入28万元。这些机柜如果空置率超过四成，折旧和电费会让财务报表很难看。宁夏中卫数据中心的上架率从30%跃升至92%，这是一个积极的信号。但92%是需求驱动的，还是价格补贴驱动的？如果是后者，一旦补贴退坡，利用率可能回落。这是推理盈利路径上最大的不确定性之一。

CHAPTER 09

3 不同场景壁垒形态不同

图8. 推理行业景气拐点前后CR3/CR5集中度与头部/尾部财务可见性差异



推理不是单一市场。搜索、聊天、代码生成、图像生成、视频生成，每个场景对"体验"的定义不同，壁垒的形态也不同。

搜索场景重响应速度。用户输入关键词，零点三秒内必须出结果。每多一毫秒，用户耐心就流失一分。Google为搜索速度优化了二十年，从分布式索引到边缘缓存，每一层都是在和毫秒赛跑。AI搜索继承了这套遗产，但增加了推理计算的复杂度。怎么在零点三秒内完成一次大模型推理？这是搜索场景的核心壁垒。做不到这点的厂商，只能做"慢搜索"，而慢搜索的市场天花板比快搜索低一个数量级。

聊天场景重连续对话体验。用户和AI助手聊十个来回，如果第八个来回开始模型"失忆"——忘了前面聊过什么——体验就会断崖式下跌。上下文窗口的长度、注意力机制的稳定性、长序列推理的时延控制，这些是聊天场景的壁垒。Claude的20万Token上下文窗口、Gemini的100万Token，都是在这个维度上竞争。


代码生成场景重正确率与延迟容忍度的平衡。开发者写一个函数，AI补全代码。正确率必须高，因为错误的代码会导致编译失败或运行时Bug。但延迟容忍度比

搜索和聊天稍高一些——开发者愿意等一两秒，如果补全质量足够好。代码生成的壁垒在于：如何在一个相对宽松的时延预算内，输出高正确率的代码。这要求模型对编程语言的语法、语义、工程惯例有极深的理解，不是随便一个通用模型都能做好的。

不同场景，壁垒不同。没有一家厂商能在所有场景都做到最好。这意味着推理市场不会是一家独大，而是会在不同场景出现不同的领先者。这也给后来者留下了机会：找到一个细分场景，把体验做到极致，就能切下一块蛋糕。

CHAPTER 10

4 实时交互与批量处理的资源调度逻辑不同



数据来源: 公司财报、行业历史

2024年秋天，一家云厂商的工程师分享了一个内部数据：同一个推理集群，白天服务实时客服对话，平均利用率28%；夜间切换到文档批量处理，利用率拉到85

%。两个场景共用一套硬件，但资源调度逻辑完全不同。这个差异，是推理服务成本结构的分水岭。

实时交互场景的核心约束是延迟SLA。一个客服机器人如果回复时间超过3秒，用户放弃率从5%跳到35%。为了保证这个3秒红线，运营商不能把资源调度压到极限。必须保留算力缓冲，必须优先排队而不是批处理，必须让模型常驻显存而不是动态加载。这些约束的代价，就是利用率的天花板。实时交互场景的利用率通常很难突破50%，因为超过50%意味着峰值时段的延迟风险急剧上升。这个天花板不是技术问题，是商业问题：延迟失控导致的客户流失，比多买几张GPU更贵。

批量处理场景完全是另一套逻辑。夜间处理文档、生成报告、跑数据分析，这些任务对延迟不敏感，但对吞吐量敏感。工程师可以把几十个请求打包成一批，一次性喂给模型，让GPU的并行计算能力充分释放。批处理可以把利用率从30%拉到80%以上，成本效率提升超过一倍。2024年四季度，行业开始出现“推理分时调度”的架构设计：白天把大部分算力分配给实时交互任务，保留基础吞吐能力；夜间把算力倾斜给批量处理，把闲置资源吃干榨净。这种“白加黑”模式，本质上是试图用时间维度上的调度，来抹平空间维度上的冗余。

两种调度逻辑的壁垒形态也不同。实时交互场景壁垒在于“低延迟下的资源保障”，需要精细的模型切分、请求优先级队列和显存常驻策略。批量处理场景壁垒在于“高吞吐下的批处理效率”，需要请求聚合算法、动态批大小调整和负载均衡。一个团队很难同时精通两套逻辑，因为实时交互要求“稳”，批量处理要求“满”，两个目标在工程上存在张力。2024年，市场上已经出现专门服务实时交互的推理厂商和专门服务批量处理的推理厂商，分工正在发生。

CHAPTER 11

1 规模经济与数据反馈形成正反馈

推理业务一旦跑起来，会呈现出强烈的规模经济特征。调用量越大，单位成本越低；数据反馈越多，模型效果越好；模型效果越好，用户粘性越高；用户粘性越高，调用量越大。这是一个闭环。

这个闭环里，利用率、时延控制、客户留存、模型适配效率、采购成本，都具有规模经济和数据反馈的特征。大厂的推理集群每天处理数十亿次请求，每一次请求都是一次数据反馈。哪些Prompt容易出错，哪些场景需要优化，哪些用户愿意

付费，这些数据只有高频调用的厂商才能积累。数据反馈变成模型迭代，模型迭代变成体验优势，体验优势变成市场份额，市场份额变成更大的数据反馈。

OpenAI的ChatGPT就是一个典型例子。2022年11月发布时，它只是一个“好玩”的demo。但到2023年底，周活用户已经超过1亿。这1亿用户每天产生的对话数据，成为OpenAI持续改进模型的燃料。后来者即使有同样的算力，也很难在短期内获得同等规模的数据反馈。这是推理侧“赢家通吃”逻辑的根源。

但“通吃”不等于“全部吃完”。

CHAPTER 12

2 标准化通用市场趋于集中

标准化通用推理市场，确实在走向集中。通用聊天、通用写作、通用问答，这些场景对模型的要求相对一致，用户也不挑剔——能用就行，便宜更好。在这样的市场里，规模就是一切。谁的调用量大，谁的单位成本低，谁就能给出更低的价格，抢走更多用户。

价格战的迹象已经很明显。2024年到2025年，国内大模型API的价格经历了多轮下调。字节、百度、阿里、腾讯，几家大厂你追我赶，把Token单价从几块钱打到几毛钱。这不是慈善，这是标准的规模竞争逻辑：用短期亏损换长期市场份额，等对手熬不住了，再慢慢提价。

但标准化市场的集中，不等于整个推理市场的终结。定制化、区域化、垂直化的需求，给中小服务商留下了生存空间。

想象一下，一个专门做法律合同审查的AI服务商。它不需要在通用聊天上和大厂竞争，它只需要在“合同审查”这个垂直场景里做到最好。法律术语的精准理解、风险条款的识别、格式规范的校验，这些能力通用模型也能做，但做不到最好。垂直服务商通过深耕一个行业，积累专业数据，训练专用模型，可以在细分领域建立比大厂更深的护城河。

再想象一下，一个区域化的推理服务商。它的机房在二线城市，电费比一线城市便宜30%，latency对本地用户来说可以接受。它不做全国市场，只做华东制造业集群的智能化改造。这种“小富即安”的商业模式，大厂看不上，但日子过得可能比那些盲目扩张的通用服务商更踏实。

CHAPTER 13

3 景气变化分层传导

推理市场的景气变化，不是一刀切地涨或跌，而是分层传导的。

上行初期，供给紧缺者受益。2023年初，ChatGPT爆火之后，全球算力紧缺，谁有GPU谁就能卖高价。英伟达股价一年涨了两倍多，云计算厂商的GPU实例价格居高不下，算力租赁公司排队接单。这是景气上行初期的典型特征：供不应求，利润向资源拥有者集中。

供给扩张后，利润向应用入口回流。2024年到2025年，随着GPU产能释放、云厂商扩产、国产芯片替代加速，算力供给从紧缺走向过剩。供给过剩之后，议价权从“谁有卡”转向“谁有客户”。应用层——也就是离用户最近的那一层——开始掌握利润分配的主导权。一个做AI客服的SaaS公司，如果绑定了1000家企业客户，它可以在多家推理服务商之间比价，压低成本，把利润留给自己。

成熟期，基础设施层趋于公用事业化。当算力供给彻底过剩，推理服务变成像水电煤一样的基础设施，定价权交给规模效率和运营成本。只有少数几家巨头能在这个层面持续盈利，它们靠的不是技术领先，而是成本控制和运营效率。其他玩家要么向上游做应用，要么向细分做垂直，要么被淘汰。

这个分层传导的过程，在云计算市场上已经发生过一次。AWS最早做IaaS，赚的是基础设施的钱。后来SaaS兴起，Salesforce、ServiceNow这些公司赚的是应用层的钱。到现在，AWS依然在赚钱，但利润率最高的已经不是裸算力，而是上层的数据库、机器学习平台、企业服务。推理市场正在重演这个剧本。 ---

CHAPTER 14

1 市场价值分三层

2025年5月，国内某大模型API平台宣布月调用量突破十亿次。同一天，另一家二线厂商的客户流失率超过60%，原因不是模型效果差，而是客户试完就没再续费。两个数字出现在同一张行业简报上，但讲的是完全不同的故事。

算力链的市场价值从来不是一个平滑的整体，它至少分三层。第一层是头部平台手里的长期需求，这些客户不是来试水的，而是已经把推理服务嵌进了自己的业务流程。调用是每天都在发生的，价格是签在年度合同里的，折扣是有限的。第二层是中腰部厂商承接的阶段性爆发需求，增速看起来漂亮，但客户结构不稳定

，收入来源里实验性预算和渠道返点占比高。第三层是长尾，大量项目制、一次性、定制化交付，这些需求制造了行业热度，却很少沉淀为利润表上的经营性现金流。

三层之间的差异不是收入规模，而是收入的"留存率"。头部平台的客户续约率通常在80%以上，中腰部可能只有40%到50%，长尾则几乎不存在续约概念。同一个行业里，有人在做生意，有人在刷流水。

CHAPTER 15

2 头部如何把波动需求变成稳定现金流

头部玩家做的不是简单地"多卖算力"，而是把原本离散、波动、带试验性质的调用需求，转化为可以预测、可以复用、可以提价的收入结构。这个过程靠三件事：产品标准化、计费规则设定、客户结构筛选。

产品标准化意味着接口稳定、文档完整、SLA可承诺。企业客户最怕的是"今天调得通，明天报错"，或者"模型一升级，原有代码全部重写"。头部平台通过版本管理和兼容层设计，把技术不确定性封装在后台，前台只呈现稳定的调用体验。这对客户来说省掉了大量适配成本，对平台来说则把客户锁进了一个生态。

计费规则设定更关键。项目制报价、临时折扣、预充值返利，这些方式在短期能冲高收入，但长期会制造利润表噪音。头部平台推进的是标准化计费：按调用量、按并发套餐、按服务等级。计费规则一旦固化，客户对价格的预期就稳定了，平台对收入的预测精度也提升了。价格不再是一场场谈判，而是一套规则。

客户结构筛选则是最后一道闸门。头部平台会主动放弃那些只来试单、要求大量定制、对价格极度敏感的客户。这些客户不是没有价值，而是服务他们的成本太高，留存率太低，算下来是亏的。筛选之后留下的客户池，调用频次高、使用深度大、迁移成本高，这才是高质量收入的真正来源。

中小玩家的生存状态不能只看客户数。一家厂商有五百个客户，但如果其中三百个是试用账号，一百个是渠道拉来的低黏性流量，真正付费且续约的只剩几十个，那这五百个客户数就是一个幻觉。判断中小玩家抗周期能力的硬指标，是收入中实验性预算、渠道性收入和低黏性流量各自的占比。占比越高，景气退潮时跌得越快。

CHAPTER 16

3 集中度不是消灭对手而是分层

行业集中度上升并不意味着中小企业全部消失，而是价值分配在收入质量上越来越向头部倾斜。2025年上半年，国内前五大模型API平台占据了约70%的调用量，但收入占比可能更高。原因很简单：它们不仅客户多，而且客户用得深、付得多、走得少。

头部平台在算力调度上也更平滑。因为客户池大、调用模式多样，它们可以错开峰值，把训练任务和推理任务放在不同的时段运行，把高优先级请求和低优先级请求分配到不同资源池。利用率因此比中小厂商高出一截。一张GPU在头部平台手里可能一天跑满十八个小时，在中小厂商手里可能只跑满十个小时，剩下的八小时在空转折旧。

这种差距不是技术差距，而是规模差距带来的经营质量差距。中小厂商不是模型不够好，而是客户不够稳、调用不够密、调度不够平。它们是同一个赛场上的运动员，但跑在不同的赛道上。

CHAPTER 17

4 景气变化中的价值分配

推理市场的景气变化，不是一刀切地涨或跌，而是分层传导的。2024年，国内大模型API调用量全年增长超过300%。几乎所有厂商的仪表盘都在闪烁绿色数字。客户数在增加，调用量在暴涨，利用率在抬升。但很少有人问一个问题：这些增长里，有多少是“用三个月就走的”，有多少是“价格补贴换来的”，有多少是“热点应用驱动的脉冲需求”。

景气上行时，行业最容易出现的误判是把“调用量上升”当成“商业成熟”，把“客户数增加”当成“留存改善”，把“高利用率”当成“高盈利能力”。如果增长主要来自促销、试用和短期热点，那么头部和中小之间的差距未必缩小，反而可能在需求退潮后迅速拉大。因为头部有更强的价格纪律、更稳定的交付能力和更完整的客户成功体系，它们能在潮水退去时守住阵地；而中小厂商在潮水上涨时冲得最远，退潮时搁浅得最快。

更隐蔽的陷阱是“虚假集中”。景气上行期，一些中小厂商可能接到短期大订单，利用率瞬间拉高，收入报表看起来很漂亮。但这笔订单如果是定制项目、一次性

交付，或者客户只是在做试验性采购，那么高利用率并不反映真实竞争力。等到试验结束，客户没有续约，利用率断崖式下跌，利润表会暴露得更惨。

反过来看，如果景气走弱或市场进入拐点，价值分配反而更容易向真正拥有高留存客户和稳定计费框架的主体集中。原因很简单：预算收缩时，客户会优先砍掉那些实验性的、替代性强的、可砍可不砍的支出。嵌入业务流程、迁移成本较高、服务稳定性较强的平台，会被保留下来。

2025年二季度，部分企业客户的AI预算开始收紧。一个做零售的企业IT总监说，他砍掉了两个“还在试用”的AI项目，但保留了已经嵌入客服系统的推理服务。因为前者的停用成本是零，后者的停用成本是重新培训客服、重写系统接口、重新评估供应商。留存的价值，在预算紧张时反而最清晰。

行业集中度的提升，往往发生在第一次景气回落之后。热潮阶段所有人都在增长，市场区分不出谁好谁坏。退潮阶段，客户用脚投票，真实需求浮出水面。那些靠补贴和试用撑起来的收入最先暴露，而真正嵌入客户业务的收入反而更加稳固。所以集中度不是被“做大”的，而是被“筛选”出来的。

CHAPTER 18

5 财务可见性比技术参数更重要

市场最终给更高估值和更高价值分配的，通常不是技术参数最强的公司，而是财务可见性最高的公司。财务可见性不是指财报多好看，而是指收入能不能预测、毛利能不能稳定、费用是不是可控。

技术差异决定企业能不能入场，商业成熟度决定企业能不能留在场上。一家厂商的模型可能在某个benchmark上排名第一，但如果它的计费方式是一家一价、回款周期超过九个月、客户半年换一次，那么利润表就会长期处于混乱之中。市场很难给这种混乱定价。

估值锚从“流量”切换到“单位经济”时，客户留存率的重要性进一步抬升。因为留存率直接连接未来收入的确定性，它是投资者用来预测明年收入的最可靠信号。计费稳定性紧随其后，因为它连接毛利率与收入确认质量。利用率则继续扮演结果变量，但一旦前两者成熟，利用率会成为利润弹性最大的放大器。三者齐备，估值才从“讲故事”走向“算得清”。

CHAPTER 19

1 核心竞争力是三组变量

推理业务的核心竞争力不是某一张GPU的型号，不是某一次模型的benchmark分数，而是把三组变量同时驯服的能力：利用率、计费模式稳定性、客户留存率。

利用率决定固定成本摊薄的速度。推理集群一旦建成，折旧和电费是每天都在发生的。利用率每提升一个百分点，单位成本就下降一截。但利用率本身是个结果变量，它反映的是前面的商业安排是否成功，而不是商业成功的原因。

计费模式稳定性决定收入是否具备连续性。如果客户每次调用都要重新谈判价格，或者厂商要靠临时折扣和预充值返利才能把量拉起来，那么收入看起来在增长，但利润表的噪音也在放大。计费模式稳定的意思是：价格是透明的，规则是统一的，收入是可以被预测的。

客户留存率决定企业是否已经跨过了“获客”阶段，进入了“复购”阶段。推理商业化的核心难点从来不是第一次成交，而是客户试用三个月后，是否还愿意继续调用、扩大调用、把服务嵌进自己的业务流程。留存率就是这道门槛的硬指标。

CHAPTER 20

2 传导链条是留存先行计费跟上

如果把推理商业化看成一条河流，那么源头是客户留存，中游是计费规则，下游才是利用率。

客户留存先改善，意味着有一批客户已经离不开你的服务。它们可能是把推理API嵌进了客服系统，可能是把大模型接进了代码补全工具，可能是把调用链路写进了自动化流程。无论哪种情况，迁移都有成本，替代都有风险。留存一旦稳定，客户从“试用者”变成“使用者”，需求就从可选项变成了经营必需项。

留存稳定之后，计费规则才能固化。因为客户愿意长期用，厂商才敢于推出年度套餐、批量折扣、服务等级承诺。客户也愿意接受标准化计费，因为频繁换供应商的谈判成本和适配成本更高。计费规则一旦固化，收入预测精度就提升，资源配置效率就跟着改善。

计费稳定之后，负载才变得可预测。厂商知道哪些时段调用量高，哪些客户峰值重叠，哪些任务可以延迟执行。算力调度从“救火模式”变成“计划模式”。利用率因此逐步抬升，而抬升的方式是有序的、可持续的，不是靠脉冲式大客户测试或者

短期热点事件撑起来的。

最后，利用率提升才传导到利润表。毛利率改善，费用率回落，利润表拐点出现。这个顺序不能颠倒。如果只有利用率提升而留存没有改善，就像一个人只靠兴奋剂跑得快，药效过了就瘫。2024年不少智算中心的利用率曾经短暂冲到80%，但三个月后又跌回40%，原因就在于背后的客户大多是临时项目，走了一个就没了。

CHAPTER 21

3 利用率是放大器不是定义器

利用率当然重要。一张H100每天闲置十个小时，折旧和电费照样发生，这部分成本直接侵蚀毛利。但研究利用率时需要区分两种情形：被动拉高的利用率和有质量的利用率。

被动拉高可能来自短期大客户测试、价格补贴换量、临时性热点应用爆发。比如某款游戏突然接入AI NPC功能，调用量暴涨，但三个月后游戏上线，需求归于平淡。这种利用率改善是脉冲式的，来得快去得也快，不会沉淀为利润。

有质量的利用率来自复购客户群体扩大、工作负载结构稳定、计费制度可预期。客户每天早上九点准时调用，厂商可以提前调度资源；客户把推理服务嵌进了生产流程，调用量不会随着季度预算波动而大幅起伏。这种利用率提升是渐进的、可积累的，才能真正支撑利润率修复。

因此，利用率更像利润表的放大器。当留存和计费已经成熟时，利用率每提升一个百分点，利润就会不成比例地增长。但如果留存和计费还没稳定，利用率提升只是提前透支了未来的空间，甚至可能掩盖了根本性的经营脆弱。

CHAPTER 22

4 留存率才是利润表拐点最敏感的信号

如果要在三者中挑一个最接近利润表拐点的前置信号，客户留存率是最值得优先跟踪的。原因很朴素：推理商业化的终极问题不是客户来不来，而是客户走不走。留存改善意味着客户已经跨过了“技术好奇”阶段，进入了“业务依赖”阶段。一旦推理服务成为客户经营流程的一部分，需求就从可选支出变成了固定支出，收入才开始具备黏性。

留存率上升还会带来二阶效应。销售费用花在同一个客户身上的边际回报提升，因为不需要每次都重新说服；获客成本摊薄，因为口碑和深度使用会带来自然增购；客户成功团队的效率提高，因为他们从“救火”转向“优化”；调用波动率下降，因为客户使用模式趋于规律，资源调度更平滑。这些效应叠加在一起，最终推动利用率和毛利率同步改善。

2025年豆包大模型的付费转化率从5%提升到10%，看起来只是翻了一倍。但真正的变化在于，新增付费客户里有多少在三个月后还在调用。如果留存率同步改善，这5%到10%的跃升就是利润表拐点的前奏；如果留存率没有跟上，那就只是多了一些尝鲜的用户，下个月可能又走了。

CHAPTER 23

1 云计算历史参照价值迁移

要理解推理商业化的未来，最好的参照物是云计算的过去。

2006年，AWS推出S3和EC2。这是IaaS的起点。当时的企业客户，想要计算资源，要么自己买服务器，要么租用托管机房的物理机。AWS把计算资源变成了一种按需取用的服务，用多少付多少。这是一个革命性的商业模式，但利润并不丰厚。IaaS的毛利率通常在20%到30%之间，因为基础设施是重资产，折旧和电费是刚性成本。

2008年，谷歌推出Google App Engine，微软推出Azure PaaS。开发者不再需要管理服务器、配置网络、维护系统，只需要写代码，平台帮你处理一切。PaaS的毛利率比IaaS高一些，因为它在基础设施之上增加了软件层的服务，有了更多的定价权。

再后来，SaaS崛起。Salesforce把CRM搬到云端，ServiceNow把IT服务管理搬到云端，Workday把HR管理搬到云端。这些应用离用户最近，用户粘性最高，定价权最强。SaaS的毛利率可以达到70%以上。

云计算二十年的历史，是一条价值从IaaS向PaaS再向SaaS迁移的河流。利润中心从“资源拥有者”向“资源组织者”再向“应用创造者”迁移。推理商业化正在走同一条路。

今天的大模型API，相当于云计算早期的IaaS。它提供的是裸推理能力，按Token计费。利润薄，竞争激烈，同质化严重。明天，会出现更多的推理中间件——模型路由、Prompt管理、A/B测试、安全合规——这相当于PaaS层。后天，真正赚

钱的可能是那些把推理能力封装成完整应用的公司——AI客服、AI销售、AI法律顾问——这相当于SaaS层。

历史不会重复，但会押韵。云计算的韵脚，推理市场正在重读。

CHAPTER 24

2 收入成本结构需切换

推理商业化从概念期进入经营兑现期，需要两个结构性的切换：收入从项目制转向订阅/高频调用制；成本从增量成本主导转向固定成本摊薄主导。

项目制的收入模式，是一锤子买卖。客户来谈一个项目，做一个定制化的AI应用，验收之后付款，合作结束。这种模式的坏处是收入不可预测，客户粘性为零，每次都要重新销售。2024年，很多大模型B端业务就是这种模式。客户说“帮我们做一个智能客服”，厂商做完之后，客户说“先用着，效果不好再换”。没有续费，没有扩展，没有网络效应。

订阅制或高频调用制不一样。客户每个月付固定费用，或者按调用量持续付费。收入变成了经常性收入（Recurring Revenue），可以预测，可以累积。豆包大模型2025年月度收入从500万跃升至7000万，这背后是付费转化率从5%提升到10%。转化率提升的本质，是客户从“试试”变成了“天天用”。

成本端的切换同样重要。推理业务早期的成本结构是增量成本主导：每多一个客户，就多一份GPU租赁费用、多一份网络带宽费用、多一份运维人力费用。这种成本结构下的利润很薄，因为收入和成本同步增长，规模效应出不来。

固定成本摊薄主导，是成熟期的标志。企业自建或买断GPU集群，一次性投入大，但后续边际成本极低。火山云45亿元建1.6万个机柜，这是巨大的固定成本。但如果这些机柜的利用率能跑到90%以上，每一张新卡片的边际成本主要只剩电费。当固定成本被足够多的调用量摊薄，利润率就会陡峭上升。

从“增量成本主导”到“固定成本摊薄主导”，这个切换需要巨大的资本投入和运营耐心。不是每家公司都能熬过去。熬过去的，会进入一个新的利润区间；熬不过去的，会在规模扩张的半路上资金链断裂。

CHAPTER 25

3 估值三阶段从需求到收入到单位经济

AI推理产业链的估值遵循一个清晰的三阶段路径。第一阶段是需求验证定价。市场问的问题不是"赚不赚钱"，而是"有没有人用"。这个阶段的核心指标是日活用户、API调用量、客户签约数量。2023年，大量AI应用公司靠这个叙事拿到了高估值，因为市场需要相信一个巨大的新需求正在诞生。这个阶段的估值逻辑类似早期互联网平台：先占用户，再谈变现。

第二阶段是收入增长定价。市场开始问"钱能不能收上来"，核心指标变成ARR（年度经常性收入）、收入增速、客单价。2024年上半年，行业普遍处于这个阶段。头部厂商披露季度收入增长50%到100%，PS倍数还能维持在20到30倍。但收入增长定价有一个隐含的脆弱性：它不区分收入的质量。一个靠项目制交付、一次性回款、低价策略堆出来的收入增长，和一个靠订阅制、高续约率、自然增长驱动的收入增长，在收入增速这个数字上看起来一样，但在利润表上的后劲完全不同。

第三阶段是单位经济和现金流质量定价。市场开始问"每一块钱收入花了几块钱成本"，核心指标变成毛利率、客户留存率、资源利用率、LTV/CAC。2024年下半年，这个切换正在加速。一家推理服务商如果收入增速80%但毛利率是负的，估值会被压缩到PS 10倍以下；另一家增速只有40%但毛利率超过60%、净留存率超过120%，估值反而能维持在PS 20倍以上。估值锚从"增速斜率"转向"单位经济模型的健康度"，这个转向的标志，就是利润表上的数字开始比收入增速数字更有定价权。

三阶段的切换不是平滑的，而是断崖式的。市场在某一个季度突然发现，收入增长的故事已经讲了两三年，但利润表没有改善。这时候估值倍数会迅速回退，从80倍掉到20倍，再掉到10倍。2024年四季度，这个断崖在多个AI应用标的上同时出现，不是偶然，是估值叙事切换的集中兑现。

CHAPTER 26

4 指标切换标志行业进入经营兑现期

2000年，Salesforce上市，市值约10亿美元。当时市场按"CRM软件用户增速"给它定价，因为SaaS是一个全新概念，没有现成的估值框架。到了2006年，Salesforce的用户数已经增长到让传统软件厂商紧张，但市值只有50亿美元，PS倍数从高峰回落。市场开始要求看到ARR、续约率、CAC回收周期。这些指标从边缘走向中心，标志SaaS行业从"概念期"进入"经营兑现期"。2020年，Salesforce市值超过2000亿美元，驱动估值的核心指标早已不是用户增速，而是自由现金流和利润率。

AI推理产业正在经历同样的切换。2023年到2024年初，行业处于概念期。估值由"用户调用量"和"收入增速"驱动，因为市场需要确认这个新需求真实存在。2024年下半年，概念期的红利开始消退。投资者发现，调用量可以靠免费策略堆出来，收入增速可以靠低价策略堆出来，但堆出来的数字不自动转化为利润。市场开始要求新的指标：客户留存率、推理集群利用率、单位token成本、LTV/CAC。这些指标不是附加信息，它们正在替代旧指标成为估值主叙事。

留存率是最先被重视的指标之一。2024年三季度，一家AI写作工具的月活用户超过500万，但三个月留存率只有8%。另一个竞品月活不到200万，但留存率超过35%。市场给后者的估值倍数反而更高。因为留存率直接决定了收入的可持续性。一个流失率90%的用户群，需要每个月重新获取90%的新用户才能维持规模，这意味CAC会被持续放大，LTV永远无法转正。留存率低于20%的推理应用，本质上是在用融资补贴用户试用，而不是在构建可持续业务。

利用率是第二个被重视的指标。2024年，市场开始要求推理服务商披露集群利用率数据。一家厂商如果收入增速100%但利用率只有30%，投资者会怀疑这100%增速背后隐藏着多少冗余成本。利用率不仅是一个效率指标，它还是商业模式成熟度的信号。高利用率意味着负载可预测、调度精细、客户结构稳定。低利用率意味着还在靠粗放扩张换增长，精细化管理还没有到位。

单位经济模型是最终的落脚点。市场开始拆解"每服务一个客户，花多少成本，赚多少收入，客户留多久"。这个拆解在2023年几乎没有人做，因为所有公司都在亏损，拆解出来的数字不好看。但2024年，随着部分头部厂商毛利率转正，单位经济模型开始成为估值分化的核心变量。毛利率、费用率、续约率、扩购率、CAC回收周期，这些数字组合在一起，决定了市场是愿意给20倍PS，还是只给5倍PS。指标切换的本质，是行业从"证明需求存在"转向"证明需求能赚钱"。这个转折点的到来，标志AI推理产业从概念期正式进入经营兑现期。

CHAPTER 27

5 利润表若未改善则估值安全垫侵蚀

2024年秋天，一家AI应用公司发布三季报：收入同比增长180%，毛利率从上年同期的70%掉到45%，费用率从55%升到68%。财报发布后，股价单日下跌22%。市场不是在惩罚收入增长，是在惩罚收入质量。这家公司用大量低价策略和项目制交付堆出了180%的增长，但每一次收入增长都在侵蚀利润表的安全垫。毛利率下降意味着每一块钱收入的含金量降低，费用率上升意味着获取这块钱收入的代价升高。双率夹击之下，估值安全垫以肉眼可见的速度变薄。

估值安全垫不是一个抽象概念，它是利润表上几个关键数字的排列组合。毛利率是收入端的保护垫：毛利率越高，覆盖固定费用的能力越强。费用率是成本端的保护垫：费用率越低，规模效应释放的空间越大。订阅化转化率是收入可持续性的保护垫：订阅收入占比越高，收入的预测性越强。利用率是成本效率的保护垫：利用率越高，单位收入的成本越低。这四个保护垫同时发挥作用，估值才能站得稳。任何一个保护垫被击穿，估值都会面临重估。

2024年四季度，市场开始系统性地审视这些保护垫。毛利率未改善是最直接的警报。一家推理服务商如果收入增长但毛利率持平甚至下降，说明它的定价能力在减弱，或者成本结构在恶化。费用率持续高位是第二个警报。如果收入增长180%但费用率也在上升，说明规模效应没有释放，每增加一块钱收入需要花更多钱去获取。这种“反规模效应”是估值的最大杀手。

订阅化转化慢是第三个警报。2024年，很多AI应用公司收入结构里项目制交付和一次性授权占比仍然超过50%。这意味着收入需要每一季度重新“打单”，销售费用无法摊薄。订阅化转化率低，本质上是客户黏性不足的财务体现。如果客户不愿意签年度合同，说明他们并不认为这个服务是不可替代的。估值模型里的续约率假设会因此下调，目标估值随之下降。

利用率无提升是第四个警报。2024年，部分推理服务商收入增长了两三倍，但集群利用率仍然停留在30%到40%的水平。这意味着收入增长是靠堆硬件堆出来的，而不是靠效率提升挤出来的。硬件堆出来的增长，对应的是资本开支的线性放大，不是经营杠杆的释放。资本回报率下降，估值倍数必然压缩。

四个警报同时响起时，估值安全垫就被彻底侵蚀。2024年四季度，多家AI应用和推理服务标的经历估值腰斩，表面原因是市场情绪变化，深层原因是利润表保护垫的集体失效。市场不是不再相信AI推理的长期价值，而是不再愿意为低质量的短期增长支付溢价。估值切换的残酷之处在于，它不发生在利润表改善之前，而发生在利润表恶化被确认之后。一旦确认，估值回落的速度远比估值上升时快。

CHAPTER 28

1 可比案例需满足三条共同逻辑

寻找AI推理产业的历史对照，不应该只看“技术都很新”或者“都很烧钱”。真正有价值的案例，需要满足三条共同逻辑：前置投入重、复购决定价值、规模释放依赖标准化。

2006年3月，亚马逊推出AWS的第一个服务S3。当时几乎没有人意识到这个举动会改变什么。AWS前九年没有公布单独盈利数据，只披露收入增长。亚马逊每年的资本开支超过30亿美元，大部分砸在数据中心和服务器的上。分析师问贝索斯什么时候赚钱，贝索斯的回答是“我不关心什么时候赚钱，我关心的是客户是不是在增加，他们是不是离不开这个服务”。2015年，AWS首次披露运营利润，当年盈利近20亿美元。从上线到盈利，走了九年。这九年里，AWS完成了一件比盈利更重要的事：证明了商业闭环可以跑通，然后才跑通利润闭环。

前置投入重意味着早期成本结构刚性强，收入增长不必然带来利润改善。云计算行业早期就是这样，亚马逊AWS在2006年推出S3和EC2之后，连续亏损多年。不是因为没客户，而是因为数据中心折旧、带宽采购、研发团队扩张都是前置且刚性的。收入增长被成本增长同步吞噬，利润迟迟出不来。AI推理产业同样符合这个特征：训练集群和推理集群的资本开支在2024年已经达到百亿级别，这些投入短期内不会转化为利润，但会在长期形成规模壁垒。

复购决定价值意味着客户第一次采购不代表商业闭环，真正的价值来自续费、加购和使用深度提升。SaaS行业是这个逻辑的典型。Salesforce在1999年成立后，前几年的收入增速很快，但盈利能力要到2008年以后才逐步释放。因为早期获客成本高，客户试用后不一定续约，直到产品成熟、客户成功体系建立、续费率稳定之后，单位经济模型才跑正。

规模释放依赖标准化意味着企业必须通过标准化产品和标准化计费降低交付摩擦，才能让规模扩张转化为利润释放。如果每个客户都要定制开发、单独部署、专属维护，那么收入增长带来的不是利润，而是人力成本和复杂度。只有当产品从项目制变成平台制，计费从谈判制变成规则制，规模效应才会出现。

CHAPTER 29

2 对照核心在拐点顺序而非增速

案例研究最重要的不是看哪个阶段增长最快，而是看利润表真正拐点出现时，先发生了什么。历史案例如果普遍呈现“留存先改善、计费后稳定、利用率最后抬升”的顺序，那么这就为推理商业化提供了有力的参照框架。

1999年，Salesforce成立，口号是“终结软件”。当时的软件行业是卖光盘、收授权费、一次性交付。Salesforce把软件搬到云端，按月订阅，在线更新。这个模式在2000年到2004年间几乎被整个行业嘲笑：客户不信任把数据放在别人的服务器上，订阅收入看起来比一次性授权少得多，公司连续亏损。2004年Salesforce上市

，市值约10亿美元。到2020年，市值超过2000亿美元。这200倍的涨幅，不是来自一个技术突破，而是来自四个变量的渐进演化：标准化程度提升、客户使用频率培养、成本曲线下行、估值锚迁移。

标准化程度提升是第一步。Salesforce早期也做定制开发，每个客户要单独配置。但定制化的代价是实施成本高、复制慢、利润薄。2005年后，Salesforce开始力推"标准对象+自定义字段"的折中方案：核心流程标准化，边缘需求允许自定义。这个策略降低了实施成本，让产品可以快速复制到不同行业。AI推理产业正在经历同样的标准化过程。2023年，厂商为客户做大量模型微调和私有化部署，定制化程度高。2024年，行业开始推"标准模型+参数调节"的轻定制模式，用预训练模型覆盖80%的通用需求，只把20%的边际场景留给定制。标准化的推进，直接决定了推理服务的毛利率能否改善。

客户使用频率培养是第二步。Salesforce在2006年推出AppExchange应用市场，2008年推出Chatter社交功能，2010年推出移动端。这些功能的共同目的不是增加新功能，而是增加用户打开Salesforce的频率。从每周用一次，变成每天用十次，从销售人员用，变成全公司用。使用频率的提升，直接转化为订阅续约率和扩购率。AI推理应用同样面临使用频率的问题。2024年的数据显示，超过60%的AI应用用户月使用次数不到5次。如果用户只是偶尔用一下，订阅续费的意愿会很低。培养高频使用场景，是推理服务从"尝鲜工具"变成"工作必需"的关键。

成本曲线下行是第三步。AWS在2006年到2015年间，存储价格下降了超过90%，计算价格下降了超过80%。这些下降不是单纯的市场竞争，而是来自规模效应、硬件效率提升、软件调度优化的综合结果。Salesforce的成本曲线下行来自多租户架构的效率提升，同一套服务器资源可以服务更多客户，边际成本递减。AI推理产业的成本曲线目前还处于早期下降阶段。2024年，推理成本相比2023年下降了约50%，但主要驱动力是模型压缩和量化技术，而不是规模效应。未来三到五年，随着集群规模扩大、调度算法成熟、芯片效率提升，推理成本还有持续下降的空间。成本曲线下行，是利润闭环兑现的基础设施。

估值锚迁移是第四步。Salesforce在2004年到2008年按PS估值，2008年到2012年按PS+ARR增速估值，2012年到2016年按PS+FCF估值，2016年后按PE+FCF估值。每一次估值锚的迁移，都对应一个经营里程碑：从收入增长到经营现金流转正，再到净利润转正。AI推理产业的估值锚正在从PS向PS+毛利率迁移，未来会进一步向PS+单位经济模型迁移。对照历史案例的意义，在于理解估值锚迁移的节奏不是线性的，而是阶梯式的。每个阶梯的跨越，都需要一个经营指标达到市场认可的阈值。thresholds不是固定数字，而是相对同行的比较优势。

AWS的拐点出现在2010年前后。此前几年，客户留存率在逐步提升，企业开始从"试用云服务"变成"依赖云服务"。随后计费模式趋于标准化，按需计费、预留实例、批量折扣等规则逐步清晰。最后利用率抬升，数据中心从早期的大量空置走向高负荷运行，毛利率开始改善。利润表拐点是在这三条曲线都趋于同向之后才出现的，而不是其中某一条单独冲高就能触发。

Salesforce的拐点则更清晰地展示了留存率的领先作用。2004年到2006年，Salesforce的客户续约率从70%左右提升到85%以上。随后定价结构从高度定制走向标准套餐，销售效率改善。最后随着客户池扩大，基础设施利用率提升，2008年以后盈利能力才明显改善。如果只看2004年的收入增速，可能会误判公司已经盈利在望；但留存率才是最早给出正确信号的指标。

CHAPTER 30

3 需求闭环只是起点单位经济是落脚点

2019年5月，Uber上市，估值800亿美元。当时Uber的年收入超过100亿美元，用户遍布全球六大洲，需求闭环看起来已经无可挑剔。但上市首日股价下跌7%，三个月内跌去近40%。问题出在单位经济模型。分析师拆解了Uber的单程经济：每次载客收入、司机补贴、平台运营成本、获客成本。结论是：扣除补贴后，Uber的每笔订单都在亏损。需求闭环已经跑通了——用户需要打车，司机需要接单，平台需要抽成——但单位经济模型没有跑通。每一单都在烧钱换增长，规模越大，烧得越多。这个发现把估值从800亿打到300亿。

AI推理产业目前面临同样的风险。2024年，市场热烈讨论"日均调用量突破多少亿""用户数量突破多少万"，这些数字证明需求闭环在形成。但需求闭环不等于商业闭环，商业闭环不等于利润闭环。需求闭环只是起点，它回答的是"有没有人用"。单位经济模型才是估值落脚点，它回答的是"用的人能不能让公司赚钱"。

Token消耗是单位经济模型的第一个变量。一个用户每天调用1000次API，每次消耗1000个token，和另一个用户每天调用100次，每次消耗10000个token，在收入上可能差不多，但成本结构完全不同。高频低消耗的用户对推理集群的调度更友好，利用率更高；低频高消耗的用户占用更多峰值资源，利用率更低。2024年，行业开始按用户结构拆解token消耗模式，因为同样的总收入背后，可能是完全不同的单位成本。

模型调用频次是第二个变量。一个嵌入企业工作流的推理应用，每天被调用数千次，和一个偶尔被打开的个人应用，调用频次差两个数量级。调用频次决定了客

户黏性和续约率。高频调用意味着用户的工作习惯已经依赖这个服务，迁移成本上升。低频调用意味着用户随时可以替代，客户价值存疑。2024年，头部推理服务商开始披露“每个企业客户的日均调用次数”，这个数字比客户数量更能反映收入质量。

客户黏性是第三个变量。客户黏性不是主观感受，是行为数据：续约率、扩购率、NPS评分、使用功能深度。2024年，部分AI应用公司的净留存率（NDR）超过120%，意味着存量客户不仅没流失，还花更多钱。另一些公司的NDR低于80%，意味着即使新客户不断涌入，老客户也在不断流失。净留存率100%是生死线：超过100%，说明产品在不断从存量客户身上挖掘价值；低于100%，说明产品获客只是在填补流失的窟窿。客户黏性最终要通过LTV/CAC来量化：一个客户的生命周期价值，能不能覆盖获取这个客户的成本，以及覆盖多少倍。

需求闭环只是起点，这个起点在2023年到2024年初已经被验证了。市场现在等待的是单位经济模型的验证。Token消耗、模型调用频次、客户黏性，这三个变量能不能组合成一个正向的单位经济模型，决定了AI推理产业的估值能否从叙事走向经营落地。历史案例的教训是：需求闭环可以支撑高估值，但只能支撑一两年。如果单位经济模型在一两年内没有跑通，估值会迅速从云端摔回地面。Uber的教训不是需求不够大，而是单位经济不够硬。AI推理产业需要警惕同样的陷阱。

CHAPTER 31

4 商业验证路径值得跟踪

最值得跟踪的不是“推理行业像不像过去的云计算”或者“像不像过去的SaaS”。历史不会重复，但商业验证的路径会重复。这条路径由三件事的先后完成来定义：客户稳定复购、企业统一计费规则、资源负载可预测并带来利用率抬升。

从“技术验证”跨入“商业验证”，是推理商业化必须跨过的一道门槛。技术验证问的是：模型能不能推理、效果够不够好、成本够不够低。商业验证问的是：客户愿不愿意持续用、计费规则能不能统一、资源调度能不能预测。技术验证解决的是“能不能做”的问题，商业验证解决的是“能不能赚钱”的问题。

研究员需要跟踪的不是某个孤立数字——比如利用率达到多少就判定成熟——而是三条曲线何时第一次开始同向收敛。客户留存率像点火器，它启动了整个商业引擎；计费模式稳定性像传动轴，它把前端需求转化为可预测的后端负载；利用率像转速表，它最终体现在利润表上的数字。点火器亮了，传动轴动了，转速表才会真正转起来。三者的收敛，才是利润表拐点的真正定义。

