
英伟达Rubin Ultra延期风险系列研究

HBM4认证瓶颈与系统件放大

狗不扯蛋·AI研究所

2026-07-12

摘要

HBM4供给由前道制造、后道封装、客户认证三段串联，有效供给等于三段最小值。三星HBM3E认证延迟18个月的教训表明，认证与制造拥有独立时间线，错配足以把技术领先企业拖入有货不能卖的困境。Rubin Ultra平台单柜功率跃升至600千瓦，液冷从可选项变成必须项。规格下修导致系统件需求被动放大，芯片数量翻倍意味着机柜、背板、网络端口数量翻倍。CX9交换机整网验证瓶颈意味着2025年只是验证规模年，可复制性打通才是放量拐点。

配套后手风险

CHAPTER 01

HBM4有效供给与认证瓶颈

■ 三段串联的木桶效应

2025年9月，三星的工程师等来了英伟达的一封邮件。HBM3E，通过认证。此前整整18个月，这条产线日夜运转，产出的样品却只能在仓库里等待。这是HBM4供应链最生动的课前预习：在存储行业，制造出产品和卖出产品之间，隔着一整条产业链。

HBM4的供给由三段串联而成。前道DRAM晶圆制造，后道堆叠封装，终端客户的平台认证。任何一段出现延后，整条链条的产出就会被卡在那一环。有效供给等于三段中的最小值，平均值和最大值在这里都不适用。

前道制造是第一步。HBM4的底层仍是DRAM晶圆，堆叠层数已经爬升到12层甚至16层。三星、SK海力士和美光需要在更先进的制程节点上把良率维持在一个可接受的水平。这个环节的苛刻之处在于，一颗底层DRAM芯片的微小缺陷，在堆叠之后会被放大成整个HBM堆栈的失效。晶圆不仅要足够多，还要足够好。

后道封装是第二步。前道是在平面上画电路，后道就是在垂直方向上盖楼。HBM4的堆叠层数已经上升到12层甚至16层，每一层都要通过TSV打孔、填充、键合，然后把整个堆栈和逻辑基板封装在一起。先进封装需要高精度热压键合设备、大面积硅中介层以及CoWoS这样的2.5D/3D产线。台积电的CoWoS产能长期以来就是AI芯片供应链的瓶颈，HBM4对封装的要求比HBM3E更高，层数增加后，散热和翘曲问题更严重。没有先进封装产能，前道造出来的晶圆只能堆在仓库里。

客户认证是第三步。HBM4必须和客户的AI加速芯片一起工作。客户要验证的是：高温高负载长时间运行下，信号是否完整？功耗是否在设计预算之内？热管理是否会导致降频？可靠性是否满足7×24小时运行的要求？这些测试需要把HBM4和GPU芯片集成在真实的系统环境里，跑上几个月甚至更长时间。任何一个环节出问题，供应商就要重新修改设计、重新流片、重新送样，然后从头再来。一个运动员不仅要自己练得好，还要和特定的搭档配合默契，而教练决定是否让你上场。

HBM4有效供给 = min(前道DRAM产出, 后道堆叠封装, 客户认证)。前道能造出100万颗晶圆，后道只能封装80万颗，有效供给就是80万颗。前道和后道都做到了100万颗，客户认证只通过了50万颗，有效供给就是50万颗。市场分析师在估算供给时，最容易把名义产能当成有效供给，把“能造多少”和“能卖多少”混为一谈。三星在2024年初宣布扩大HBM3E产能时，很多供应链调研给出的数字是产

能充足，实际出货却被卡在英伟达认证环节，长达18个月的供给真空由此形成。

“产能充裕、供给紧缺”的悖论，恰恰是三段串联木桶效应的鲜活注脚。

这三段链条的主导者还不一样。前道在存储厂商自己手里，后道需要存储厂商和台积电等封装厂协同，认证环节的主导权完全在客户手里。存储厂商可以决定自己的资本开支，可以和封测厂签产能协议，认证时间表却不由他们说了算。一家存储厂商在前两道跑得最快，只要在第三道被卡住，先发优势就会被时间抹平。在HBM4这一代，技术复杂度更高、客户要求更严、竞争格局更紧张，任何一段的延迟，都会让整个链条的产出预期大打折扣。

■ 从存储器到系统组件的技术跃迁

HBM4的I/O接口从1024翻倍到了2048。数据进出的通道直接宽了一倍。带宽飙升到2.5TB/s，堆叠层数进入12层甚至16层的新阶段。把一栋楼从12层加盖到16层，每一层都要保证电力、供水、通风系统完美对接，难度呈指数级上升。

功耗的提升是最容易被低估的变量。HBM4的功耗从上一代水平大幅提升到48W甚至80W。传统的风冷或者简单的散热片已经搞不定这个范围。冷却方式必须演进到Direct-to-Chip液冷，直接把冷却液送到芯片表面。这又是一个系统性工程——HBM4自己凉快远远不够，整个机箱、整个机柜、整个数据中心的液冷系统都要配合改造。

英伟达要验证的是：这个存储芯片装到我的Rubin Ultra平台上，能不能在高负载、长时间、复杂任务场景下稳定运行。认证范围从单一元器件扩展到了整机系统。每一个新增的子系统，都意味着多一轮测试、多一套验证环境、多一组边界条件排查。这远非“多填几张表格”，而是实打实的工程验证周期。

HBM4的身份已经转变。它从一个单纯的存储器，变成了一个系统组件。认证对象是整个系统，认证链条自然呈几何级数拉长。

■ 三星HBM3E的认证延迟教训

2024年4月，三星开始向英伟达送测HBM3E的8层和12层样品。市场一度期待它能很快进入英伟达的供应链，和SK海力士、美光形成三足鼎立。实际情况是，三星的HBM3E在热测试和功耗测试中未能达到英伟达的标准。第一次认证失败。之后重新修改设计，再次送样，再次遇到问题。这个过程从2024年4月一直拖到2025年9月，整整18个月。

这18个月里，三星的HBM产线日夜运转。它不断调整工艺、不断产出样品、不断和客户沟通。认证关卡未过，这些产出的绝大部分只能躺在仓库里，无法转化为对英伟达的收入。供应链的“热度”是真实的，财务报表的“兑现”是缺席的。

这18个月横跨了整个Blackwell平台的导入期。当三星最终在2025年9月通过认证时，英伟达的HBM3E订单已经被SK海力士和美光瓜分殆尽，三星只能拿到剩余份额，价格谈判的主动权早已不在自己手里。

从DRAM制造到封装成品需要5到6个月。三星在2025年6月或7月取得认证许可，考虑到制造到封装的固有周期，最终出货也要拖到年底。2025年上半年的产能，良品率达标，在账面上也只能算作“库存”，距离“收入”还有漫长的距离。对于一家存储巨头来说，几亿美元的存货在仓库里躺着，资金周转效率直接受影响，财务报表上的营收确认要向后平移至少两个季度。

这个案例的核心教训：认证和制造并行，拥有各自的“独立时间线”。认证绝非制造完成后的“收尾工作”。两条线之间的错配，足以把一家技术领先、产能充足的企业，硬生生拖入“有货不能卖”的尴尬境地。三星在2025年2月就已经实现了12层HBM3E产品的全面量产，这并没有改变它无法向目标GPU客户供货的事实。

HBM4的复杂度超越HBM3E，认证-制造错配的风险随之放大。HBM4的I/O接口从1024个翻倍到2048个，逻辑基板第一次采用了台积电代工的先进制程。SK海力士在2025年3月送出的HBM4样品被定义为“早期样品”，不是接近完成的工程样片，而是需要后续大量修改的初版。行业内的预期是，从送样到量产，HBM4需要9到15个月。中间有反复，两年以上也不奇怪。

■ 认证与封装路线的耦合风险

把HBM3E的教训平移到HBM4，形势更加严峻。认证和制造之间的错配属于结构性问题，而非偶发事件。对于Rubin Ultra来说，HBM4认证极有可能成为整个整机交付的首个主约束。其他环节再快、再好，这个环节卡住，整机就无法交付。

封装方案最终确定，连接路线调整成功，HBM4认证未完成，整机仍然无法交付。封装是必要条件，HBM4认证是另一个独立且同样关键的必要条件。两个条件必须同时满足，整机才能出厂。封装方案花了三个月敲定，HBM4认证花了六个月才通过，整机交付时间就由HBM4认证这个更长的链条决定。


HBM4认证和封装方案之间还存在耦合关系。封装路线中途调整，比如从某种方案切换到另一种方案，已经进行了一半的HBM4认证测试可能需要部分重启或者重新适配。两个并行的工程流之间不是简单的“取最大值”，而是可能产生相互干扰，进一步拉长总周期。

CHAPTER 02

HBM4配额分配与竞争格局演变


■ 名义产能与有效产能的缺口

图1. HBM4三大原厂产能分配与英伟达订单锁定比例




数据来源：交银国际/产业链/英伟达IR

图2. HBM4 vs HBM3E认证周期历史对照



总周期: HBM3E 6月 vs HBM4 10月

图3. HBM4需求结构——英伟达vs ASIC/自研芯片客户占比



2026年第一季度，全球HBM营收份额中，SK海力士占58%，三星和美光各占21%。SK海力士的HBM出货量从2024年的6.5Eb攀升到2025年的12.5Eb，2026年预计达到21.4Eb。这些数字看起来很壮观，SK海力士的领先产能正在被全行业争夺。英伟达是最大的单一客户，博通、亚马逊、AMD、华为，甚至更多ASIC设计厂商都在排队等着拿货。

这里的排队效应远比“先来后到”复杂。HBM4的供应商分配给每个客户的配额，取决于多重因素的乘积关系。英伟达的有效配额，可以大致拆解为：名义产能 × 良率 × 认证兑现系数 ×

优先分配系数。四个因子缺一不可，大多数人只关注前两个，忽略了后两个。

良率决定了能从晶圆上切出多少合格芯片，属于物理层面的约束。认证兑现系数决定了这批合格芯片中有多少能被特定客户实际接收。某一批HBM4通过了英伟达的认证，对英伟达来说，这批货就是有效供给。未能通过认证，即使物理性能合格，也无法装入英伟达的Rubin Ultra平台。优先分配系数则取决于客户的重要性排序、合同条款、长期合作框架等商业因素。SK海力士等供应商的产能被更多客户争夺，英伟达在单一供应商内部的优先级不变，分母上的竞争者增多，边际上英伟达能拿到的绝对数量也可能被摊薄。

■ ASIC需求对分配分母的放大

图4. 三星HBM4认证进度与底层工艺问题修复时间线





图5. HBM4价格曲线与第二/第三供应商放量节奏



英伟达在HBM市场的特殊地位，正在受到一个结构性因素的侵蚀。博通、亚马逊、AMD、华为，以及更多正在涌入AI芯片市场的参与者，它们对HBM的需求正在同步放大。这些ASIC客户中，有些是英伟达的直接竞争对手，有些是间接替代者。它们的共同点：都需要高性能HBM来支撑自己的AI芯片。

SK海力士等供应商的产能被更多客户瓜分，英伟达在单一供应商内部的优先级不变，整个行业的客户基数在快速膨胀。一张桌子上，英伟达分到的比例没变，但蛋糕周围突然多了几张嘴。从英伟达的视角看，它能拿到的HBM4数量，不仅取决于供应商对它有多优先，还取决于有多少其他客户在同一张桌子上吃饭。

ASIC客户的增速持续高于英伟达的增速，HBM市场的分配逻辑可能从“英伟达优先”逐渐转向“按合同价分配”或者“竞价分配”。对英伟达意味着两件事：一是它可能需要通过更长期的合同、更高的预付款来锁定供应；二是如果某一天供应不再紧张，这种“争夺”会变成供应商的议价筹码，而不是英伟达的。

■ 二三供应商的进展与信号

图6. HBM4从晶圆投片到客户交付的全周期时间线





图7. HBM厂商订单能见度与定价权指数



任何关键元器件，只有当第二供应商、第三供应商都能形成稳定可重复交付时，供需矛盾才能真正缓解。第一供应商可以领先，可以占据大部分份额，如果市场上只有一家能稳定供货，这家供应商的任何风吹草动都会传导到整个下游产业链。第二、第三供应商在同一平台上达到同等水平的交付质量，“替代”才从理论变成现实，供需格局才从“卖方市场”转向均衡。

三星在HBM3E上的障碍，出现在比认证更上游的环节——1a DRAM性能本身。问题出在HBM最底层的基础DRAM芯片上，封装和与GPU的接口适配都无济于事。1a DRAM的性能不达标，往上堆叠再多的层、做再复杂的封装，也改变不了根基。问题出在DRAM设计层面，重新设计意味着至少再推迟六个月。这六个月里，认证流程暂停，制造流程要么暂停要么转产其他规格，客户平台的导入计划也跟着后移。这条故障链条从底层工艺问题开始，向上传导到认证无法通过，再传导到客户平台无法导入，最终传导到收入延后和份额被锁定。在HBM4上，这条链条的每一环都比HBM3E更长。

三星在2026年2月启动了HBM4的量产出货，大约130天后营收突破10亿美元。这是一个相当快的爬坡速度，说明三星在HBM4上投入了巨大的资源，并且至少在

部分客户那里取得了突破。与此同时，三星把大约半数的HBM产能分配给了HBM4，战略上已经把HBM4作为下一代主力产品来押注。

美光的HBM4营收也突破了10亿美元，12层产品的爬坡速度是同规格HBM3E的两倍。这个“两倍”是一个关键信号。它说明美光在HBM4上的工艺成熟度比它在HBM3E上的时候要强得多，或者至少在12层这个特定规格上找到了更高效的生产路径。不管哪种原因，结果都一样：美光作为HBM市场的第三极，正在以比预期更快的速度加入HBM4的战局。

从英伟达的角度来看，三星和美光在HBM4上越成功，英伟达的供应链就越安全。更多的合格供应商意味着更多的认证席位、更大的有效配额、更小的单一供应商依赖风险。资本市场看到的却是另一幅图景：三星和美光都能稳定交付HBM4，供需紧张的预期就会松动，涨价预期就会降温，存储股的那层估值溢价，建立在“供应持续吃紧”这个假设之上。

英伟达需要三星和美光成功，来确保自己的供应链安全。资本市场看到三星和美光成功，就会开始怀疑HBM供不应求的故事还能讲多久。供需矛盾和估值叙事，在二三供应商的进展这个问题上，形成了方向相反的两个作用力。

■ 三星认证进度决定三强格局

在HBM4的供给格局中，最大的变量不是英伟达的需求有多大，也不是SK海力士和美光的产能有多强，而是三星的认证进度。三星作为全球规模最大的DRAM厂商，它在HBM4上的表现，将直接决定这个行业是从“两家主导”走向“三家竞争”，还是继续维持在“双寡头+一个追赶者”的状态。这个格局的转换，不是简单的“三星能不能做出来”的问题，而是“三星什么时候能以主力料号的身份进入英伟达的供应链”的问题。

三星的HBM4认证进度持续偏慢，英伟达可用合格供应商就只有SK海力士和美光两家。这两家已经在HBM3E的周期中证明了自己的能力，和英伟达建立了深度的合作关系。三星长期缺席，这种“两家主导”的格局会持续下去，并且产生一系列连锁反应。

订单集中度上升。英伟达为了确保供应链安全，三星缺席，更多的订单只能集中给SK海力士和美光。从客户的角度看，它并不希望只有两家供应商可选，任何一家的产能波动或质量问题都会对它的出货造成影响。英伟达会一直催促三星通过认证，同时给SK海力士和美光更多的订单。这种“被迫集中”的订单结构，让SK海力士和美光在谈判中占据了优势地位，它们也知道这种优势是暂时的——一旦三星进来，格局就会改变。在三星缺席的窗口期，SK海力士和美光会尽可能多地锁定长期订单、签订有利的LTA条款，为未来的竞争做准备。

议价权更强。在两家主导的格局下，英伟达的议价能力相对较弱。它不能轻易威胁把订单转给第三家，因为第三家还没有通过认证。SK海力士和美光可以据此要求更高的价格、更长的付款周期、更严格的绑定条款。在HBM3E的周期中，SK海力士作为英伟达HBM的主要供应商，享受了非常高的溢价，其HBM业务的利润率一度超过60%。美光虽然份额较小，但同样享受了短缺红利。三星继续缺席，这种高溢价状态会持续更长时间，供给的弹性被认证瓶颈人为压低。

英伟达作为客户，一直有动力去扶持三星，以打破两家垄断的局面。这意味着即使三星的认证进度慢，英伟达也会给它更多的技术支持和测试机会，甚至在某些非主力平台上提前导入三星的HBM4。这种“客户扶持追赶者”的策略，是产业链中常见的制衡手段。在三星缺席的窗口期，SK海力士和美光虽然享受了眼前的红利，但也知道它们正在培养未来的竞争对手。

估值逻辑的差异。在两家主导的格局下，市场会给SK海力士和美光更高的“稀缺溢价”，它们是仅有的合格供应商。这种溢价不仅体现在更高的PE倍数上，还体现在市场对它们长期市场份额的乐观假设上。投资者会认为，即使三星最终进来，SK海力士和美光已经建立了客户关系和技术壁垒，足以维持较高的份额。三星的缺席时间过长，这种稀缺溢价会被过度放大，导致股价中隐含了对长期垄断格局的预期。三星最终通过认证，市场需要重新评估这个格局，稀缺溢价会迅速消退，从而对股价造成压力。三星认证进度慢，对SK海力士和美光是短期利好、长期利空，短期享受溢价，但长期要面临竞争加剧的格局重塑。

三星的HBM4认证顺利通过，以主力料号的身份进入英伟达的供应链，供给格局会从两家主导变成三家竞争。这个变化看似简单，但对行业定价、利润分配和估值逻辑的影响是深远的。

价格谈判重心的下移。在三家竞争的格局下，英伟达的议价能力显著增强。它可以在三家之间进行比价、分单、甚至威胁把某家的订单转给另一家。供应商为了保住份额，不得不在价格上做出让步。在“挑客户”阶段，供应商的心态是“你爱买不买，不买有的是人买”；在“争订单”阶段，供应商的心态是“这个订单我一定要拿到，哪怕利润薄一点”。这种心态的转变，会直接反映在实际成交价格上。在HBM3E的后期，当三星最终通过认证后，市场上已经观察到HBM3E的价格松动，虽然幅度不大，但趋势是明确的。

订单分散化。英伟达为了降低供应链风险，会刻意把订单分散给三家，而不是集中在一家。这意味着即使某一家在技术或成本上有优势，它的份额也会被天花板限制。SK海力士在HBM3E上享受了超过50%的份额，但在HBM4上，市场普遍预期它的份额会下降到50%左右，而三星和美光会分别拿到25%到30%和20%到22%。这种分散化对供应商的影响是：收入增长的斜率变缓，因为增量订单被竞争对

手分流了；但收入的稳定性提高，因为单一客户的风险被分散了。

估值逻辑的转换。在两家主导的格局下，市场给的是“稀缺溢价”，即“你能做别人做不了的事，你值得更高的估值”。三家竞争的格局下，估值逻辑从“稀缺溢价”转向“兑现能力竞争”。市场不再问“你能不能做出来”，而是问“你能以多低的成本、多高的良率、多快的速度做出来”。这更接近传统制造业的估值逻辑，即看ROE、看成本曲线、看产能利用率，而不是看技术壁垒的稀缺性。这种估值转换通常伴随着PE倍数的压缩，因为制造业的估值中枢天然低于技术垄断型行业。

还有一个容易被忽视的细节：三星的特殊地位。三星不仅是存储厂商，它还有自己的代工业务（Samsung Foundry）和系统业务（比如AI芯片、手机、服务器）。这意味着三星和英伟达的关系比SK海力士和美光更复杂——它既是供应商，也是潜在的竞争对手。三星在HBM4上取得强势地位，它可能会利用HBM作为杠杆，换取在其他业务上的合作机会。这种“交叉谈判”的可能性，让三家竞争格局的博弈更加复杂。

真正改变行业定价逻辑的，在于“这个产品是否从边缘导入变成了主力料号”，以及“这个变化是否引发了竞争对手在价格和合同条款上的让步”。

“边缘导入”就是某家供应商的HBM4被用在客户的非主流平台上，比如测试平台、低端产品线、或者特定区域市场。这种导入虽然也算出货，但规模小、价格敏感度低、对竞争对手的威胁有限。竞争对手可能对此保持观望，不会立即调整自己的定价策略或合同条款。在这个阶段，新进入者只是“有了一席之地”，而不是“改变了游戏规则”。三星在HBM3E的后期，虽然通过了英伟达的认证，但初期拿到的份额主要是补单和次要平台，主力平台（比如GB200）的HBM3E仍然由SK海力士和美光主导。这种“有认证、无主力”的状态，并没有改变双寡头格局的定价逻辑。

“主力料号”就是某家供应商的HBM4被用在客户的核心平台上，成为该平台的主要或唯一供应来源。客户对新供应商的产品质量已经建立了充分信任，愿意把最重要的订单交给它。这种转变的信号通常包括：客户在新产品发布会上明确提到该供应商、该供应商的HBM4被用在旗舰型号的AI加速器上、订单规模达到该平台HBM需求的显著比例（比如20%以上）。当三星的HBM4从“边缘导入”变成“主力料号”时，SK海力士和美光才会真正感受到竞争压力。因为它们知道，客户现在有了替代选择，如果再维持高价和严苛条款，客户可能会把更多订单转给三星。

“竞争对手的让步”是关键。三星变成了主力料号，SK海力士和美光在价格上拒绝让步，坚持维持溢价和绑定条款，行业格局并不会真正改变。只有当竞争对手

因为三星的进入而被迫调整策略时，格局质变才发生。这种让步可能体现在多个维度：价格上接受更低的溢价、合同上接受更短的LTA期限、服务上接受更灵活的交货安排、技术上接受更开放的互操作性标准。当这些让步开始大规模出现时，市场从“卖方市场”转向了“买方市场”，从“挑客户”转向了“争订单”。这个转折点，才是投资者应该密切关注的核心信号。

在HBM4的周期中，如果三星在HBM4的初期就成为主力料号，那么SK海力士和美光没有历史份额的惯性可以依赖，它们必须从一开始就在价格和条款上保持竞争力。这会导致HBM4的定价竞争比HBM3E更激烈，格局转变的速度也更快。反之，如果三星在HBM4初期仍然只是边缘导入，主力平台由SK海力士和美光主导，那么格局转变会被延迟。这个“主力料号”的时间节点，是判断HBM4行业格局何时真正从“稀缺溢价”转向“兑现竞争”的最关键变量。

CHAPTER 03

Rubin Ultra平台与配套需求放大

■ 单柜功率跃升与液冷前置

Hopper时代，一个机柜大概50千瓦。Blackwell时代跳到120千瓦。Blackwell Ultra时代150千瓦。Rubin时代220千瓦。Rubin Ultra时代直接达到600千瓦。这个数字阶梯，每踏上一级，机房地板都在震动。

600千瓦是什么概念？一个普通居民楼的整栋楼用电功率，大概在几百千瓦到一两兆瓦之间。Rubin Ultra的一个机柜，相当于一栋居民楼的用电量。而且这不是平均功率，是持续满载功率，24小时不间断。

更夸张的是芯片层面的功率密度。下一代GPU典型芯片功率密度可以达到165瓦每平方厘米。这个热量密度已经逼近了传统散热的物理极限。单相冷板液冷的极限散热能力，最高大约200瓦每平方厘米。Rubin Ultra级别的芯片功率密度，已经占到了液冷极限的80%以上。如果未来芯片继续升级，功率密度再往上涨，现有的单相液冷方案就兜不住了。功率密度已经跨过了风冷的物理边界，液冷从“可选项”变成了“必须项”。

液冷的经济性门槛也已经跨过去了。2022年，液冷数据中心的1千瓦散热成本大概在6500元左右。但到了2023年，这个数字降到了5000元左右。传统风冷数据中心，考虑机房空间、空调设备、电力损耗等综合成本，1千瓦散热成本也差不多在这个区间。液冷和风冷在经济性上，已经基本持平。

这个成本下降的背后，是产业链的快速成熟。冷板、管路、快接头、液泵、CDU（冷却分配单元），这些液冷系统的核心部件，在过去两年里从“定制化”走向“标准化”。量一上来，价格就下来了。液冷带来的不只是散热效率的提升，还有整体能耗的下降。超微（Supermicro）推出的DLC-2方案给出了一个很有说服力的数据：液冷可以降低电力成本40%，降低TCO（总拥有成本）20%。风冷需要大量的空调设备，空调本身就要耗电。风冷的数据中心，为了让冷空气能够流通，机柜之间要留出很大的间距，直接浪费了机房空间。液冷的数据中心，机柜可以排得更密，空间利用率更高，空调设备可以大幅削减甚至去掉，省下来的电费和空间费非常可观。

一旦一个数据中心决定上液冷，这个决定就是不可逆的。机房的水管路、地板承重、机柜布局、电力分配、维护流程，全都要围绕液冷重新设计。基础设施的改造周期，通常以年为单位。一旦投入，就是长期的承诺。

Rubin Ultra的600千瓦机柜，对液冷系统提出了前所未有的要求。冷板内部的流道设计，必须确保每颗芯片都能得到均匀的冷却，不能有的地方热、有的地方凉。管路系统的压力控制，必须确保在数百个机柜同时运行时，不会出现局部流量不足。CDU的冗余设计，必须确保在单个CDU故障时，整个系统不会过热宕机。这些工程挑战，都是基础设施层面的硬约束。

液冷和供电这两个环节，从AI算力集群的“配套设施”，变成了Rubin Ultra能否成立的“前置条件”。缺少液冷，Rubin Ultra的机柜一上负载就会过热保护。缺少配套的供电升级，600千瓦的机柜电网根本扛不住。这两个环节，在2023年之前可能还被视为“锦上添花”的配角，在Rubin Ultra时代，它们已经变成了舞台中央的C位。

■ 规格下修对系统需求的放大

市场上有一个很直觉的推论：如果Rubin Ultra从4-die的高配版本下修到2-die版本，单颗GPU的价值量会下降，所以配套环节的需求也会跟着下降。这个逻辑听起来很顺，实际上有一个重大的隐藏假设：平台的总算力目标保持不变。

某个云厂商原本计划采购1000颗4-die版本的Rubin Ultra，每颗芯片算力是X，总算力目标是1000X。现在改成2-die版本，每颗芯片算力只有0.5X左右，要维持1000X的总算力目标，芯片数量就要变成2000颗。芯片数量翻倍，机柜数量也要跟着增加。如果原来一个机柜放32颗4-die芯片，现在一个机柜放32颗2-die芯片，但总算力只有一半，要维持同样的总算力，机柜数量就得翻倍。

机柜数量翻倍，意味着背板数量翻倍、网络端口数量翻倍、交换机数量翻倍。一个Rubin Ultra集群内部，芯片之间的互联密度非常高。机柜内部有背板互联，机

柜之间有交换机互联。芯片数量翻倍，这些互联件的数量不是线性增加，而是超线性增加。更多的芯片意味着更多的互联节点，更多的互联节点意味着网络拓扑更复杂，需要更多的交换机层级来支撑。

“降配等于减需求”的直觉，前提是“总算力目标也下降”。总算力目标不变，降配会导致系统件需求的被动放大。一个非常反直觉的结论，却是严格的数学关系。

■ 系统互联密度取代单芯规格

以前评价一个GPU平台，大家主要看单颗芯片的算力、显存、带宽。在Rubin这一代，系统的价值越来越依赖于机柜内部和机柜之间的互联密度，而不是单颗GPU的规格。AI训练任务的规模，已经到了单颗芯片无论如何都处理不完的程度。一个大模型训练任务，需要数千甚至数万颗芯片协同工作。协同的效率，取决于芯片之间的通信速度。芯片之间的通信带宽不够，芯片就算再强，大部分时间也是在等数据。系统级的互联架构，比单颗芯片的性能更决定整个平台的效率。

Rubin的NVLink和NVSwitch架构，把机柜内部和机柜之间的互联密度推到了新的高度。即使单颗芯片的规格下修，只要互联架构不变，系统的整体效率仍然很高。而且，因为芯片数量增加了，互联节点增加了，对背板、连接器、线缆、交换机这些系统件的需求，实际上是在增加的。

以前你卖的是一辆辆独立的跑车，每辆车都很贵。现在你在卖的是一个高铁网络，单个车厢的价格可能更低，轨道、车站、调度系统、信号系统的总价值，远超单个车厢。Rubin系统的价值逻辑，正在从“单颗芯片”转向“整个网络”。

Rubin Ultra从4-die下修到2-die，整个系统的物理架构都要重新设计。远非“芯片少了一半，其他不变”那么简单。

系统功耗分布会变化。4-die版本和2-die版本，芯片在PCB上的布局不同，热源的位置不同，液冷回路的设计就要跟着调整。原来某个冷板通道负责冷却两颗芯片，现在可能变成负责冷却一颗芯片，但流量分配、压力平衡、温度控制都要重新计算。直接照搬原来的液冷方案，很可能出现局部过热或者冷却过度，两者都会影响系统稳定性。

供电的瞬态响应也要重做。AI训练任务的负载波动非常大，可能在毫秒级别内从空闲跳到满载。2-die版本的芯片数量翻倍，意味着供电系统需要管理的瞬态负载节点翻倍。每个节点的电压、电流、纹波都要控制在很窄的范围内，否则芯片就会出错。供电系统的环路响应、去耦电容布局、电源分配网络的阻抗，全部都要针对新的芯片配置重新设计。

系统验证的复杂度，随之上升。原来验证一个4-die系统的热、电、网络、软件协同，现在要对2-die系统重新做一遍。而且因为芯片数量更多，互联关系更复杂，验证的排列组合更多。从芯片规格下修到系统量产之间的时间差，可能比预期更长。配套环节供应商的订单，不是在规格下修后减少，反而可能因为系统件数量增加和验证周期拉长，获得更持续的需求。

市场直觉认为“降配等于减需求”。真实的产业链逻辑是：规格下修，芯片数量上升，系统件需求补偿，系统验证复杂度上升。配套环节是被被动放大的受益方。

CHAPTER 04

CX9网络与整网验证瓶颈

■ 高带宽交换机的整网验证难题

英伟达在GTC 2025上放出的数字听起来很霸气：115.2T的InfiniBand CX9交换机，2025年先给GPU交换方案铺两三千台，2026年目标直接拉到1万台。懂行的人看到这组数字，第一反应不是“好厉害”，而是“等等，这得验证到什么时候”。

交换机这东西，从来不是芯片做出来就能上市的。它更像是一辆车——发动机再猛，变速箱、悬挂、刹车、轮胎有一个不匹配，这车就没法跑。CX9这一代，115.2T的带宽意味着什么？单台交换机要处理的数据流量，相当于把整个北京市早高峰的车流塞进一条高架桥。这已经不是“芯片能不能跑满”的问题，而是“整条路能不能扛住”的问题。

英伟达2025年的计划只有两三千台，这个数字非常克制。它不是做不出更多，而是不敢做更多。这两三千台的核心任务不是卖货，而是“验证”——验证协议栈在超大规模集群下的稳定性，验证光引擎在高速率下的误码率，验证散热在持续高负载下的衰减曲线，验证布线在机柜间穿梭时的信号完整性，验证维护模型在故障发生时的响应速度。每一个单项都有实验室数据，但实验室数据和大规模集群数据之间，隔着整整一个“工程地狱”。

从试点到大规模集群切换，最大的风险不是某一台交换机坏了，而是坏的时候你不知道怎么修。传统数据中心，一个机柜出问题，工程师走过去，拔线、换板、重启。在CX9这种级别的网络里，一个故障可能同时涉及协议层、光层、电层、散热层，而且症状在A点表现出来，根因可能在B点。没有成熟的运维体系，这种故

障就是灾难。

2025年根本不是放量年，而是“验证规模年”。两三千台的量，刚好够英伟达和它的核心客户把系统级调试跑一遍。这个过程中，会发现很多芯片设计阶段根本想不到的问题。协议栈在某种特定流量模式下会抖动，光引擎在某种温度梯度下会偏置，散热在某种布局下会形成热点。这些问题不是不能解决，但解决需要时间。

■ xPO与CPO对维护体系的重构

CX9这一代还有一个更大的变量：xPO和CPO方案。

传统网络架构里，光模块是独立的，坏了就拔下来换一个新的。这相当于你的电脑显示器坏了，拔线换个显示器，完事。但xPO和CPO把传统模块侧的功能前移，直接集成到交换机内部。光引擎、交换芯片、甚至部分信号调理电路，都被封装在一个更大的系统里。

好处是集成度更高、延迟更低、功耗更省。代价是，维护方式被彻底重构。

以前，一个光模块坏了，运维人员拿着备件走过去，几分钟换好。光引擎集成在交换机内部，故障隔离和备件更换的逻辑完全变了。你需要诊断的是：到底是光引擎的问题，还是交换芯片的问题，还是两者之间的互连问题？诊断复杂度呈指数级上升。而且，如果故障点需要更换整个交换机板卡，那维护成本和时间完全不在一个量级。

2025年只能叫“验证规模年”，2026年才能叫“复制规模年”。2025年要做的，不只是把设备卖出去，而是把整个运维体系搭起来。从故障诊断流程到备件策略，从现场工程师的培训手册到远程监控的阈值设定，这些都要在真实环境里跑一遍。只有这套运维体系被验证通了，2026年的1万台才能顺利部署。

■ 调试可复制性决定放量拐点

CX9的瓶颈从来不在交换芯片本身。115.2T的芯片，英伟达设计能力没问题，台积电制造工艺也没问题。真正的瓶颈在于：从“一台交换机能工作”到“一万台交换机能稳定工作且能被有效维护”，这中间的距离有多远。

放量拐点可以定义为“系统调试可复制”。某个云厂商在A数据中心成功部署了一套CX9集群，它能不能用同一套方案、同一套运维流程，在B数据中心快速复制，而且不出新的问题。这个“可复制性”，才是决定CX9能否从2025年的两三千台跳到2026年1万台的关键。

如果可复制性没打通，2026年的1万台就会变成一个又一个的定制项目。每个数据中心都需要重新调试、重新适配、重新培训运维团队。这种情况下，出货量不是被芯片产能限制的，而是被工程师人数和调试周期限制的。

观测CX9是否真正进入放量期，不要看芯片出货量，要看系统级调试的周期是否在缩短。某个客户从下单到上线的时间越来越短，而且故障率稳定下降，这才说明可复制性被打通了。反之，如果每个项目都在延期，都在出各种稀奇古怪的故障，那CX9的放量就会比英伟达规划的时间表晚很多。

CHAPTER 05

供需缺口收敛与股价定价逻辑

■ 最紧时刻预期与股价提前见顶

从制造到封装需要5到6个月，再加上认证环节的时间时滞，当前锁定的高景气订单，其实际会计兑现周期可能跨越年度。今天签下的订单、今天锁定的价格，真正变成利润表上的收入和毛利率，可能要等到明年。在这漫长的等待期里，无数变量可能发生变化：客户需求可能放缓、竞争对手可能突破、技术路线可能调整、宏观经济可能波动。

交付速度慢于预期，或者新增需求的斜率低于预期，估值就会先于利润调整。资本市场的铁律：估值是对未来的贴现，利润是对过去的确认。未来变得模糊时，贴现率就会上升，估值就会下修。利润由于已经有订单在排队、有产线在运转，可能在短期内保持惯性，直到几个季度后才会真正反映需求的变化。

某家HBM供应商的出货量还在增长、营收还在创新高，股价已经开始下跌。这不是市场错了，而是市场在提前消化“远期利润兑现的不确定性”。出货量增长是已经锁定的过去，股价下跌是对未来不确定性的提前反应。两者的时差，就是那5到6个月的制造周期，加上3到6个月的认证周期，再加上1到2个季度的财务确认周期。总的时间差可能长达一年以上，而市场的估值调整，往往在这个时间差的中段就已经开始了。

股价等于未来现金流的贴现值。未来现金流取决于当期的利润，更取决于对未来利润路径的预期。市场认为一个行业正处于供需缺口最紧的阶段，它会给出很高的估值，预期未来的利润会持续高企。市场认为缺口最紧的时点已经过去，即使当期利润还在上升，市场对未来利润的预期路径也会下调，从而导致估值收缩和股价下跌。

在HBM4的周期中，有几个关键信号会被市场解读为“最紧时刻已经过去”的拐点。第一个信号是新供应商的认证突破。当三星在HBM3E上迟迟未能通过英伟达认证时，SK海力士和美光享受了两家垄断的定价权。三星通过认证，市场立刻会预期供给增加、价格竞争加剧，即使三星的正式出货还要几个月，股价也会提前反应。第二个信号是价格谈判的松动。当客户开始和供应商重新谈价格、缩短LTA的覆盖期限、或者不再接受溢价时，这意味着客户的紧迫感下降了，供应商的定价权在弱化。第三个信号是库存或交货周期的改善。当供应链调研显示HBM4的交货周期从52周缩短到40周、再到26周时，即使价格还在高位，市场也会认为紧张的态势在缓解。

在HBM3E的周期中，SK海力士的股价在2025年上半年达到高点，但当时它的HBM3E利润还在持续上升。为什么股价提前跌了？市场从2025年初就开始看到三星的认证进度在改善、台积电的CoWoS产能在扩张、英伟达的订单结构在调整。这些信号让市场判断：HBM3E的供需缺口虽然还在，但最紧的时刻已经过去了。后来的事实证明，虽然SK海力士2025年的HBM利润确实很好，但估值已经从2025年高点的30倍以上PE回落到2026年初的20倍以下。利润上升了，估值下降了，股价自然被压住。

“利润上行、估值下行、股价横盘或下跌”的组合，在周期性股票中非常常见。HBM4的股价高点和利润高点之间的时间差，可能比HBM3E更大。HBM4的认证周期更长，从“认证通过”到“大规模出货”之间的时间窗口也更宽。在这个窗口期，市场会看到“新供应商加入”的信号，但还不会看到“价格竞争加剧”的现实。“预期走在现实前面”的特性，会让股价的见顶时间比利润的见顶时间更加提前。投资者如果只看当期财报来线性外推，很容易在股价高点附近接盘，然后看着利润持续增长但股价不断下跌。

破解这种困惑的方法：把注意力从“当期利润”转移到“缺口的边际变化”上。看未来会不会更紧，比看现在有多紧，更有价值。

■ 缺口的摆动速度比短缺本身更危险

供需缺口最危险的状态，不是缺口本身有多大，而是缺口从“扩大”到“收缩”的摆动速度有多快。在缺口扩大的阶段，供应商是挑客户的，谁给的价格高、谁签的LTA长，谁就能拿到货。客户被迫接受溢价、接受严格的绑定条款，甚至要提前半年到一年锁定订单。供应商的利润率和现金流都非常好，股价也享受稀缺溢价。缺口开始收缩，市场的力量对比会迅速反转。客户从“求着买”变成“挑着买”，供应商从“挑客户”变成“争订单”。这种转换的速度，往往比大多数人想象的要快得多，股价往往在这个转换完成之前就已经见顶。

DDR4到DDR5的切换过程，给过一个非常经典的教训。2020年到2021年，远程办公和数据中心扩张导致DDR4的需求暴增，供给端因为晶圆厂产能紧张、原材料短缺，迟迟无法跟上。那段时间，内存厂商的利润率高企，股价也一路飙升。到了2022年，情况急转直下。晶圆厂的新产能开始释放，客户的需求因为PC和智能手机出货量下滑而减弱，供需关系从极度短缺迅速转向过剩。内存价格从2022年高点下跌了超过50%，一些厂商的内存业务甚至出现了亏损。股价从2021年下半年就开始见顶回落，而不是等到2022年价格下跌才反应。市场从2021年中期就开始看到产能扩张的信号、需求放缓的信号，从而预期缺口的顶点已经过去。

这种“从挑客户到争订单”的摆动，在HBM4的周期中可能会更加剧烈。HBM4的客户集中度极高，英伟达、AMD、谷歌等几家大客户就占了绝大部分需求。当供给短缺时，这些大客户为了确保供应链安全，愿意同时和多家供应商签LTA，甚至接受溢价。供给开始缓解，这些大客户的议价能力会迅速放大。他们可以利用供应商之间的竞争来压低价格、缩短合同期限、增加灵活性条款。HBM4的技术门槛虽然高，但主要供应商（三星、SK海力士、美光）最终都有能力量产，长期看，HBM4的供给弹性比很多人想象的要大。一旦认证瓶颈突破，供给的释放速度可能会很快，从而加速从“短缺”到“过剩”的摆动。

股价在这个摆动之前见顶。市场在看的是“缺口的边际变化”，“缺口的绝对水平”反而居于次要地位。缺口还在扩大时，即使绝对水平还不是历史上最大的，边际方向是向上的，估值也会扩张。缺口达到最大并开始收缩时，即使绝对水平仍然很高，边际方向是向下的，估值就会收缩。股价是估值和利润的乘积，估值收缩的速度往往比利润增长的速度更快，所以股价会在利润见顶之前就开始下跌。

在HBM4的投资中，最大的风险是“短缺结束的预期形成”。“短缺结束了”这个事件本身，反而没有预期危险。这个预期一旦形成，就会提前反映在股价中，投资者如果还在看当期利润，就会错过最佳的离场时机。

■ 订单收入利润高点的时间错位

在HBM4这样的复杂供应链中，“订单热度”“收入确认”和“利润率峰值”这三个指标，出现在同一个季度的概率极低。它们之间的时间错位，是由产业链的运作机制决定的，线性外推任何一个单一指标，都会产生严重的预期差。

订单热度的高点，通常出现在供需缺口最紧的时候，也就是客户最恐慌、最愿意抢单的时候。客户会大量下单，甚至提前锁定未来几个季度的需求。供应商的订单簿看起来非常饱满，给市场的信号是“需求非常强劲”。但这些订单中，有一部分是客户的“预防性库存”，是为了避免断供而提前锁定的，并不代表真实的

需求增长。供给开始缓解时，客户会取消或推迟这些预防性订单，导致订单热度迅速下降。订单热度的高点，往往出现在供给最紧、客户最恐慌的时刻，而不是需求真正最高的时刻。

收入确认的高点，通常滞后于订单热度。HBM4从接单到出货需要经历封装、测试、认证、系统集成等多个环节。即使客户在Q1下了大量订单，供应商可能要到Q2甚至Q3才能确认收入。认证环节出现延迟，已经封装完成的产品也无法确认收入，只能在库存里等待。收入确认的高点，不仅取决于订单的热度，还取决于供应链的运作效率和认证的进度。在认证瓶颈突破后，前期积压的库存会集中释放，导致收入出现一个脉冲式的高峰。但这个高峰可能是过去几个季度订单的集中兑现，而不是当期需求的爆发。如果把这种脉冲当成趋势，就会高估未来的收入增长。

利润率的高点，又和收入确认不同步。在供需缺口最紧的时候，供应商确实可以享受很高的溢价，毛利率和营业利润率都处于高位。新供应商进入、竞争加剧，价格会开始松动。利润率对价格的敏感度非常高，因为HBM4的固定成本（设备折旧、研发投入）占比很大，价格的微小下降会大幅压缩利润。利润率的高点，往往出现在价格仍然高位但竞争开始加剧的过渡期，而不是收入最高的那个季度。在HBM3E的周期中，SK海力士的HBM业务收入在2025年下半年仍然强劲，但利润率已经开始从峰值回落，因为三星的重新进入和价格谈判的松动已经在压缩溢价空间。

这三个指标的错位，意味着投资者在分析HBM4相关股票时，不能简单地看一个指标就线性外推。

只看订单热度，可能会忽略认证延迟导致的收入兑现风险。只看收入确认，可能会把库存释放的脉冲当成可持续的增长。只看利润率，可能会错过估值收缩的先兆。

真正的分析框架，应该把这三个指标放在时间轴上，看它们的相位关系和领先滞后结构。订单热度是领先指标，收入确认是同步或滞后指标，利润率是滞后但敏感指标。订单热度开始下降、收入确认还在上升，警惕的是“虚假繁荣”。收入确认还在高峰、利润率开始下滑，警惕的是“量价背离”。多指标的交叉验证，是避免线性外推陷阱的唯一方法。

■ 第二供应源形成与估值逻辑切换

在存储行业的历史周期中，股价通常在市场开始相信“第二供应源正在形成、涨价斜率将放缓”的时候提前见顶，而不是等到产能真正过剩、价格真正下跌的时候才见顶。

股价对“预期”定价，而非对“现状”定价。市场上只有一家供应商能供货时，预期是“供应永远紧张、价格永远上涨”。第二家供应商接近突破时，预期转向“紧张即将缓解、上涨即将放缓”。实际的供需转折点尚未到来，预期的转折点已经足以让股价提前反应。
